

Kategoriske udfald

WebR Status

 Ready!



Kategoriske udfald

Kategoriske variable er variable hvor observationerne kan falde i en af flere (mindst to) kategorier.

Køn, rask/syg, død/levende, hvilken region har man folkeregisteradresse i.

Der er ikke nødvendigvis en orden: Det er ikke bedre at være mand end at være kvinde.

Men der kan være - socialklasse eg.

Der kan vi ikke beregne gennemsnit. Så hvad gør vi så?

Vi tæller



Kategoriske udfald

Når vi tæller får vi at vide hvor mange der er af hver.

Vi kan beregne hvor stor en andel de forskellige kategorier udgør af det samlede hele.

Vi vil blive spurgt:

- Er der forskel på de andele grupperne imellem?
- Kan vi sige noget om hvad sandsynligheden for at være i den ene gruppe kontra den anden?
- Og hvor sikre er vi på vores estimer?



Kategoriske udfald

Så vi skal kigge på:

- Proportioner - også kendt som andele
- Relativ risiko
- Odds ratio
- Chi i anden



En opgave

Vi skal se på prævalensen af tuberkulose blandt stiknarkomaner og om den er afhængig af om der deles sprøjter med andre narkomaner.

I en gruppe med 97 narkomaner der deler sprøjte med andre narkomaner, testede 24.7% positiv for TB.

I en gruppe på 161 narkomaner der ikke delte sprøjte, testede 17.4% positive for TB.

Hvis vi antager at prævalensen ikke afhænger af om der deles sprøjter - hvad estimerer vi så prævalensen til at være?

▶ Run Code

↺ ↻

1



Hvor sikre er vi på det tal?

Opgaven fortsætter:

Angiv også et 95% konfidensinterval på det estimat.

Estimatet er en andel. Også kaldet en proportion. Eller p .

Metoden har vi set før.

$$\textit{estimat} \pm 1.96 \cdot SE$$

Det ligner næsten et mønster...

Så - hvordan beregner vi en standardfejl på estimatet af en proportion?

$$SE_{prop} = \sqrt{\frac{p \cdot (1-p)}{n}}$$

Man kan godt udlede hvorfor SE_{prop} har det udseende. Det bliver vi ikke spurgt om, så det springer vi over.



Hvor sikker var vi?

Hvad er et 95% KI for prævalensen af TB blandt stiknarkomaner, hvis vi antager at den ikke afhænger af om man deler sprøjte eller ej?

Proportionen beregnede vi til 0.2015504

Standardfejlen er givet ved:

$$SE_{prop} = \sqrt{\frac{p \cdot (1-p)}{n}}$$

Der var 258 observationer i stikprøven

$estimat \pm 1.96 \cdot SE$

```
Run Code
1
```



Videre med samme opgave

Undersøg hypotesen om at risikoen for at få TB for stiknarkomaner ikke afhænger af om man deler sprøjte eller ej. Argumenter ud fra relevant KI.

Hvordan gør vi det? Eller: Hvad vil det egentlig sige at risikoen for TB er uafhængig af om der deles sprøjter?

Det kan vi gøre på fire måder:

Forskellen på de to prævalenser er 0

Den ene prævalens divideret med den anden er 1 (for så er de ens)

I stedet for prævalenser kan vi beregne odds. Og se om odds er ens. Det kræver at vi lige finder ud af hvad “odds” egentlig er...

Kan vi undersøge om fordelingen af TB er forskellig i de to grupper?

Vi tager dem en for en

Hvis I har fået fat i modelbesvarelsen for denne opgave - bemærk at der er en regnefejl, fordi nogen har byttet om på n for de to grupper.



Forskel på prævalenser

Er forskellen i virkeligheden 0?

Eller - vi opstiller en NULL-hypotese, $H_0 : p_{TB:deler} - p_{TB:delerikke} = 0$

Den alternative hypotese er så, at der er forskel på prævalensen.

Samme metode som før:

$$\text{estimat}_{diff} \pm 1.96 * SE_{diff}$$

Er 0 indeholdt i det 95% KI, kan vi ikke afvise NULL-hypotesen.

1.96 fordi vi implicit har valgt $\alpha = 0.05$ og der er tale om to samples der ikke er parrede. Vi kan også sammenligne med testværdien.

Så... Hvordan beregner vi SE_{diff} ?

Helt som før

$$SE_{diff} = \sqrt{SE_1^2 + SE_2^2}$$

Og standardfejl på de enkelte proportioner var: $SE = \sqrt{\frac{p(1-p)}{n}}$




Så kan vi regne

- Prævalens af TB blandt de 97 der delte sprøjter: 24.7%
- Prævalens af TB blandt de 161 der ikke delte sprøjter: 17.4%

- $SE = \sqrt{\frac{p(1-p)}{n}}$

- $SE_{diff} = \sqrt{SE_1^2 + SE_2^2}$

Run Code



1



Forholdet mellem de to prævalenser?

At de måske er ens kan vi også udtrykke ved at den ene divideret med den anden giver 1.

Den hypotese vi så tester er:

$$H_0 : \frac{p_{deler}}{p_{delerikke}} = 1$$

Så hvad kan vi, hvis estimatet er tilstrækkeligt forskelligt fra 1?

Afvise H_0 .

Metoden er den samme som før. Estimatet $\pm 1.96 \cdot SE$

Eller beregne en test-værdi og sammenligne med den kritiske værdi.

Prævalensen for TB kan vi også kalde risikoen for at have TB. Eller risk. Forholdet mellem to tal kalder vi også en ratio. Så i jeres branche kalder I det her for - tada - Risk Ratio. Eller RR.



Komplikationer

Så skal vi “bare” beregne SE.

Det er lidt bøvlet - og derfor var metoden med KI på differencen den første vi så på (og den foretrukne).

Vi har nemlig ikke en let formel for standardfejlen på en riskratio.

Det vi har er en formel for standardfejlen af *logaritmen* af RR.

Og derfor skal vi se på:

$$\log RR \pm 1.96 \cdot SE_{\log RR}$$

Hvordan gør vi så det?



SE for log(RR)

For det generelle forhold:

	udfald 1	udfald 2
eksponeret	a	b
ikke eksponeret	c	d

Hvad er risikoen for udfald 1 hvis man er eksponeret?

$$\frac{a}{a+b}$$

og hvis man ikke er eksponeret:

$$\frac{c}{c+d}$$

Så gælder det at:

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$



Og så er vi ca. klar til at regne

Prævalensen af TB blandt de 97 der delte sprøjter var 24.7%.


Prævalensen af TB blandt de 161 der ikke delte sprøjter var 17.4%

Bonus: Hvordan finder vi - fra det - nedenstående tal?

TB	deler	deler ikke
TB-positiv	24	28
TB-negativ	73	133

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$

Run Code



1



Hvad så vi?

RR var 1.42268.

Hvordan vil vi fortolke det?

Det vil vi formulere som at “risikoen er 42% højere” for at være TB+ hvis man deler sprøjter, end hvis man ikke gør.

Men. KI for RR var [0.877; 2.307]

Det indeholder 1. Og derfor er der ikke statistisk signifikant forskel på risikoen for at teste positiv for TB hvis man deler sprøjter.

Vi kunne også se på KI for $\log(RR)$, der var [-0.131; 0.836]. Det indeholder 0.

Også derfor er der ikke (statistisk signifikant forskel).

Hvorfor? Fordi $\log(1) = 0$.

Vi kunne også få teststørrelsen ved $\frac{\log(RR)}{SE(\log(RR))}$. Den var 1.429.

Mindre end den kritiske værdi.



Odds - hvad er det?

Blandt de 97 narkomaner der delte sprøjter var 24 TB+.

Det gav en risiko for at være TB+ på 24/97.

Eller sandsynlighed. Eller prævalens af TB+ blandt... eller risiko for at være TB+ hvis...

Det kan vi udtrykke anderledes - ved odds.

Det er antallet af positive udfald divideret med antallet af negative udfald.

Eller: 24/73

Hvorfor? Matematikken bliver en del mere medgørlig hvis vi regner i odds.



Odds - fordelene

Hvis sandsynligheden for et positivt udfald er 10%

Er der, ved 10 observationer 1 positivt og 9 negative udfald.

Som sandsynligheder: 0.1 og 0.9 hhv.

Som odds: 1/9 og 9/1 hhv.

Det er intuitivt hinandens modsætninger.

Og:

```
1 log(1/9)
```

```
[1] -2.197225
```

```
1 log(9/1)
```

```
[1] 2.197225
```

Hvor er det bare pænt og symmetrisk! Og lige langt fra $\log(1) = 0$



Hvad tester vi så med odds?

(Næsten) det samme som med Risk Ratio. Nu blot Odds Ratio.

Er odds for at være TB+ når man deler sprøjter den samme som odds for at være TB+ når man ikke deler sprøjter?

Eller:

Kan vi afvise H_0 :

$$\frac{\text{odds}_{\text{TB+}: \text{deler}}}{\text{odds}_{\text{TB+}: \text{deler ikke}}} = 1$$

Kan I gætte hvordan vi beregner et 95% KI på det?

Fuldstændig som før:

estimat $\pm 1.96 \cdot \text{SE}$



Lignende problem som med SE for RR

Problemet med at beregne SE for OR er nøjagtig det samme som for RR.

Løsningen er ca. den samme. Vi har en pæn formel for $SE(\log(OR))$

For det generelle forhold:

	udfald 1	udfald 2
eksponeret	a	b
ikke eksponeret	c	d

$$\text{Får vi: } SE(\log(OR)) = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

$$\text{Sammenlign med } SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$


Og se hvorfor jeg mener at matematikken bliver enklere med odds...



Så er vi klar til at regne

TB	deler	deler ikke
TB-positiv	24	28
TB-negativ	73	133

Run Code



1

$$SE(\log(OR)) = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

$$\log OR \pm 1.96 \cdot SE(\log OR)$$



Hvad så vi

OR var 1.56

Det vil vi formulere som at odds for at teste positiv for tb er 56% højere hvis man deler sprøjter end hvis man ikke gør.

Men 95% konfidensintervallet på log-OR var [-0.170; 1.061]

Og da 0 er indeholdt i intervallet kan vi afvise hypotesen om at odds er højere for at være TB+ hvis man deler sprøjter, sammenlignet med hvis man ikke deler sprøjter.

Vi kunne også finde testværdien: $\frac{\log OR}{SE(\log OR)} = 1.420$. Den er mindre end den kritiske værdi (1.96), hvorfor vi ikke kan afvise H_0 .

95% konfidensintervallet på OR var [0.844; 2.890]. 1 er indeholdt i intervallet, og vi kan derfor ikke afvise H_0

Vær skarpe her. Odds er noget andet end risiko. Så husk *altid* at skrive odds i stedet for risiko.

Hvorfor finder vi testværdien ved $\log(OR)/SE(\log OR)$? Fordi OR ikke er pæn og symmetrisk og normalfordelt. Men det er $\log(OR)$! Og så fungerer matematikken.



Hvad hvis OR var mindre end 1?

En OR på 1.56 betød at odds var 56% større for (det vi undersøger), end for (det vi sammenligner med).

Hvad hvis OR havde været 0.95?

Ja, så havde odds været 5% mindre end (det vi undersøger) end for (det vi sammenligner med).



Fra sandsynlighed til odds

Hvordan beregner vi odds hvis vi kender sandsynligheden?

$$\text{odds} = \frac{p}{1-p}$$

Hvordan beregner vi sandsynligheden hvis vi kender odds?

$$p = \frac{\text{odds}}{1+\text{odds}}$$

En særlig funktion vi kommer til at møde igen:

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$$

logit funktionen tager sandsynligheden for et givet udfald, og returnerer log-odds for det udfald.

Den omvendte kan også være nyttig. Hvis $x = \text{logit}(p)$:

$$p = \frac{e^x}{1+e^x}$$

Det er den inverse logit-funktion. Også (spoiler alert) kaldet logistic-funktionen.

Og hvor ville verden dog være rar hvis de funktioner var indbyggede i R. Er verden rar? Nej, det er den ikke. Derfor findes den funktion heller ikke i R.



χ^2 tilgangen

Mere generel - kan håndtere mere end et udfald.

Sjælden til eksamen - kræver tasteri, og det er ikke hvad I bliver testet i.

Tester forskellen på den fordeling vi ser - og den vi ville forvente

Hvis vi kun kender totalerne

	TB+	TB-	Total
Deler sprøjter	?	?	97
Deler ikke	?	?	161
Total	52	206	258

Og fordelingen af TB+ og TB- er den samme blandt de der deler sprøjter, som de der ikke deler sprøjter

Hvor mange forventer vi så har TB blandt de der deler sprøjter?



Regne-regne

52 ud af 258 er TB+. Hvis der er 97 der deler sprøjter - men det at dele sprøjter ikke påvirker om man tester positiv for TB.

Så må der være $\frac{52}{258} \cdot 97 \approx 20$ der tester positiv.

Det er hvad vi forventer. Men vi ser at der er 24.

Blandt de 161 der ikke deler sprøjter, vil vi med samme antagelse forvente at se $\frac{52}{258} \cdot 161 \approx 32$ der tester positiv.

Det er hvad vi forventer. Men vi ser at der kun er 28.

Vi laver de samme beregninger på de to andre celler. Og så tester vi om der er forskel på hvad vi ser. Og hvad vi forventer (hvis der ikke er forskel).



Regne-regne

χ^2 testens H_0 er, at der ikke er forskel på fordelingen af TB-status i de to grupper.

Testens p-værdi er sandsynligheden for at se så store forskelle på hvad vi forventer, og hvad vi faktisk observerer, i data. Hvis der i virkeligheden ikke er forskel på fordelingen af TB-status i de to grupper.

Styrken er at den kan håndtere flere udfald end to.

Svagheden er at den ikke fortæller hvilken gruppe der har størst risiko for at teste positiv for TB. Blot at der er forskel på fordelingen i de to grupper.

Og så forudsætter χ^2 testen at der er mindst 5 *forventede* observationer i hver “celle”.

Det kan man korrigere for, og det gør R funktionen automatisk. Her har vi så store forventede værdier at vi bør slå korrektionen fra.

Funktionen hedder `chisq.test()`. Med argumentet `correct = FALSE` hvis vi vil slå den fra.




Hvordan gør vi?

En smule bøvlet - for vi skal have data ind i en matrix.

```
1 tab <- matrix(  
2   c(24, 73,  
3     28, 133),  
4   nrow = 2,  
5   byrow = TRUE  
6 )  
7  
8 dimnames(tab) <- list(  
9   Exposure = c("Deler", "Deler_ikke  
10  TB = c("Ja", "Nej")  
11 )
```

▶ Run Code



1



p-værdien?

Det er vist første gang vi støder på den.

Testværdien fortæller hvor langt fra H_0 vi er, målt i standardafvigelser.

Hvis vi placerer testværdien i normalfordelingen [link](#), så svarer det til en sandsynlighed.

Den sandsynlighed er sandsynligheden for at vi ser en testværdi af den størrelse, eller større, hvis H_0 er sand.

Det kan vi også forstå som risikoen for at vi afviser H_0 , selvom H_0 faktisk er sand.

Så når vi afviser H_0 , fordi testværdien er langt væk, er der stadig en sandsynlighed for at vi tager fejl.

Det er helt i orden, det er der altid, den skal bare være lille nok.

Her var sandsynligheden 0.154. Eller 15%

Hvis vi afviser H_0 , er der altså 15% sandsynlighed, risiko, for at vi afviser den selvom den er falsk.

Eller, mere teknisk korrekt, sandsynligheden for at vi ser data der er så ekstreme som det er tilfældet (ekstreme relativt til H_0), hvis H_0 er sand. Og selvom det er teknisk mere korrekt, er det her I bliver forvirrede, så hold jer til intuitionen om at det er risikoen for at begå en type-1 fejl.

Det kalder vi også en type-1 fejl. En falsk positiv. Vi tror vi har evidens for at den alternative hypotese er sand. Men det har vi ikke.



Sammenfattende

Det er ca. altid:

Estimat $\pm 1.96 \cdot \text{standardfejlen}$

Undertiden er estimeret logaritmen til det vi er interesseret i. Så er det også standardfejlen på logaritmen til estimeret.

Den kritiske værdi er 1.96. Den knytter sig til 95% KI. Skal I bruge et andet interval - så er det en anden kritisk værdi. Hint: `qnorm`.

Og så skal standardfejlen beregnes forskelligt - afhængig af hvad det er vi tester.



Og hvilken skal man så vælge?

- Forskel i proportion
- RR
- OR
- χ^2

Hvis opgaven nævner odds. Så skal I bruge OR. Taler den om risici. Så er det RR. Hvis den “bare” taler om forskel, så er det forskelle i proportioner. Hvis den taler om at det skal undersøges om der er forskel på fordeling. Så er det χ^2 .

Forskelle i proportioner måler absolutte forskelle. Mens RR måler relative forskelle. Hvad er forskellen? => Forskelle i proportioner. “Hvor meget større end?” => Som regel RR.

Husk: χ^2 *kun* svarer på om der er forskel i fordelingen af eg TB i to grupper. Den svarer *ikke* på om der er større risiko i den ene gruppe end den anden.

Læs også det næste delspørgsmål. Hvis der optræder en logistisk regression. Så beregner I OR. Optræder der RR i delspørgsmål b, så skal I formentlig også regne RR i delspørgsmål a.

Men den hemmelighed I nok ikke har fået fortalt er, at de her fire måder at se forskel, faktisk er ret ens...



Hvor ens er de?

Tag denne 2x2 tabel:

	Treatment	Placebo
Syg	42	27
Rask	58	73

Er der forskel på andelen af syge hhv raske i de to grupper?

Type	Testværdi
$p_1 - p_0$	2.259538
OR	2.217594
RR	2.186153
χ^2	4.978427
χ	2.231239



For tidlig fødsel

Et studie i England undersøgte faktorer for tidlig fødsel blandt 1513 gravide kvinder og fandt at incidensen for tidlig fødsel var 7.5%.

Beregn 95% KI for insidensen for tidlig fødsel baseret på disse tal.

Hvordan ser et 95% KI ud?

estimat $\pm 1.96SE$

Hvordan ser SE for en andel ud?

$$SE_{prop} = \sqrt{\frac{p(1-p)}{n}}$$

Har I fået fingre i modelbesvarelsen, er der en tastefejl i standardfejlen.

```
Run Code
1
```



For tidlig fødsel - i Danmark

Et tilsvarende dansk studie med 51851 kvinder fandt en incidens på 4.5%
Estimer forskellen i incidensen for tidlig fødsel i England vs danmark.
Er der signifikant forskel?

Hvad er H_0 ?

$$H_0 : p_{gb} - p_{dk} = 0$$


Hvordan ser den samlede standardfejl ud?

$$SE_{diff} = \sqrt{SE_1^2 + SE_2^2}$$

$$p_{gb} = 7.5\%, n_{gb} = 1513$$

Der spørges til forskel i incidens. Ikke til forskel i risiko eller odds. Eller om der er forskel i fordelingerne de to lande imellem.

Run Code



1

