


Lineær regression

WebR Status

 Ready!



Hvad er det nu det er?




Vi ved ikke hvad x og y er. Pointen er at det ser ud til at der er en lineær sammenhæng mellem x og y. Når x stiger, stiger y også. Hvordan ser den lineære sammenhæng ud?



En ret linie

Her har vi lagt en ret linie ind. Men er det den bedste? (spoiler: Det er den)



Den beskriver en sammenhæng mellem x og y.



Lineær regression

I husker måske at en ret linie kan beskrives som

$$y = ax + b$$


Opgaven er altså at finde den rette linie, beskrevet ved a og b , der bedst beskriver sammenhængen mellem x og y .

Hvordan gør vi det?



Lineær regression

Linien fortæller: Hvis x har en bestemt værdi, hvilken værdi burde y så have?



Den værdi har y *ikke*. Forskellen kalder vi “residualen”.



Lineær regression

Alle punkterne har en residual.

En afvigelse fra den “sande” værdi.

Vi vil derfor skrive at:

$$y = ax + b + \epsilon$$


Den “bedste” linie er den hvor summen af residualerne, ϵ , er mindst mulig.

Der er en del sjusk i notationen både her, overalt på nettet og i eksamensopgaver, hvor vi skriver $y = ax + b$. Det er ikke korrekt, for ϵ mangler.

$\hat{y} = ax + b$ er mere korrekt.



Lineær regression



Læg mærke til at residualen er negativ for det med rødt markerede punkt.
Andre punkter har en positiv værdi.

Hvad sker der hvis vi lægger dem alle sammen sammen?

Vi risikerer at resultatet bliver 0 - fordi summen af positive og negative tal kan risikere at blive 0.



Lineær regression

Så vi kvadrerer residualerne og lægger dem sammen.

Den sum forsøger vi at minimere ved at vælge a og b.

Derfor kalder vi også metoden for “mindste kvadraters metode”. Eller OLS - Ordinary Least Squares.

Det kunne man gøre med papir, blyant, lineal og lommeregner.

Det er der ingen der gider

Så vi bruger funktionen `lm()`



Det generelle eksempel

Hvis vi vil finde ud af hvordan x beskriver y, skriver vi:

```
lm(y ~ x, data = df)
```

Læs det som: y som funktion af x.

Den giver et output:

Call:

```
lm(formula = y ~ x, data = data)
```

Coefficients:

(Intercept)	x
44.15	42.76



De enkelte dele

```
1 lm(y ~ x, data = data)
```

y er den afhængige variabel, x er den uafhængige.

Eller:

y er responsvariabel, og x er forklarende.

Der gemmer sig mere information!



Outputtet

Gem resultatet og kør funktionen “summary” på det gemte resultat:

```
1 lineær_model <- lm(y ~ x, data = data)
2 summary(lineær_model)
```

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	44.153	5.442	8.113	1.49e-10	***
x	42.764	0.913	46.840	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Hyppig eksamensopgave: Her er output af det I burde have svaret i opgave 1a). Hvilken regression er der tale om? Fortolk resultaterne.

Så lad os kigge på de enkelte dele, så vi ved hvad de dækker over.



Call og Residuals

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	44.153	5.442	8.113	1.49e-10	***
x	42.764	0.913	46.840	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Call er den funktion vi faktisk kørte for at få dette resultat. Den er som regel redigeret væk.

Residuals er summary statistics på residualerne. Vi bruger dem til at tjekke modellen. De er som regel også redigeret væk.



Koefficienter - Estimate

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	44.153	5.442	8.113	1.49e-10	***
x	42.764	0.913	46.840	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Estimaterne er koefficienterne i $y = ax + b$. Intercept er b , x er koefficienten der ganges på x værdien, her altså a .

Den model vi har bygget er altså:

$$\hat{y} = 44.153 + 42.764x$$



Koefficienter - Std. error

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	44.153	5.442	8.113	1.49e-10 ***
x	42.764	0.913	46.840	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Error er standardfejlen (i familie med SEM her dog ikke standarderror på “mean” men SE på estimatet)

H_0 for hvert af estimerne er at “Estimate = 0”. Det spørgsmål vi som regel forsøger at finde svar på er - hvor meget betyder “x” for værdien af “y”. Eller: “Hvis alder stiger med 1 år, hvor mange mmHg stiger det systoliske blodtryk”.

Hvis estimatet på den koefficient er 0 - har alder så betydning for blodtrykket? Hvis koefficienten i virkeligheden er 0 - så har alder ingen betydning for blodtrykket.



Koefficienter - t value

```
Call:
lm(formula = y ~ x, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-45.116 -11.157  -1.313   10.985   43.723

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    44.153      5.442    8.113 1.49e-10 ***
x              42.764      0.913   46.840 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom
Multiple R-squared:  0.9786,    Adjusted R-squared:  0.9781
F-statistic: 2194 on 1 and 48 DF,  p-value: < 2.2e-16
```

t value er testværdien vi bruger til at afgøre om vi kan afvise H_0 . Hvad viser den?

Hvor mange “Std. Error” ligger vores estimat fra 0?

Vi finder den ved at dividere “Estimate” med “Std. Error”

I kommer til at støde på to typer model- eller regressions output. (multipel) lineær og logistisk. At der står “t value” fortæller os at det er en lineær regression.



Koefficienter - p-value

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	44.153	5.442	8.113	1.49e-10	***
x	42.764	0.913	46.840	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

$\Pr(>|t|)$ er p-værdien: Risikoen for at vi afviser H_0 , selvom den faktisk er sand. Altså at vi afviser at estimatet i virkeligheden er 0 - og accepterer den alternative hypotese, at estimatet ikke er 0 (og at x derfor faktisk påvirker y).

Typisk: Større eller mindre end 0.05.



Populær ting i eksamensopgaver

De der formulerer eksamensopgaver synes det er supersjovt at redigere en værdi ud af outputtet af en model og stille et spørgsmål der kræver at I har netop den værdi.

$$\text{Husk: } t \text{ value} = \frac{\text{Estimate}}{\text{Std. Error}}$$

p-værdien kan vi ikke beregne direkte. Mangler den i opgaven, bruger vi testværdien:

$$\frac{\text{Estimate}}{\text{Std. Error}},$$

og ser om den er større eller mindre end 1.96 (hvis vi tester på et 5% niveau)

Vi kan faktisk godt beregne p-værdien. Den er givet ved: `2*(1-pt(abs(t value), df))`

`pt` er `pnorm()` blot for t-fordelingen i stedet for normalfordelingen, og `df` er antallet af frihedsgrader i modellen.

Men det behøver vi ikke - test-værdien er rigelig.



Resten

```
Call:
lm(formula = y ~ x, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-45.116 -11.157  -1.313   10.985   43.723

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  44.153      5.442   8.113 1.49e-10 ***
x            42.764      0.913  46.840 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom
Multiple R-squared:  0.9786,    Adjusted R-squared:  0.9781
F-statistic: 2194 on 1 and 48 DF,  p-value: < 2.2e-16
```

Residual standard error er et estimat af standardafvigelsen af residualerne, ϵ . Den *bliver* brugt til noget. Men det behøver vi ikke bekymre os så meget om. De “48” frihedsgrader vi så lige før kan vi også aflæse her.

Multiple R-squared er den andel af variationen i y der forklares af modellen. 0.9786 er utroligt godt.

Adjusted R-squared er R-squared, hvor vi korrigerer for at vi har lagt flere parametre ind i modellen. Det har jeg ikke set i eksamensopgaver.

Modellen giver et svar på spørgsmålet: Hvad forventer vi at y ville være hvis x var “noget”. Alternativet til den model ville være at vi svarede “gennemsnittet af alle y-værdierne” uanset hvad x var. F-statistic fortæller om vores modeler signifikant bedre end det.



Hvor sikre er vi på estimerne?

Vi får som regel lov at antage normalitet, og derfor:

$\text{estimate} \pm 1.96 \cdot \text{Std. Error}$

Skal vi være helt korrekte, skal vi beregne den kritiske værdi ud fra t-fordelingen, og kende antallet af frihedsgrader.

Så ville det blive:

$\text{estimate} + c(-1,1) * qt(1-0.025, df = 48)$

Det har jeg ikke set i nogen eksamensopgaver (endnu).



Hvordan estimerer vi Y fra X?

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	44.153	5.442	8.113	1.49e-10	***
x	42.764	0.913	46.840	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Hvis $x = 10$, hvad forventer vi så y vil være?

```
1 44.153 + 42.764*10
```

```
[1] 471.793
```



En rigtig opgave

Vi får denne variabelliste:

- episodes: Antal episoder med feber under graviditeten (før interview)
- death: Fosterdød (ja = 1, nej = 0)
- mage: Moderens alder ved interview
- smoke: Rygning under graviditet (1=0 cigaretter/dag, 2=1-10 cigaretter/dag, 3 = 11+ cigaretter/dag)
- alco: Antal genstande pr uge under graviditet
- weight: Fødselsvægt i gram

Og skal undersøge en evt sammenhæng mellem fødselsvægt og rygning. Vi vil også se på indtagelse af alkohol under graviditeten.

Hvilken type analyse vil du udføre for at undersøge den sammenhæng?



Hvilken type analyse?

Der er mange at vælge imellem. Men til eksamen er der to:

- Lineær regression
- Logistisk regression

Hvis vi skal forudsige eller forklare noget der er kontinuert:

Lineær

Hvis vi skal forudsige eller forklare noget der er kategorisk:

Logistisk

Her skal vi forklare/undersøge/forudsige fødselsvægt. Den er kontinuær.



Hvordan skal modellen så se ud?

Vi skal se på sammenhæng mellem fødselsvægt og rygning, samt indtagelse af alkohol under graviditeten.

Så der er to forklarende variable



Hov! To forklarende variable!!

Når vi har mere end en forklarende variabel - kalder vi det for multipel lineær regression.

...

Jeg har bemærket at modelbesvarelser kalder det hele for multipel lineær regression. Det kræver sådan set at der er mere end en forklarende variabel. Her har vi to, så det er faktisk multipelt.

...

Hvad var det?

Ja, det er når der er mere end en forklarende variabel. Indtil videre har vi set på:

```
lm(y~x, data = data)
```

Nu skal vi have en der er mere kompleks:

```
lm(y~x+z, data = data)
```

Den kan vi ikke tegne eller plote. Men ellers fungerer det fuldstændigt som før, vi får blot flere estimater, for nu er modellen jo:

$$\hat{y} = ax + bz + c$$



Mer hov!

Mors rygning under graviditeten:

smoke: Rygning under graviditet (1=0 cigaretter/dag, 2=1-10 cigaretter/dag, 3 = 11+ cigaretter/dag)

Det er jo ikke kontinuært. Hvordan så?

`lm` klarer det fint. Vi skal blot huske at fortælle funktionen at `smoke` er en kategorisk variabel. Det gør vi ved at pakke variabelen ind i funktionen `factor()`

Men så bliver det heller ikke mere kompliceret (i de eksamensopgaver jeg har set)



Kategoriske variable

Variable der kun kan tage en af flere værdier.

De kan være ordnede - så de ligger i en bestemt rækkefølge.

Det gør de her, 1 er mindre rygning end 2, som igen er mindre rygning end 3. Der behøver ikke være en “god-dårlig” betydning i det.

De kan også være uordnede - så er rækkefølgen ligegyldig. Det kunne være mand-kvinde.

Det væsentligste er at enten er man i en kategori. Eller også er man i en anden.



Opgaven fortsætter

Angiv relevant R-kode med brug af de variabelnavne vi har fået.

Hvilken R-kode skriver vi så?

```
lm(weight ~ factor(smoke) + alco, data = data)
```

Vi husker at forklare at det er med `smoke`, mors rygestatus, som forklarende/uafhængig kategorisk variabel. Og `alco`, mors alkoholindtag under graviditeten som forklarende/uafhængig kontinuært variabel, og fødselsvægt som den afhængige kontinuærte variabel.

I den virkelige verden ville vi sørge for at de variable i `data` der er kategoriske, optræder som kategoriske variable i `data`. Her skriver vi `factor(smoke)` fordi vi ikke ved om `smoke` optræder som kategorisk variabel i datasættet. Og for at vise at vi har forstået at den skal være kategorisk i modellen.



Næste delspørgsmål

Vi får oplyst at dette er resultatet af den korrekte analyse.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3613.623	7.108	508.372	<2e-16***
factor(smoke)2	-127.377	15.757		
factor(smoke)3	-194.897	17.519	-11.125	<2e-16***
alco	1.045	6.075	0.172	0.863

Hvad mangler - og hvad skulle der stå?

 Run Code

1

Er det signifikant?

Testværdien er >1.96 og Estimate for `factor(smoke)2` er derfor signifikant på et $\alpha = 0.05$ niveau.



Hvordan tolker vi ellers tallene?

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3613.623	7.108	508.372	<2e-16***
factor(smoke)2	-127.377	15.757		
factor(smoke)3	-194.897	17.519	-11.125	<2e-16***
alco	1.045	6.075	0.172	0.863

Intercept er vores “referencegruppe”. Den forventede fødselsvægt når smoke = 1 (ingen rygning), og alco = 0.

Altså for børn af ikke-rygende mødre, der drikker 0 genstande alkohol pr uge.

smoke = 1 er referenceværdien for smoke. Fordi den står først. Vi kan tvinge modellen til at vælge en anden referencegruppe, 2 fx.

Hvis mor var i smoke = 2 kategorien, så estimerer vores model at den forventede fødselsvægt er 127 gram lavere, alt andet lige.

Hvis mor var i smoke = 3 kategorien, så estimerer modellen at den forventede fødselsvægt er 195 gram lavere, alt andet lige.

Bemærk at Estimate på factor(smoke)2 og factor(smoke)3 ikke skal lægges sammen.

For hver enhed **alco** stiger, stiger den forventede fødselsvægt, alt andet lige, med ca 1 gram.



Sammenfattende

Estimatet for fødselsvægt er signifikant lavere for børn af rygende mødre. Effekten er større når der ryges mere. Der findes ikke evidens for en sammenhæng mellem alkoholforbrug og fødselsvægt.

Ryges der 1-10 cigaretter pr dag under graviditeten estimeres det at fødselsvægten er 127 gram lavere med et 95% KI på

```
1 -127.377 + c(-1,1) * 1.96 * 15.757
```

```
[1] -158.26072 -96.49328
```

Ryges der mere end 10 cigaretter om dagen estimeres fødselsvægten til at være 195 gram lavere med et 95% KI på:

```
1 -194.897 + c(-1,1) * 1.96 * 17.519
```

```
[1] -229.2342 -160.5598
```

Ved fastholdt alkoholindtag.

Estimatet på alkoholindtagets påvirkning af fødselsvægten indikerer at den, alt andet lige, stiger med 1 gram pr. genstand mor har drukket om ugen. Estimatet er dog ikke statistisk signifikant, og vi kan ikke afvise null-hypotesen.



Opgave

Vi skal se på sammenhæng mellem blodtryk og fedme. Vi får oplyst at der er et datasæt med 102 individer, 44 mænd, 58 kvinder.

Der er varibler: KØN (1=kvinde, 0= mand) FEDME: Fedmegrad - vægt i forhold til ideelvægt. 1.2 betyder at man vejer 20% mere end man burde. Svarende til 120% af ideelvægten BLODTRYK: Systolisk blodtryk (i mmHg)

De første 6 observationer, og nogle deskriptive størrelser:

```
# A tibble: 6 × 3
  KØN FEDME BLODTRYK
  <dbl> <dbl>    <dbl>
1     0  1.31     130
2     0  1.31     148
3     0  1.19     146
4     0  1.11     122
```

