


Lineær regression

WebR Status

 Ready!



Hvad er det nu det er?




Vi ved ikke hvad x og y er. Pointen er at det ser ud til at der er en lineær sammenhæng mellem x og y. Når x stiger, stiger y også. Hvordan ser den lineære sammenhæng ud?



En ret linie

Her har vi lagt en ret linie ind. Men er det den bedste? (spoiler: Det er den)



Den beskriver en sammenhæng mellem x og y.



Lineær regression

I husker måske at en ret linie kan beskrives som

$$y = ax + b$$


Opgaven er altså at finde den rette linie, beskrevet ved a og b , der bedst beskriver sammenhængen mellem x og y .

Hvordan gør vi det?



Lineær regression

Linien fortæller: Hvis x har en bestemt værdi, hvilken værdi burde y så have?



Den værdi har y *ikke*. Forskellen kalder vi “residualen”.



Lineær regression

Alle punkterne har en residual.

En afvigelse fra den “sande” værdi.

Vi vil derfor skrive at:

$$y = ax + b + \epsilon$$


Den “bedste” linie er den hvor summen af residualerne, ϵ , er mindst mulig.

Der er en del sjusk i notationen både her, overalt på nettet og i eksamensopgaver, hvor vi skriver $y = ax + b$. Det er ikke korrekt, for ϵ mangler.

$\hat{y} = ax + b$ er mere korrekt.



Lineær regression



Læg mærke til at residualen er negativ for det med rødt markerede punkt.
Andre punkter har en positiv værdi.

Hvad sker der hvis vi lægger dem alle sammen sammen?

Vi risikerer at resultatet bliver 0 - fordi summen af positive og negative tal kan risikere at blive 0.



Lineær regression

Så vi kvadrerer residualerne og lægger dem sammen.

Den sum forsøger vi at minimere ved at vælge a og b.

Derfor kalder vi også metoden for “mindste kvadraters metode”. Eller OLS - Ordinary Least Squares.

Det kunne man gøre med papir, blyant, lineal og lommeregner.

Det er der ingen der gider

Så vi bruger funktionen `lm()`



Det generelle eksempel

Hvis vi vil finde ud af hvordan x beskriver y, skriver vi:

```
lm(y ~ x, data = df)
```

Læs det som: y som funktion af x.

Den giver et output:

Call:

```
lm(formula = y ~ x, data = data)
```

Coefficients:

(Intercept)	x
44.15	42.76



De enkelte dele

```
1 lm(y ~ x, data = data)
```

y er den afhængige variabel, x er den uafhængige.

Eller:

y er responsvariabel, og x er forklarende.

Der gemmer sig mere information!



Outputtet

Gem resultatet og kør funktionen “summary” på det gemte resultat:

```
1 lineær_model <- lm(y ~ x, data = data)
2 summary(lineær_model)
```

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	44.153	5.442	8.113	1.49e-10	***
x	42.764	0.913	46.840	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Hyppig eksamensopgave: Her er output af det I burde have svaret i opgave 1a). Hvilken regression er der tale om? Fortolk resultaterne.

Så lad os kigge på de enkelte dele, så vi ved hvad de dækker over.



Call og Residuals

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	44.153	5.442	8.113	1.49e-10	***
x	42.764	0.913	46.840	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Call er den funktion vi faktisk kørte for at få dette resultat. Den er som regel redigeret væk.

Residuals er summary statistics på residualerne. Vi bruger dem til at tjekke modellen. De er som regel også redigeret væk.



Koefficienter - Estimate

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	44.153	5.442	8.113	1.49e-10	***
x	42.764	0.913	46.840	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Estimaterne er koefficienterne i $y = ax + b$. Intercept er b, x er koefficienten der ganges på x værdien, her altså a.

Den model vi har bygget er altså:

$$\hat{y} = 44.153 + 42.764x$$



Koefficienter - Std. error

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	44.153	5.442	8.113	1.49e-10 ***
x	42.764	0.913	46.840	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Error er standardfejlen (i familie med SEM her dog ikke standarderror på “mean” men SE på estimatet)

H_0 for hvert af estimerne er at “Estimate = 0”. Det spørgsmål vi som regel forsøger at finde svar på er - hvor meget betyder “x” for værdien af “y”. Eller: “Hvis alder stiger med 1 år, hvor mange mmHg stiger det systoliske blodtryk”.

Hvis estimatet på den koefficient er 0 - har alder så betydning for blodtrykket? Hvis koefficienten i virkeligheden er 0 - så har alder ingen betydning for blodtrykket.



Koefficienter - t value

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	44.153	5.442	8.113	1.49e-10 ***
x	42.764	0.913	46.840	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

t value er testværdien vi bruger til at afgøre om vi kan afvise H_0 . Hvad viser den?

Hvor mange “Std. Error” ligger vores estimat fra 0?

Vi finder den ved at dividere “Estimate” med “Std. Error”

I kommer til at støde på to typer model- eller regressions output. (multipel) lineær og logistisk. At der står “t value” fortæller os at det er en lineær regression.



Koefficienter - p-value

```
Call:
lm(formula = y ~ x, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-45.116 -11.157  -1.313   10.985   43.723

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   44.153     5.442   8.113 1.49e-10 ***
x             42.764     0.913  46.840 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom
Multiple R-squared:  0.9786,    Adjusted R-squared:  0.9781
F-statistic: 2194 on 1 and 48 DF,  p-value: < 2.2e-16
```

$\Pr(>|t|)$ er p-værdien: Risikoen for at vi afviser H_0 , selvom den faktisk er sand. Altså at vi afviser at estimatet i virkeligheden er 0 - og accepterer den alternative hypotese, at estimatet ikke er 0 (og at x derfor faktisk påvirker y).

Typisk: Større eller mindre end 0.05.

Tæt sammenhæng mellem t-value og p-value!



Populær ting i eksamensopgaver

De der formulerer eksamensopgaver synes det er supersjovt at redigere en værdi ud af outputtet af en model og stille et spørgsmål der kræver at I har netop den værdi.

$$\text{Husk: } t \text{ value} = \frac{\text{Estimate}}{\text{Std. Error}}$$

p-værdien kan vi ikke beregne direkte. Mangler den i opgaven, bruger vi testværdien:

$$\frac{\text{Estimate}}{\text{Std. Error}}$$

og ser om den er større eller mindre end 1.96 (hvis vi tester på et 5% niveau)

Vi kan faktisk godt beregne p-værdien. Den er givet ved: `2*(1-pt(abs(t value), df))`

`pt` er `pnorm()` blot for t-fordelingen i stedet for normalfordelingen, og `df` er antallet af frihedsgrader i modellen.

Men det behøver vi ikke - test-værdien er rigeligt.



Resten

```
Call:
lm(formula = y ~ x, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-45.116 -11.157  -1.313   10.985   43.723

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  44.153      5.442   8.113 1.49e-10 ***
x            42.764      0.913  46.840 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom
Multiple R-squared:  0.9786,    Adjusted R-squared:  0.9781
F-statistic: 2194 on 1 and 48 DF,  p-value: < 2.2e-16
```

Residual standard error er et estimat af standardafvigelsen af residualerne, ϵ . Den *bliver* brugt til noget. Men det behøver vi ikke bekymre os så meget om. De “48” frihedsgrader vi så lige før kan vi også aflæse her.

Multiple R-squared er den andel af variationen i y der forklares af modellen. 0.9786 er utroligt godt.

Adjusted R-squared er R-squared, hvor vi korrigerer for at vi har lagt flere parametre ind i modellen. Det har jeg ikke set i eksamensopgaver.

Modellen giver et svar på spørgsmålet: Hvad forventer vi at y ville være hvis x var “noget”. Alternativet til den model ville være at vi svarede “gennemsnittet af alle y-værdierne” uanset hvad x var. F-statistic fortæller om vores modeler signifikant bedre end det.



Hvor sikre er vi på estimerne?

Vi får som regel lov at antage normalitet, og derfor:

$\text{estimate} \pm 1.96 \cdot \text{Std. Error}$

Skal vi være helt korrekte, skal vi beregne den kritiske værdi ud fra t-fordelingen, og kende antallet af frihedsgrader.

Så ville det blive:

$\text{estimate} + c(-1,1) * qt(1-0.025, df = 48)$

Det har jeg ikke set i nogen eksamensopgaver (endnu).



Hvordan estimerer vi Y fra X?

Call:

```
lm(formula = y ~ x, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-45.116	-11.157	-1.313	10.985	43.723

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	44.153	5.442	8.113	1.49e-10	***
x	42.764	0.913	46.840	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 18.81 on 48 degrees of freedom

Multiple R-squared: 0.9786, Adjusted R-squared: 0.9781

F-statistic: 2194 on 1 and 48 DF, p-value: < 2.2e-16

Hvis $x = 10$, hvad forventer vi så y vil være?

```
1 44.153 + 42.764*10
```

```
[1] 471.793
```



En rigtig opgave

Vi får denne variabelliste:

- episodes: Antal episoder med feber under graviditeten (før interview)
- death: Fosterdød (ja = 1, nej = 0)
- mage: Moderens alder ved interview
- smoke: Rygning under graviditet (1=0 cigaretter/dag, 2=1-10 cigaretter/dag, 3 = 11+ cigaretter/dag)
- alco: Antal genstande pr uge under graviditet
- weight: Fødselsvægt i gram

Og skal undersøge en evt sammenhæng mellem fødselsvægt og rygning. Vi vil også se på indtagelse af alkohol under graviditeten.

Hvilken type analyse vil du udføre for at undersøge den sammenhæng?



Hvilken type analyse?

Der er mange at vælge imellem. Men til eksamen er der to:

- Lineær regression
- Logistisk regression

Hvis vi skal forudsige eller forklare noget der er kontinuert:

Lineær

Hvis vi skal forudsige eller forklare noget der er kategorisk:

Logistisk

Her skal vi forklare/undersøge/forudsige fødselsvægt. Den er kontinuær.



Hvordan skal modellen så se ud?

Vi skal se på sammenhæng mellem fødselsvægt og rygning, samt indtagelse af alkohol under graviditeten.

Så der er to forklarende variable



Hov! To forklarende variable!!

Når vi har mere end en forklarende variabel - kalder vi det for multipel lineær regression.

Jeg har bemærket at modelbesvarelser kalder det hele for multipel lineær regression. Det kræver sådan set at der er mere end en forklarende variabel. Her har vi to, så det er faktisk multipelt.

Hvad var det?

Ja, det er når der er mere end en forklarende variabel. Indtil videre har vi set på:

```
lm(y~x, data = data)
```

Nu skal vi have en der er mere kompleks:

```
lm(y~x+z, data = data)
```

Den kan vi ikke tegne eller plote. Men ellers fungerer det fuldstændigt som før, vi får blot flere estimater, for nu er modellen jo:

$$\hat{y} = ax + bz + c$$

Eller mere generelt:

$$\hat{y} = \beta_0 + \beta_1 x + \beta_2 z$$



Mer hov!

Mors rygning under graviditeten

smoke: Rygning under graviditet (1=0 cigaretter/dag, 2=1-10 cigaretter/dag, 3 = 11+ cigaretter/dag)

Det er jo ikke kontinuært. Hvordan så?

`lm` klarer det fint. Vi skal blot huske at fortælle funktionen at `smoke` er en kategorisk variabel. Det gør vi ved at pakke variabelen ind i funktionen `factor()`

Men så bliver det heller ikke mere kompliceret (i de eksamensopgaver jeg har set)



Kategoriske variable

Variable der kun kan tage en af flere værdier.

De kan være ordnede - så de ligger i en bestemt rækkefølge.

Det gør de her, 1 er mindre rygning end 2, som igen er mindre rygning end 3. Der behøver ikke være en “god-dårlig” betydning i det.

De kan også være uordnede - så er rækkefølgen ligegyldig. Det kunne være mand-kvinde.

Det væsentligste er at enten er man i en kategori. Eller også er man i en anden.



Opgaven fortsætter

Angiv relevant R-kode med brug af de variabelnavne vi har fået.

Hvilken R-kode skriver vi så?

```
lm(weight ~ factor(smoke) + alco, data = data)
```

Vi husker at forklare at det er med `smoke`, mors rygestatus, som forklarende/uafhængig kategorisk variabel. Og `alco`, mors alkoholindtag under graviditeten som forklarende/uafhængig kontinuært variabel, og fødselsvægt som den afhængige kontinuærte variabel.

I den virkelige verden ville vi sørge for at de variable i `data` der er kategoriske, optræder som kategoriske variable i `data`. Her skriver vi `factor(smoke)` fordi vi ikke ved om `smoke` optræder som kategorisk variabel i datasættet. Og for at vise at vi har forstået at den skal være kategorisk i modellen.




Næste delspørgsmål

Vi får oplyst at dette er resultatet af den korrekte analyse.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3613.623	7.108	508.372	<2e-16***
factor(smoke)2	-127.377	15.757		
factor(smoke)3	-194.897	17.519	-11.125	<2e-16***
alco	1.045	6.075	0.172	0.863

Hvad mangler - og hvad skulle der stå?

 Run Code

1

Er det signifikant?

Testværdiens absolutte værdi er >1.96 og Estimate for `factor(smoke)2` er derfor signifikant på et $\alpha = 0.05$ niveau.



Hvordan tolker vi ellers tallene?

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3613.623	7.108	508.372	<2e-16***
factor(smoke)2	-127.377	15.757		
factor(smoke)3	-194.897	17.519	-11.125	<2e-16***
alco	1.045	6.075	0.172	0.863

Intercept er vores “referencegruppe”. Den forventede fødselsvægt når smoke = 1 (ingen rygning), og alco = 0.

Altså for børn af ikke-rygende mødre, der drikker 0 genstande alkohol pr uge.

smoke = 1 er referenceværdien for smoke. Fordi den står først. Vi kan tvinge modellen til at vælge en anden referencegruppe, 2 fx.

Hvis mor var i smoke = 2 kategorien, så estimerer vores model at den forventede fødselsvægt er 127 gram lavere, alt andet lige.

Hvis mor var i smoke = 3 kategorien, så estimerer modellen at den forventede fødselsvægt er 195 gram lavere, alt andet lige.

Bemærk at Estimate på factor(smoke)2 og factor(smoke)3 ikke skal lægges sammen.

For hver enhed **alco** stiger, stiger den forventede fødselsvægt, alt andet lige, med ca 1 gram.



Sammenfattende

Estimatet for fødselsvægt er signifikant lavere for børn af rygende mødre. Effekten er større når der ryges mere. Der findes ikke evidens for en sammenhæng mellem alkoholforbrug og fødselsvægt.

Ryges der 1-10 cigaretter pr dag under graviditeten estimeres det at fødselsvægten er 127 gram lavere med et 95% KI på

```
1 -127.377 + c(-1,1) * 1.96 * 15.757
```

```
[1] -158.26072 -96.49328
```

Ryges der mere end 10 cigaretter om dagen estimeres fødselsvægten til at være 195 gram lavere med et 95% KI på:

```
1 -194.897 + c(-1,1) * 1.96 * 17.519
```

```
[1] -229.2342 -160.5598
```

Ved fastholdt alkoholindtag.

Estimatet på alkoholindtagets påvirkning af fødselsvægten indikerer at den, alt andet lige, stiger med 1 gram pr. genstand mor har drukket om ugen. Estimatet er dog ikke statistisk signifikant, og vi kan ikke afvise null-hypotesen.




Prædiktion

Hvad forventer vi fødselsvægten vil være, hvis mor har røget 20 cigaretter om dagen og drukket 16 genstande alkohol om ugen under graviditeten?

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3613.623	7.108	508.372	<2e-16***
factor(smoke)2	-127.377	15.757		
factor(smoke)3	-194.897	17.519	-11.125	<2e-16***
alco	1.045	6.075	0.172	0.863

▶ Run Code



1



Fedme og blodtryk

Vi skal se på sammenhængen mellem blodtryk og fedme. Vi får oplyst at der er et datasæt med 102 individer, 44 mænd, 58 kvinder.

Variable:

KØN (1=kvinde, 0= mand)

FEDME: Fedmegrad - vægt i forhold til ideelvægt. 1.2 betyder at man vejer 20% mere end man burde. Svarende til 120% af ideelvægten

BLODTRYK: Systolisk blodtryk (i mmHg)

De første 6 observationer, og nogle deskriptive størrelser:

```
# A tibble: 6 × 3
  KØN FEDME BLODTRYK
  <dbl> <dbl>    <dbl>
1     0  1.31     130
2     0  1.31     148
3     0  1.19     146
4     0  1.11     122
5     0  1.34     140
6     0  1.17     146
```

```
mean(BLODTRYK[KØN==0]) 127.9545
```

```
mean(BLODTRYK[KØN==1]) 126.3103
```

```
sd(BLODTRYK[KØN==0]) 16.59077
```

```
sd(BLODTRYK[KØN==1]) 19.41893
```

Beregn for kvinderne et referenceinterval for blodtrykket. Hvad udtrykker det?



Fedme og blodtryk

Der er ikke angivet hvilket referenceinterval der ønskes. Så vi går med et der indeholder 95% af observationerne. Vi antager at målingerne er normalfordelte.

```
mean(BLODTRYK[KØN==1]) 126.3103  
sd(BLODTRYK[KØN==1]) 19.41893
```

En fælde! Når vi beregner referenceintervaller beskriver vi spredning i data. Derfor bruger vi standardafvigelsen. Når vi beregner konfidensintervaller beskriver vi usikkerheden på middelværdien. Derfor bruger vi SEM. Så her *skal* vi bruge standardafvigelsen, og ikke dividere med kvadratroden af antallet.

```
Run Code  
1
```



Fedme og blodtryk

Undersøg nu om blodtrykket er ens for de to køn ved en t-test.

En eller to samples? Parret? Hvad er vores H_0 ?

Der er to uparrede samples.

$$H_0 : \mu_0 - \mu_1 = 0$$

Hvordan beregner vi så SE for hver gruppe?

$$SE = \frac{s}{\sqrt{n}}$$

Og SE for differensen?

$$SE_{diff} = \sqrt{SE_0^2 + SE_1^2}$$

t-test er kode for at vi sammenligner middelværdier



Fedme og blodtryk

Så er vi klar til at regne

```
mean(BLODTRYK[KØN==0]) 127.9545
```

```
mean(BLODTRYK[KØN==1]) 126.3103
```

```
sd(BLODTRYK[KØN==0]) 16.59077
```

```
sd(BLODTRYK[KØN==1]) 19.41893
```

Antal kvinder (1): 58

Antal mænd (0): 44

Hvad er test-værdien?

$$SE_{diff} = \sqrt{SE_0^2 + SE_1^2}$$

```
Run Code
```

```
1
```



Fedme og blodtryk

Der bliver lavet en analyse, der giver dette output:

```
Call: lm(formula = BLODTRYK ~ FEDME)

            Estimate Std. Error t value Pr(>|t|)
(Intercept)  96.818     8.920     10.86  <2e-16***
FEDME         23.001     6.667      3.45   0.000822***
```

Hvilken analyse er der udført?
Hvad kan vi konkludere, og
hvordan fortolker vi
estimerterne

(multipel) Lineær regression
med BLODTRYK som kontinuært
responsvariabel

og FEDME som den uafhængige variabel.
Der er også kontinuær.

Vi estimerer at hvis FEDME graden stiger
med 1

vil blodtrykket stige med ca. 23

I gennemsnit.

Dette estimat er statistisk signifikant på
95% niveau.

Interceptet svarer til blodtrykket ved en
fedmegrad på 0, og kan derfor ikke
fortolkes.



Fedme og blodtryk


Så laver vi en anden analyse, hvor vi inddrager KØN.

```
Call: lm(formula = BLODTRYK ~ factor(KØN) + FEDME)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	93.287	8.937	10.438	<2e-16***
factor(KØN)1	-7.730	3.715		
FEDME		7.172	4.049	

Beregn det manglende estimat for FEDME og t value for KØN.

Run Code



1



Fedme og blodtryk

Fortolk estimater og konkluder.

```
Call: lm(formula = BLODTRYK ~ factor(KØN) + FEDME)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	93.287	8.937	10.438	<2e-16***
factor(KØN)1	-7.730	3.715	-2.080754	
FEDME	29.03943	7.172	4.049	

t value for KØN var (i absolutte tal) større end 1.96

og er derfor statistisk signifikant på et 5% niveau.

Justeret for FEDME, ser vi at kvinderne i gennemsnit har

et lavere blodtryk end mændene. Vi estimerer forskellen til at være 7.73

En stigning på 1 i fedmegrad, estimerer vi til at give en

gennemsnitlig stigning på 29 i blodtrykket, *kontrolleret* for KØN.

Denne forskel er signifikant på et 5% niveau.

Intercept svarer stadig til en fedmegrad på 0, og kan derfor ikke fortolkes.



Fedme og blodtryk - sidste omgang

Sammenlign resultaterne i b) og d) (b var testen af forskellig middelværdi for de to køn, d var den lineære model med KØN inkluderet) og kommenter på en eventuel forskel i betydningen af køn for blodtrykket

De to analyser gav forskellige konklusioner vedr. effekten af KØN for blodtrykket.

Hvad er forskellen?

Den første test justerer ikke for fedme og konkluderer at der ikke er forskel på blodtrykket for mænd og kvinder.

Den anden model justerer for fedme og ser en forskel på kønnene.

Hvad kan det skyldes?

Potentielt at kvinder har en højere fedmegrad end mænd, hvilket maskerer effekten af køn i den ujusterede analyse.



Hoppemålinger genbesøgt

Recap: 249 børn, drenge (1) og piger (2) har fået målt hvor langt de kan hoppe på højre og venstre. Forskellen er målt som “diff” (højre - venstre). Nu udføres følgende analyse:

`summary(lm(diff~factor(gender)))` Ja, p-værdien er 0.00065, der er en signifikant kønsforskel (i forskellen på hvor langt børnene kan hoppe på højre og venstre ben)
og vi får dette resultat:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.775	3.471	-1.087	0.27795
factor(gender)2	16.283	4.714	3.454	0.00065***

Hvilken analyse har vi gennemført?

Hvad kan vi konkludere?

Fortolk de to værdier i søjlen

“Estimate”

Hvilken analyse?

Multipel lineær regression med diff som afhængig variabel, og køn som kategorisk forklarende variabel.

Hvad er referenceværdien for køn?

Det er drengene.

Er kønsforskellen signifikant?

Hvor stor er den?

Vi estimerer at pigerne i middel kan hoppe $16.283 - 3.775 = 12.508$ cm længere på højre end på venstre ben.

Denne forskel var statistisk signifikant

Hvordan med drengene?

Vi estimerer forskellen på hoppelængde (på højre - venstre ben) for drengene er -3.775


Denne forskel er *ikke* signifikant.



The final hoppe opgave

Beregn de tilhørende 95%
konfidensintervaller på
estimerne

Run Code



1

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.775	3.471	-1.087	0.27795
factor(gender)2	16.283	4.714	3.454	0.00065***



Drenge - hormoner

Vi har undersøgt koncentrationen af et hormon hos ellers sunde og raske drenge. Vi ønsker at undersøge sammenhængen mellem denne koncentration og drengenes alder og BMI.

Drengene blev opdelt i aldersgrupper, og vi får oplyst hvor mange der var i hver:

(5,8]	(8,9]	(9,10]	(10,11]	(11,12]	(12,13]	(13,14]	(14,15]	(15,16]	(16,17]
115	44	40	45	43	29	33	38	37	32
(17,18]	(18,20]								
32	10								

Vi får også et eksempel på data fra datasættet:

```
# A tibble: 6 × 3
  horm   BMI Ald.gr
<dbl> <dbl> <chr>
1  5.72  15.2 (5,8]
2  8.71  15.3 (5,8]
3  5.8   14.7 (5,8]
4  7.17  16.9 (5,8]
5  7.46  17   (9,10]
6  6.51  16.9 (9,10]
```



Dreng - hormoner

Vi får nu oplyst at der er foretaget følgende analyse:

```
model=lm(horm~factor(Ald.gr)+BMI)
summary(model)
```

Hvilket giver dette resultat:

```
# A tibble: 13 × 5
  Coefficients      Estimate `Std. Error` `t value`
`Pr(>|t|)`
  <chr>           <dbl>      <dbl>      <dbl> <chr>
1 (Intercept)      5.40      0.368      14.7  <2e-16
***
2 factor(Ald.gr)(8,9]  0.0734    0.202      0.363  0.71700
3 factor(Ald.gr)(9,10]  0.357     0.199      1.79   0.07382
4 factor(Ald.gr)(10,11] 0.579     0.209      2.78   0.00581
**
5 factor(Ald.gr)(11,12] 1.09      0.197      5.53   6.42e-08
***
6 factor(Ald.gr)(12,13] 1.37      0.221      6.23   1.37e-09
***
7 factor(Ald.gr)(13,14] 2.29      0.219     10.5    < 2e-16
***
8 factor(Ald.gr)(14,15] 2.12      0.211     10.0    < 2e-16
***
9 factor(Ald.gr)(15,16] 2.24      0.209     10.7    < 2e-16
***
```

Hvilken analyse er der udført?

Hvilken model?

“model = lm(osv)”: Lineær regression

Med hormonniveau som den afhængige variabel.
Hvad er den ellers?

multipl, fordi?

Mere end en forklarende, eller uafhængig,
variabel

Hvilke?

Aldersgruppen er kategorisk forklarende
variabel. BMI er en kontinuert forklarende
variabel.



Drenge - hormoner

```
model=lm(horm~factor(Ald.gr)+BMI)
summary(model)
```

```
# A tibble: 13 × 5
  Coefficients      Estimate `Std. Error` `t value`
`Pr(>|t|)`
  <chr>           <dbl>      <dbl>      <dbl> <chr>
1 (Intercept)      5.40      0.368      14.7  <2e-16
***
2 factor(Ald.gr)(8,9]  0.0734    0.202      0.363 0.71700
3 factor(Ald.gr)(9,10] 0.357     0.199      1.79  0.07382
4 factor(Ald.gr)(10,11] 0.579     0.209      2.78  0.00581
**
5 factor(Ald.gr)(11,12] 1.09      0.197      5.53  6.42e-08
***
6 factor(Ald.gr)(12,13] 1.37      0.221      6.23  1.37e-09
***
7 factor(Ald.gr)(13,14] 2.29      0.219     10.5  < 2e-16
***
8 factor(Ald.gr)(14,15] 2.12      0.211     10.0  < 2e-16
***
9 factor(Ald.gr)(15,16] 2.24      0.209     10.7  < 2e-16
***
10 factor(Ald.gr)(17,18] 2.57      0.209     12.3  < 2e-16
***
```

Fortolk resultaterne.

Hvad ser vi?

Hormonniveauet stiger tilsyneladende med stigende alder (og fastholdt BMI)

Giv et eksempel

Hormonniveauet for alderskategorien (11,12] er 1.08688 højere end for referencen (5,8].

Er det statistisk signifikant?

Ja, stigningen er statistisk signifikant for næsten alle aldersgrupper.

Er der noget vi bør tilføje i den sammenhæng?

Ja, der er en vis variation i hvor meget hormonniveauet stiger med alderen.

Hvad med BMI?

BMI er også klart signifikant med en middel stigning i hormonniveauet på 0.058 pr BMI-point (ved fastholdt alder)



Drenge - hormoner - prediktion

Prædikter (forudsig) hormonniveauet for en dreng på 6 år med et BMI på 17 og for en dreng på 14 med et BMI på 18.


```
model=lm(horm~factor(Ald.gr)+BMI)
```

```
# A tibble: 13 × 5
  Coefficients
  <chr>
1 (Intercept)
2 factor(Ald.gr)(8,9]
3 factor(Ald.gr)(9,10]
4 factor(Ald.gr)(10,11]
5 factor(Ald.gr)(11,12]
6 factor(Ald.gr)(12,13]
7 factor(Ald.gr)(13,14]
8 factor(Ald.gr)(14,15]
9 factor(Ald.gr)(15,16]
10 factor(Ald.gr)(16,17]
11 factor(Ald.gr)(17,18]
12 factor(Ald.gr)(18,20]
13 BMI

  Estimate `Std. Error` `t value` `Pr(>|t|)`
  <dbl>    <dbl>      <dbl>    <dbl>
1 5.40      0.368      14.7    <2e-16 ***
2 0.0734    0.202      0.363  0.71700
3 0.357     0.199      1.79   0.07382 .
4 0.579     0.209      2.78   0.00581 **
5 1.09      0.197      5.53   6.42e-08 ***
6 1.37      0.221      6.23   1.37e-09 ***
7 2.29      0.219     10.5   < 2e-16 ***
8 2.12      0.211     10.0   < 2e-16 ***
9 2.24      0.209     10.7   < 2e-16 ***
10 1.71      0.230      7.45   7.30e-13 ***
11 1.72      0.227      7.61   2.71e-13 ***
12 1.32      0.321      4.10   5.14e-05 ***
13 0.0582    0.0218      2.67   0.00791 **
```

Bum. Det var en hel eksamensopgave. Hvis man kan fortolke outputtet af en regression, foretage en prediktion og måske beregne et konfidensinterval på et estimat (eller to), kommer man langt.

Run Code



1



Transplanteret lungevolumen

Vi ser på data for 426 lungetransplanterede patienter. Man har været nødt til at bruge ældre donorer, der også kan have været rygere.

De første 6 observationer er givet:

```
# A tibble: 6 × 4
  fevl_prior_to_tx fevl_after fevl_diff SMOKE
      <dbl>         <dbl>    <dbl> <chr>
1         1.4         3.8        2.4 Never smoker
2         0.56        0.95        0.39 Smoker or former
  smoker
3         0.37        1.25        0.88 Smoker or former
  smoker
4         0.54        2.35        1.81 Smoker or former
  smoker
5         0.71        1.6         0.89 Never smoker
6         1.78        2.08        0.3  Never smoker
```

fevl_prior_to_tx: fevl målt før transplantation

fevl_after: fevl målt efter transplantation

fevl_diff: differencen mellem *fevl_after* og *fevl_prior_to_tx*

SMOKE: Rygestatus for donor.

Vi får oplyst følgende:

	mean	sd
fevl_prior_to_tx	0.835086	0.5365149
fevl_after	2.122762	0.9459951
fevl_diff	1.279024	0.9411598



Transplanteret lungevolumen

Undersøg ved brug af relevant statistik metode om patienternes lungefunktion (fevl) har ændret sig efter transplantationen.

Hvad er det for en test?

Parret t-test (vi har målinger på samme patient før og efter)

Det er sådan set kun forskellen vi er interesserede i:

	mean	sd
fevl_diff	1.279024	0.9411598

Hvordan beregner vi testværdien?

$$\frac{\text{estimat}}{SE}$$

Hvordan beregner vi SE?

$$SE = \frac{sd}{\sqrt{n}}$$

```
Run Code
1
```



Transplanteret lungevolumen

Nu udførtes følgende analyse:

```
model <-  
lm(fevl_diff~factor(SMOKE))  
summary(model)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.36970	0.06646	20.61	<2e-16***
factor(SMOKE)Smoker or former smoker	-0.19092	0.09644	-1.98	0.0485*

Hvilken analyse er der tale om, og hvad kan vi konkludere på baggrund af denne?

Hvilken slags analyse?

(multipel) lineær regression

Hvilke variable?

fevl_diff er den kontinuære
responsvariabel

SMOKE er den forklarende, kategoriske (og
binære) variabel

Er der en ændring i lungefunktionen for
reference gruppen?

Ja, den bliver 1.37 l bedre

Og hvis donor var (tidligere) ryger?


Ændringen i lungefunktionen efter
transplantation afhænger af om donor var
(tidligere) ryger. Den er statistisk signifikant
med en p-værdi på 0.0485



Transplanteret lungevolumen

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.36970	0.06646	20.61	<2e-16***
factor(SMOKE)Smoker or former smoker	-0.19092	0.09644	-1.98	0.0485*

Run Code



1

Fortolk værdierne i søjlen “Estimate”. Beregn også de tilhørende 95% KI.

Intercept er den estimerede ændring i lungefunktion (dvs. før vs efter transplantationen), for patienter med en donor der var ikke-ryger.

Hvad er estimatet?

1.3697

Og 95% KI?

Hvad med de der fik lunger fra en (tidligere) ryger?

Der var forbedringen lidt mindre.

Hvor meget?

0.19 mindre end hvis de havde fået lunger fra en ikke-ryger

95% KI?



Leversygdom

583 personer, er blevet henvist til undersøgelse pga mistanke om leversygdom. De første 6 observationer er:

```
# A tibble: 6 × 8
  age albumin ratio globulin status idnr sex l_ratio
<dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <chr> <dbl>
1   65   3.3  0.9   3.67     1     1 F  -0.105
2   62   3.2  0.74  4.32     1     2 M  -0.301
3   62   3.3  0.89  3.71     1     3 M  -0.117
4   58   3.4  1     3.4      1     4 M    0
5   72   2.4  0.4    6      1     5 M  -0.916
6   46   4.4  1.3   3.38     1     6 M   0.262
```

Variable: *idnr*: Løbenummer

sex: Køn

age: alder i år

status: leversygdom, 1=ja

albumin: serum albumin g/dL

globulin: serum globulin g/dL

ratio: ratio m. albumin og globulin

l_ratio: log(ratio) (den naturlige logaritme)

Vi får denne tabel:

```
1 table(status, sex)
```

```
sex
status F  M
0    50 117
1    92 324
```

Og oplyst at log-ratio er normalfordelt.

For status = 0 får vi:

	Gennemsnit	Spredning (sd)
l_ratio	-0.011	0.289
age	41.2	17.0

og for status = 1

	Gennemsnit	Spredning (sd)
l_ratio	-0.152	0.358
age	46.2	15.7

Er der forskel i log-ratio mellem syge og raske, når der ikke tages højde for forskel i alder og køn?

Hvor mange raske (status 0) er der?

50+ 117 = 167

Hvor mange syge (status 1) er der?

92 + 324 = 416



Leversygdom

Vi skal ikke lade os forvirre over log-ratio - det er “bare” logaritmen af forholdet mellem albumin og globulin. Vi behandler den som ethvert andet tal.

Men husk alligevel at en generel tommelfingerregel er, at ting der ikke er normalfordelte bliver (mere) normalfordelte hvis vi tager logaritmen.

Hvordan tester vi om to middelværdier var forskellige?

$$H_0 : \mu_0 - \mu_1 = 0$$

Husk at nævne at det er en t-test

Så vi skal have differensen.

Og vi skal have SE for differensen.

Den fandt vi ved:

$$SE(\bar{x}_1 - \bar{x}_2) = \sqrt{SE_1^2 + SE_2^2}$$

Så vi skal have SEM for hver middelværdi

$$SEM = \frac{sd}{\sqrt{(n)}}$$


Og så kan vi beregne hvad?

Teststørrelsen.

l_ratio:

Status	Gennemsnit	Spredning (sd)	n
0	-0.011	0.289	167
1	-0.152	0.358	416

▶ Run Code



1



Leversygdom

Undersøg nu om kønsfordelingen er den samme for de syge og de raske.

	sex	
status	F	M
0	50	117
1	92	324

Hvordan gør vi det?

Der er flere måder - lad os igen kigge på differensen.

Så forskellen på sandsynligheden for at være kvinde hvis man er rask og sandsynligheden for at være kvinde hvis man er syg.

$$H_0 : p_{f:r} - p_{f:s} = 0$$

$p_{f:r}$ er andelen af kvinder blandt de raske.

Hvordan fandt vi SE for en andel?

$$SE_p = \sqrt{\frac{p(1-p)}{n}}$$


SE for differensen er stadig:

$$SE(\hat{p}_1 - \hat{p}_2) = \sqrt{SE_1^2 + SE_2^2}$$

Hvad beregner vi så?

En testværdi.

Run Code



1



Leversygdom

Er aldersfordelingen den samme for syge som for raske? Hvordan vil vi undersøge det?

Det er nøjagtig det samme som før. Men nu middelværdier i stedet for andele.

Der er to samples hvor vi sammenligner middelværdierne af alder:

Two-sample t-test

$$H_0 : \mu_1 - \mu_2 = 0$$


$$SE = \frac{sd}{\sqrt{n}}$$

$$SE(\bar{x}_1 - \bar{x}_2) = \sqrt{SE_1^2 + SE_2^2}$$

age:

status	Gennemsnit	Spredning (sd)	n
0	41.2	17.0	167
1	46.2	15.7	416

Run Code



1



Leversygdom

Nu laver vi denne analyse i R, hvor vi inddrager alder og køn:

```
> analyse1 <- lm(l_ratio~factor(status)+factor(sex)+age)
> summary(analyse1)
```

Det gav dette output:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.1730998	0.0488724	3.542	0.000430***
factor(status)1	-0.1196883	0.0310025	-3.861	0.000126***
factor(sex)M	0.0042939	0.0324442	0.132	0.894756
age	-0.0045177	0.0008616	-5.241	2.24e-7***

Hvilken analyse er der tale om, og hvad kan vi konkludere på baggrund af den? Fortolk værdier i søjlen “Estimate” svarende til variablene status og age.

Det er en multipel lineær regression med l_ratio som responsvariabel og status, sex og age som forklarende variable.

Hvad er de variable?

age er kontinuert, status og sex er kategoriske

Hvad kan vi sige om de syge patienter?

De har i gennemsnit, alt andet lige, en lavere l_ratio en raske

Hvad estimerer vi den til?

ca. 0.12 lavere

Har vi justeret for noget?

Der er justeret for køn og alder.

Er den signifikant?

Ja, p-værdien er 0.0001

Hvad med alderen?

Alderseffekten er også signifikant ($p < 0.001$).

l_ratio ændrer sig hvordan?

l_ratio falder, i gennemsnit, med 0.0045 pr år. Justeret for status og køn.



Leversygdom

Predikter median-ratio for de syge (status 1) kvinder i populationen med en alder på 50 år.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.1730998	0.0488724	3.542	0.000430***
factor(status)1	-0.1196883	0.0310025	-3.861	0.000126***
factor(sex)M	0.0042939	0.0324442	0.132	0.894756
age	-0.0045177	0.0008616	-5.241	2.24e-7***

Hvad fik vi oplyst at vi kunne antage om l_ratio ?

At den var normalfordelt.

Hvad ved vi om medianen i en normalfordeling?


At medianen er lig middelværdien (og omvendt)

Bemærk at vi spørges til medianen af ratio, ikke medianen af log-ratio

Hvordan fikser vi det?

Vi beregner medianen (middelværdien) af l_ratio , og exponentierer.

Run Code



1



Blodtryk i Ghana

Vi ser på blodtryksmålinger fra 641 forsøgspersoner i Ghana.

Det er et interventionsstudie, der skulle undersøge om en ny behandling kunne sænke blodtrykket for patienter med ukontrolleret hypertension.

To grupper, control & treatment. Begge har fået standardbehandling, mens treatmentgruppen dertil har fået personligt tilpasset behandling af sygeplejersker med speciale i behandling af hypertension. Den blev randomiseret, og vi har blodtryksmålinger fra baseline (før behandling) og efter 12 måneder. Der var 323 individer i treatment gruppen.

Variable:

SBPbl: systolisk blodtryk ved baseline (mmHg)

SBP12: systolisk blodtryk efter 12 måneder

group: (control/treatment)

sex: (male/female)

diff: differensen mellem SBP12 og SBPbl

Summariske værdier for *diff*:

Gruppe	Gennemsnit	Spredning	n
Control	-16.6	19.9	318
Treatment	-19.6	17.4	323

Vi fik ikke oplyst antallet i kontrolgruppen. Men $641 - 323 = 318$



Blodtryk i Ghana

Er der et signifikant fald i blodtrykket i interventionsgruppen i den undersøgte periode. Besvar samme spørgsmål for kontrolgruppen.

Hvad er det så vi tester?

$$H_0 : diff = 0$$

Hvordan gør vi det?

Kl. Og hvordan ser det ud?


Estimat $\pm 1.96 \cdot SEM$

$$SEM = \frac{s}{\sqrt{n}}$$

Summariske værdier for *diff*:

Gruppe	Gennemsnit	Spredning	n
Control	-16.6	19.9	318
Treatment	-19.6	17.4	323

Run Code



1



Blodtryk i Ghana

Er faldet signifikant forskelligt i de 2 grupper? Hvad kan vi konkludere vedrørende effekten af præcisionsbehandlingen på blodtrykket på baggrund af det?

Kan vi bruge KI til at sige noget om det?

Nej. De to KI overlapper, men ingen af dem indeholder gennemsnittet fra det andet KI.

Hvad gør vi så?

Vi beregner SEM for differensen:

Hvad skal vi så bruge?


En samlet SE for differensen

$$SE_{\text{diff}} = \sqrt{SE_1^2 + SE_2^2}$$

Summariske værdier for *diff*:

Gruppe	Gennemsnit	Spredning	n
Control	-16.6	19.9	318
Treatment	-19.6	17.4	323

Run Code



1



Blodtryk i Ghana

Nu udførtes følgende analyser for mænd og kvinder hver for sig:

```
summary(lm(diff[sex=="female"]~factor(group[sex=="female"])))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-16.988	1.3556	-12.527	<2e-16***
factor(group[sex=='female']) treatment	-5.915	1.901	-3.112	0.002**

```
summary(lm(diff[sex=="male"]~factor(group[sex=="male"])))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-15.893	1.594	-9.968	<2e-16***
factor(group[sex=='male']) treatment	1.692	2.264	0.747	0.456

Hvilke analyser er der tale om, hvad kan vi konkludere på den baggrund? Der ønskes fortolkning af værdierne i "Estimate". Giver det anledning til en anden konklusion end den vi fik lige før?

To multiple lineære regressioner, med diff som kontinuært responsvariabel og group som forklarende, kategorisk (og binær) variabel.

For kvinder ser vi at blodtrykket i snit falder med ca 17 mmHg under kontrolbehandling (signifikant, med $p \sim 0$), og yderligere ca 6 mmHg ved præcisionsbehandlingen (signifikant med $p = 0.002$)

For mænd ser vi at blodtrykket i snit falder med ca. 16 mmHg under kontrolbehandling, men at der ikke er signifikant forskel på effekten af de to behandlinger ($p=0.456$)



Det var den lineære regression

Vi skal kunne opstille sådan en

Vi skal kunne beregne evt. manglende estimer, standardfejl eller t-værdier

Vi skal kunne fortolke outputtet af regressionen

Vi skal kunne prædiktere en værdi ud fra modellen

