

Kategoriske udfald

Herunder logistisk regression

WebR Status

 Ready!



Kategoriske udfald

Kategoriske variable er variable hvor observationerne kan falde i en af flere (mindst to) kategorier.

Køn, rask/syg, død/levende, hvilken region har man folkeregisteradresse i.

Der er ikke nødvendigvis en orden. Det er ikke bedre at være mand end at være kvinde.

Men der kan være - socialklasse eg.

Der kan vi ikke beregne gennemsnit. Så hvad gør vi så?

Vi tæller.



Kategoriske udfald

Hvor mange er der af hver?

Og hvor stor en andel udgør de så af de samlede hele.

Er der forskel på de andele grupper imellem?

Kan vi sige noget om hvad sandsynligheden for at være i den ene gruppe kontra den anden?

Og hvor sikre er vi på vores estimer?



Kategoriske udfald

Så vi skal kigge på:

- Proportioner
- Relativ risiko
- Odds ratio
- Chi i anden

Og lidt senere den logistisk regression



En opgave

Vi skal se på prævalensen af tuberkulose blandt stiknarkomaner og om den er afhængig af om der deles sprøjter med andre narkomaner.

I en gruppe med 97 narkomaner der deler sprøjte med andre narkomaner, testede 24.7% positiv for TB.

I en gruppe på 161 narkomaner der ikke delte sprøjte, testede 17.4% positive for TB.

Hvis vi antager at prævalensen ikke afhænger af om der deles sprøjter - hvad estimerer vi så prævalensen til at være?

▶ Run Code

1



Hvor sikre er vi på det tal?

Opgaven fortsætter:

Angiv også et 95% konfidensinterval på det estimat.

Estimatet er en andel. Også kaldet en proportion

Metoden har vi set før.

$$\textit{estimat} \pm 1.96 \cdot SE$$

Så - hvordan beregner vi en standardfejl på estimatet af en proportion?

$$SE_{prop} = \sqrt{\frac{p \cdot (1-p)}{n}}$$



Hvor sikker var vi?

Hvad er et 95% KI for prævalensen af TB blandt stiknarkomaner, hvis vi antager at den ikke afhænger af om man deler sprøjte eller ej?

Proportionen beregnede vi til 0.2015504

Standardfejlen er givet ved:

$$SE_{prop} = \sqrt{\frac{p \cdot (1-p)}{n}}$$

Der var 258 observationer i stikprøven

$$estimat \pm 1.96 \cdot SE$$

```
Run Code
1
```



Videre med samme opgave

Undersøg hypotesen om at risikoen for at få TB for stiknarkomaner ikke afhænger af om man deler sprøjte eller ej. Argumenter ud fra relevant KI.

Hvis I har fået fat i modelbesvarelsen for denne opgave - bemærk at der er en regnefejl, fordi nogen har byttet om på n for de to grupper.

Hvordan gør vi det? Eller: Hvad vil det egentlig sige at risikoen for TB er uafhængig af om der deles sprøjter?

At: I virkeligheden er forskellen på de to prævalenser 0

Den ene prævalens divideret med den anden er 1 (for så er de ens)

I stedet for prævalenser kan vi beregne odds. Og se om odds er ens.

Kan vi undersøge om fordelingen af TB er forskellig i de to grupper?

Vi tager dem en for en



Forskel på prævalenser

Er forskellen i virkeligheden 0?

Eller - vi opstiller en NULL-hypotese, $H_0 : p_{TB:deler} - p_{TB:delerikke} = 0$

Den alternative hypotese er så, at der er forskel på prævalensen.

Samme metode som før:

$$estimat_{diff} \pm 1.96 * SE_{diff}$$

Er 0 indeholdt i det 95% KI, kan vi ikke afvise NULL-hypotesen

Så... Hvordan beregner vi SE_{diff} ?

$$SE_{diff} = \sqrt{SE_1^2 + SE_2^2}$$

Og standardfejl på de enkelte proportioner var: $SE = \sqrt{\frac{p(1-p)}{n}}$




Så kan vi regne

- Prævalens af TB blandt de 97 der delte sprøjter: 24.7%
- Prævalens af TB blandt de 161 der ikke delte sprøjter: 17.4%

- $SE = \sqrt{\frac{p(1-p)}{n}}$

- $SE_{diff} = \sqrt{SE_1^2 + SE_2^2}$

Run Code



1



Kritisk værdi

Har man et estimat. Og en standardfejl. Så kan man springe konfidensintervallet over.

$$\left| \frac{\text{estimat}}{SE} \right| > \text{kritisk værdi}$$

Når vi spørger om værdien i virkeligheden kan være 0, og kriteriet er 5% signifikans (eller 95%). Så er den kritiske værdi 1.96.

Venstresiden fortæller hvor mange standardfejl estimatet ligger fra 0. Og så er spørgsmålet om det er langt nok væk.

Så vi kan ofte springe konfidensintervallet over, konstatere at vi har en *test-værdi* $\left| \frac{\text{estimat}}{SE} \right|$ på hvad den nu er, og at det er større end (eller mindre end) den kritiske værdi, og vi derfor kan afvise NULL-hypotesen (eller at vi ikke kan afvise den).



Forholdet mellem de to prævalenser?

Den hypotese vi så tester er:

$$H_0 : \frac{p_{deler}}{p_{delerikke}} = 1$$

Er de (tilstrækkeligt) forskellige - kan vi konkludere at der er forskel i risikoen.

Vi kalder også prævalenserne for proportioner. Og i jeres branche: Risk, og derfor Riskratio, eller RR.

Metoden er den samme som før. Estimatet +/- 1.96 SE.

Sådan da...



Komplikationer

Hvordan beregner vi SE?

Det er bøvlet - og derfor var metoden med KI på differencen den første vi så på (og den foretrukne).

Vi har ikke en let formel for standardfejlen på en riskratio.

Det vi har er en formel for standardfejlen af logaritmen af RR.

Og derfor:

$$\log RR \pm 1.96 \cdot SE_{\log RR}$$



SE for log(RR)

For det generelle forhold:

	udfald 1	udfald 2
eksponeret	a	b
ikke eksponeret	c	d

Hvor risikoen for udfald 1 hvis man er eksponeret er: $\frac{a}{a+b}$, og hvis man ikke er eksponeret: $\frac{c}{c+d}$

Gælder at:

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$




Og så er vi ca. klar til at regne

TB	deler	deler ikke
TB-positiv	24	28
TB-negativ	73	133

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$

▶ Run Code



1



Hvad så vi?

RR var 1.42268. Det vil vi formulere som at “risikoen er 42% højere” for at være TB+ hvis man deler sprøjter.

Men. KI for RR var [0.877; 2.307]

Det indeholder 1. Og derfor er der ikke statistisk signifikant forskel på risikoen for at teste positiv for TB hvis man deler sprøjter.

Vi kunne også se på KI for $\log(RR)$, der var [-0.131; 0.836]. Det indeholder 0. Også derfor er der ikke (statistisk signifikant forskel).

Hvorfor? Fordi $\log(1) = 0$.

Vi kunne også få teststørrelsen ved $\frac{\log(RR)}{SE(\log(RR))}$. Den var 1.429. Mindre end den kritiske værdi.



Odds - hvad er det?

Blandt de 97 narkomaner der delte sprøjter var 24 TB+.

Det gav en risiko for at være TB+ på 24/97.

Eller sandsynlighed. Eller prævalens af TB+ blandt... eller risiko for at være TB+ hvis...

Det kan vi udtrykke anderledes - ved odds.

Det er antallet af positive udfald divideret med antallet af negative udfald.

Eller: 24/73

Hvorfor? Matematikken bliver en del mere medgørlig hvis vi regner i odds.



Odds - fordelene

Hvis sandsynligheden for et positivt udfald er 10%

Er der, ved 10 observationer 1 positivt og 9 negative udfald.

Som sandsynligheder: 0.1 og 0.9 hhv.

Som odds: 1/9 og 9/1 hhv.

Det er intuitivt hinandens modsætninger.

Og:

```
1 log(1/9)
```

```
[1] -2.197225
```

```
1 log(9/1)
```

```
[1] 2.197225
```

Hvor er det bare pænt og symmetrisk!



Hvad tester vi så med odds?

(Næsten) det samme som med risiko.

Er odds for at være TB+ når man deler sprøjter den samme som odds for at være TB+ når man ikke deler sprøjter?

Eller:

Kan vi afvise at:

$$\frac{\text{odds}_{\text{TB}+: \text{deler}}}{\text{odds}_{\text{TB}+: \text{deler ikke}}} = 1$$

Hov! Det var Odds-Ratio, OR, der dukkede op der!

Samme teknik som før:

estimat $\pm 1.96 \cdot \text{SE}$

Hvad er SE?



Lignende problem som med SE for RR

Vi har ikke en pæn formel for $SE(OR)$. Men vi har en for $SE(\log(OR))$

For det generelle forhold:

	udfald 1	udfald 2
eksponeret	a	b
ikke eksponeret	c	d

$$\text{Får vi: } SE(\log(OR)) = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

$$\text{Sammenlign med } SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$


Og se hvorfor jeg mener at matematikken bliver enklere med odds...



Så er vi klar til at regne

TB	deler	deler ikke
TB-positiv	24	28
TB-negativ	73	133

▶ Run Code



1

$$SE(\log(OR)) = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

$$\log OR \pm 1.96 \cdot SE(\log OR)$$



Hvad så vi

OR var 1.56

Det vil vi formulere som at odds for at teste positiv for tb er 56% højere hvis man deler sprøjter end hvis man ikke gør.

Men 95% konfidensintervallet på log-OR var [-0.170; 1.061]

Og da 0 er indeholdt i intervallet kan vi afvise hypotesen om at odds er højere for at være TB+ hvis man deler sprøjter, sammenlignet med hvis man ikke deler sprøjter.

Vi kunne også finde testværdien: $\frac{\log OR}{SE(\log OR)} = 1.420$. Den er mindre end den kritiske værdi (1.96), hvorfor vi ikke kan afvise H_0 .

95% konfidensintervallet på OR var [0.844; 2.890]. 1 er indeholdt i intervallet, og vi kan derfor ikke afvise H_0

Vær skarpe her. Odds er noget andet end risiko.



Fra sandsynlighed til odds

Hvordan beregner vi odds hvis vi kender sandsynligheden?

$$\text{odds} = \frac{p}{1-p}$$

Hvordan beregner vi sandsynligheden hvis vi kender odds:

$$p = \frac{\text{odds}}{1+\text{odds}}$$

En særlig funktion vi kommer til at møde igen:

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right)$$

logit funktionen tager sandsynligheden for et givet udfald, og returnerer log-odds for det udfald.

Den omvendte kan også være nyttig. Hvis $x = \text{logit}(p)$:

$$p = \frac{e^x}{1+e^x}$$

Det er den inverse logit-funktion. Også (spoiler alert) kaldet logistic-funktionen.



χ^2 tilgangen

Mere generel - kan håndtere mere end et udfald.

Sjælden til eksamen - kræver tasteri, og det er ikke hvad I bliver testet i.

Tester forskellen på den fordeling vi ser - og den vi ville forvente

Hvis vi kun kender totalerne

	TB+	TB-	Total
Deler sprøjter	?	?	97
Deler ikke	?	?	161
Total	52	206	258

Og fordelingen af TB+ og TB- er den samme blandt de der deler sprøjter, som de der ikke deler sprøjter

Hvor mange forventer vi så har TB blandt de der deler sprøjter?



Regne-regne

52 ud af 258 er TB+. Hvis der er 97 der deler sprøjter - men det at dele sprøjter ikke påvirker om man tester positiv for TB.

Så må der være $\frac{52}{258} \cdot 97 \approx 20$ der tester positiv.

Det er hvad vi forventer. Men vi ser at der er 24.

Blandt de 161 der ikke deler sprøjter, vil vi med samme antagelse forvente at se $\frac{52}{258} \cdot 161 \approx 32$ der tester positiv.

Det er hvad vi forventer. Men vi ser at der kun er 28.

Vi laver de samme beregninger på de to andre celler.



Regne-regne

χ^2 testens H_0 er, at der ikke er forskel på fordelingen af TB-status i de to grupper.

Testens p-værdi er sandsynligheden for at se så store forskelle på hvad vi forventer, og hvad vi faktisk observerer, som der er i data. Hvis der i virkeligheden ikke er forskel på fordelingen af TB-status i de to grupper.

Styrken er at den kan håndtere flere udfald end to.

Svagheden er at den ikke fortæller hvilken gruppe der har størst risiko for at teste positiv for TB. Blot at der er forskel på fordelingen i de to grupper.

Og så forudsætter χ^2 testen at der er mindst 5 *forventede* observationer i hver “celle”.

Det kan man korrigere for, og det gør R funktionen automatisk. Her har vi så store forventede værdier at vi bør slå korrektionen fra.




Hvordan gør vi?

En smule bøvlet - for vi skal have data ind i en matrix.

```
1 tab <- matrix(  
2   c(24, 73,  
3     28, 133),  
4   nrow = 2,  
5   byrow = TRUE  
6 )  
7  
8 dimnames(tab) <- list(  
9   Exposure = c("Deler", "Deler_ikke  
10  TB = c("Ja", "Nej")  
11 )
```

▶ Run Code



1



Sammenfattende

Det er ca. altid:

Estimat $\pm 1.96 \cdot \text{standardfejlen}$

Undertiden er estimeret logaritmen til det vi er interesseret i. Så er det også standardfejlen på logaritmen til estimeret.

Den kritiske værdi er 1.96. Den knytter sig til 95% KI. Skal I bruge et andet interval - så er det en anden kritisk værdi. Hint: `qnorm`.

Og så skal standardfejlen beregnes forskelligt - afhængig af hvad det er vi tester.



Flere øvelser



Logistisk regression

Vi så den lineære regression. Den forklarede hvordan en numerisk, kontinuær variabel afhang af andre variable.

Den logistiske regression forklarer hvordan en kategorisk variabel afhænger af andre variable.

I den lineære regression fittede vi

$$y = \beta_0 + \beta_1 x$$

Den forventede værdi af y , givet x .

i den logistiske regression er det:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x$$

Også kaldet logit-funktionen.

Så - givet x , får vi log-odds for et bestemt udfald.



Hvordan laves en logistisk regression?

Den logistiske regression lignede ret meget den lineære. Den beskidte hemmelighed er, at den faktisk er lineær - hvis vi regner på log-odds.

Det er dog ikke “OLS” vi bruger til at regne inde bag ved, men “Maximum Likelihood” i stedet. Det bekymrer vi os ikke om her.

Det er endnu et eksempel på at vi i en del sammenhænge arbejder med log-odds fordi det gør matematikken enklere.

Det betyder også at vi i R kan betragte en logistisk regression som en mere generel udgave af den almindelige (multiple) lineære regression.

Funktionen er derfor `glm()` i stedet for `lm()`.



Hvordan ser det ud i praksis?

Har vi et datasæt med følgende variable:

episodes: Antal episoder med feber under graviditeten (før interview)

death: Fosterdød (ja = 1, nej = 0)

mage: Moderens alder ved interview

smoke: Rygning under graviditet (1=0 cigaretter/dag, 2=1-10 cigaretter/dag, 3 = 11+ cigaretter/dag)

alco: Antal genstande pr uge under graviditet

weight: Fødselsvægt i gram

Kan vi derfor modellere den primære outcome variabel “death” som funktion af rygning, feberepisoder og moderens alder ved:

```
1 glm(factor(death) ~ I((mage-25)/10) + episodes + factor(smoke), data = dataset, family = "binomial")
```



Hvad betyder de enkelte dele?

```
1 glm(factor(death) ~ I((mage-25)/10) + episodes + factor(smoke), data = dataset, family = "binomial")
```

Hvad får vi ved at trække 25 fra, og dividere mors alder med 10?

Mors alder målt i enheden “10 år”, med et nulpunkt på 25 år. Ikke væsensforskelligt fra at standardisere værdier, men nok ikke med middelværdi og standardafvigelse

Indpakket i “I()” som specificerer at `glm` skal behandle `(mage-25)/10` som en variabel. Uden, ville `glm` behandle `25` som en variabel.

`episodes` er en kontinuærte variabel. Sådan da, for man har nok 1 eller 2 feberepisoder, ikke 1.5 så helt kontinuært er den ikke. Men vi behandler den som kontinuært.

`smoke` er den kategoriske variabel der beskriver rygevaner.

Men `smoke` er gemt som tal, så den er pakket ind i `factor()` for at behandle den som en kategorisk variabel.

Vi skal specificere hvad datasættet hedder


Og fordi `glm` er en generel funktion, der kan modellere mange forskellige ting, skal vi specificere at det er en logistisk regression. Med `family = "binomial"`



Hvordan ser resultatet ud?

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage- 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

Logistisk? “z values” i stedet for “t values”. Og opgaven fortalte at responsvariablen var fosterdød. Der er ret kategorisk.

Tolkningen af estimatet vender vi tilbage til.

z value er testværdien. Hvordan hænger den sammen med Estimate og Std. Error?

p-værdien tester H_0 : At estimatet i virkeligheden er 0. Det er risikoen/sandsynligheden for at vi afviser H_0 selvom den er sand.

$p=2 \cdot P(Z \geq |z|)$. Eller: $2 \cdot (1 - \text{pnorm}(\text{abs}(z)))$



Estimaterne

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage-25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Først og fremmest - “alt andet lige”.

(Intercept) log-odds for fosterdød -5.0526 for referencegruppen.

Hvad er referencegruppen?

De efterfølgende giver os log-odds-ratio (OR). Hvor meget stiger odds med?

I((mage-25)/10). Alt andet lige - når mors alder stiger med 10 år (hvorfor), stiger log-odds med 0.7423.

episodes. For hver ekstra feberepisode, stiger log-odds med -0.0752. Det vil sige at den falder.

Hvis mor har røget i kategori 2 (det var 1-10 cigaretter/dag), stiger log-odds med 0.2063

Hvis mor har røget i kategori 3 (>10 cigaretter/dag) stiger log-odds med 0.4364

Men kun mors alder er statistisk signifikant på 5% niveau. Eller “På et signifikansniveau $\alpha = 0.05$.”



Hvor sikre er vi på de estimer?

Hvad er et 95% KI på estimatet for “mors alder”?

Estimate $\pm 1.96 \cdot SE$

Estimate = 0.7423

SE = 0.2149

Husk, det er stadig log-oddsratio!

Så hvordan finder vi oddsratio?

Vi exponentierer!

```
Run Code
1
```



Prædiktion

Hvad er odds for forsterdød for en 37 årig mor, der har røget >11 cigaretter/dag, og har haft 3 feberepisoder?

Hvordan gør vi det?

Vi indsætter i modellen.

Så vi skal bruge estimerne:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage-25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

$$\text{logodds} = -5.0526 + 0.7423 \frac{\text{mage}-25}{10} - 0.0752 \cdot \text{episodes} + 0.2063 \cdot \text{smoke:2} + 0.4364 \cdot \text{smoke:3}$$

mage = 37, episodes = 3, smoke:2 = 0, smoke:3 = 1

logodds = -3.95104

odds = $\exp(-3.95104) = 0.01923469$.



Hvad skal vi kunne?

Vi skal kunne genkende en logistisk regression vi skal kunne pege på alle dele af outputtet og forklare hvad det er, og hvad tallet betyder. Vi skal kunne tage outputtet af modellen/regressionen - og beregne den forudsagte værdi af estimatet for et givet sæt af observationer.



teoridelen er done. Nu er det opgaver!



Opgave fra opgave maj 2025 1 b

Vi havde tidligere

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   3613.623    7.108     508.372 <2e-16***
factor(smoke)2 -127.377   15.757
factor(smoke)3 -194.897   17.519     -11.125 <2e-16***
alco           1.045      6.075      0.172    0.863
```

Som måske ikke er så relevant - men vi skal nok have beskrivelsen af data med.

Anyways: `> table(fever$episodes)`

```
 0      1      2      3      4      5      6      7     10
9693 1872   183   20      3      3      1      1      2
```

Er der en sammenhæng mellem den primære responsvariabel (død), og feber i tidlig graviditet.

Vi får også et test af om der er en sammenhæng mellem de to variabler.



Eksamensopgave

Vi ser på 3 års overlevelsen af lungetransplanterede patienter. Man har været nødt til at bruge ældre donorer, der også kan have været rygere. Der er observationer fra 426 patienter og vi har følgende variable: Surv3y: 3 års overlevelsen, med værdien 1 hvis patienten er død inden for tre år efter transplantationen. Ellers 0. SMOKE: Rygestatus for donor, med værdierne “Never smoker” eller “Smoker or former smoker” don_age_cat: Donor alder (<40, 40-55, >= 56). Den sidste kategori er kodet som 56 i data.

De første 6 observationer:

```
# A tibble: 6 × 3
  Surv3y don_age_cat SMOKE
  <dbl> <chr>         <chr>
1      0 0-39       Never smoker
```

