

Logistisk regression

WebR Status

 Ready!



Logistisk regression

Vi så den lineære regression.

Den forklarede hvordan en numerisk, kontinuær variabel afhang af andre variable.

Den logistiske regression forklarer hvordan en kategorisk variabel afhænger af andre variable.

I den lineære regression fittede vi

$$y = \beta_0 + \beta_1 x$$

Den forventede værdi af y , givet x .

i den logistiske regression er det:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x$$

Også kaldet logit-funktionen.

Så - den forventede log-odds for et bestemt udfald, givet x .



Hvordan laves en logistisk regression?

Den logistiske regression ligner ret meget den lineære.

Den beskidte hemmelighed er, at den faktisk er lineær - hvis vi regner på log-odds.

Inde bagved er det dog ikke OLS vi bruger, men en “Maximum Likelihood” funktion. Det behøver vi ikke bekymre os om, det klarer R.

Det er endnu et eksempel på at vi i en del sammenhænge arbejder med log-odds fordi det gør matematikken enklere.

Det betyder også at vi i R kan betragte en logistisk regression som en mere *generel* udgave af den almindelige (multiple) lineære regression.

Funktionen er derfor `glm()` i stedet for `lm()`.



Hvordan ser det ud i praksis?

Har vi et datasæt med følgende variable (det virker bekendt):

episodes: Antal episoder med feber under graviditeten (før interview)

death: Fosterdød (ja = 1, nej = 0)

mage: Moderens alder ved interview

smoke: Rygning under graviditet (1=0 cigaretter/dag, 2=1-10 cigaretter/dag, 3 = 11+ cigaretter/dag)

alco: Antal genstande pr uge under graviditet

weight: Fødselsvægt i gram

Kan vi derfor modellere den primære outcome variabel “death” som funktion af rygning, feberepisoder og moderens alder ved:

```
1 glm(factor(death) ~ I((mage-25)/10) + episodes + factor(smoke), data = dataset, family = "binomial")
```



Hvad betyder de enkelte dele?

```
1 glm(factor(death) ~ I((mage-25)/10) + episodes + factor(smoke), data = dataset, family = "binomial")
```

Hvad får vi ved at trække 25 fra, og dividere mors alder med 10?

Mors alder målt i enheden “10 år”, med et nulpunkt på 25 år. Ikke væsensforskelligt fra at standardisere værdier, men dog ikke med middelværdi og standardafvigelse

Indpakket i “I()” som specificerer at `glm` skal behandle `(mage-25)/10` som en variabel. Uden, ville `glm` forsøge at behandle `25` som en variabel.

`episodes` er en kontinuærte variabel. Sådan da, for man har nok 1 eller 2 feberepisoder, ikke 1.5 så helt kontinuært er den ikke. Men vi behandler den som kontinuært.

`smoke` er den kategoriske variabel der beskriver rygevaner.

Men `smoke` er gemt som tal, så den er pakket ind i `factor()` for at behandle den som en kategorisk variabel. Helt som vi gjorde tidligere i den lineære regression.

Vi skal specificere hvad datasættet hedder


Og fordi `glm` er en generel funktion, der kan modellere mange forskellige ting, skal vi specificere at det er en logistisk regression. Med `family = "binomial"`



Hvordan ser resultatet ud?

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage- 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

Logistisk? “z values” i stedet for “t values”. Og opgaven fortalte at responsvariablen var fosterdød. Der er ret kategorisk.

Tolkningen af estimatet vender vi tilbage til.

z value er testværdien. Hvordan hænger den sammen med Estimate og Std. Error?

p-værdien tester H_0 : At estimatet i virkeligheden er 0. Det er risikoen/sandsynligheden for at vi afviser H_0 selvom den er sand.

$p=2 \cdot P(Z \geq |z|)$. Eller: $2 \cdot (1 - \text{pnorm}(\text{abs}(z)))$



Estimaterne

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage-25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Først og fremmest - “alt andet lige”.

(Intercept) log-odds for fosterdød -5.0526 for referencegruppen.

Hvad er referencegruppen?

De efterfølgende giver os log-odds-ratio (OR). Hvor meget stiger odds med?

I((mage-25)/10). Alt andet lige - når mors alder stiger med 10 år (hvorfor), stiger log-odds med 0.7423.

episodes. For hver ekstra feberepisode, stiger log-odds med -0.0752. Det vil sige at den falder.

Hvis mor har røget i kategori 2 (det var 1-10 cigaretter/dag), stiger log-odds med 0.2063

Hvis mor har røget i kategori 3 (>10 cigaretter/dag) stiger log-odds med 0.4364

Men kun mors alder er statistisk signifikant på 5% niveau. Eller “På et signifikansniveau $\alpha = 0.05$.”



Hvor sikre er vi på de estimer?

Hvad er et 95% KI på estimatet for “mors alder”?

Estimate $\pm 1.96 \cdot SE$

Estimate = 0.7423

SE = 0.2149

Husk, det er stadig log-oddsratio!

Så hvordan finder vi oddsratio?

Vi exponentierer!

```
Run Code
1
```



teoridelen er done. Nu er det opgaver!

hm.



Mors rygning

Vi har tidligere kigget på sammenhængen mellem fødselsvægt og mors rygning/alkohol indtag under graviditeten.

Nu ser vi på den primære responsvariabel, som var fosterdød.

Recap af de relevante variable i datasættet:

episodes: antal episoder med feber under graviditeten death: Fosterdød (ja = 1, nej = 0)

mage: Morderens alder smoke: Rygning under graviditet (1=0 cigaretter/dag, 2=1-10 cigaretter/dag, 3=11+ cigaretter/dag)

Vi får også oplyst:

```
> table(fever$episodes)
```

0	1	2	3	4	5	6	7	10
9693	1872	183	20	3	3	1	1	2

Er der en sammenhæng mellem den primære responsvariabel (død), og feber i tidlig graviditet.



Mors rygning

Vi får oplyst at den korrekte analyse gav dette resultat:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

i((mage-25)/10) skal vi lige holde tungen lige i munden. mage er moderens alder ved interview. Vi sætter et nulpunkt der er 25, og måler derefter i enheder af 10 år.

c. Hvad kan vi konkludere på denne analyse? Fortolk relevante estimer



Mors rygning

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Det er en logistisk regression, så estimerterne er log-odds

For at få odds skal vi derfor

exponentiere estimerterne for at få odds.

Hvordan fandt vi en sandsynlighed ud fra odds?


$$p = \frac{\text{odds}}{1+\text{odds}}$$



Mors rygning - intercept

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

$$p = \frac{\text{odds}}{1 + \text{odds}}$$

Hvad repræsenterer interceptet?

Baseline - hvad er det?


Find: Odds, sandsynlighed og 95% KI
for Intercept



Mors rygning - alder

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

$$p = \frac{\text{odds}}{1 + \text{odds}}$$

Hvad sker der med odds for fosterdød
når mors alder stiger?

Husk at det er i enheder af 10 år

Find: Odds, sandsynlighed og 95% KI
for I((mage-25)/10)

Signifikant?



Mors rygning - resten

Hverken antallet af feberepisoder eller rygning har statistisk signifikant betydning.

Vi kan beregne OR på dem og konfidensintervaller.


Den der kommer tættest på er rygning niveau 3, men den er ikke signifikant ved et 5% niveau.



Mors rygning - prediktion

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

$$p = \frac{\text{odds}}{1 + \text{odds}}$$


Forudsig (predikter) risiko for fosterdød for gravid kvinde, 25 år gammel der ikke ryger og ikke har feberepisoder.



Mors rygning - prediktion 2

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

$$p = \frac{\text{odds}}{1 + \text{odds}}$$

Gentag forudsigelsen for en
kvinde der er 40 år.



Rygende donorer

Vi ser på 3 års overlevelsen af lungetransplanterede patienter. Man har brugt ældre donorer, der også kan have været rygere. Der er observationer fra 426 patienter og vi har følgende variable:

Surv3y: 3 års overlevelsen, med værdien 1 hvis patienten er død inden for tre år efter transplantationen. Ellers 0.

SMOKE: Rygestatus for donor, med værdierne "Never smoker" eller "Smoker or former smoker"

don_age_cat: Donor alder (<40, 40-55, >= 56). Den sidste kategori er kodet som 56 i data.

De første 6 observationer:

```
# A tibble: 6 × 3
  Surv3y don_age_cat SMOKE
  <dbl>   <chr>      <chr>
1     0 0-39      Never smoker
2     1 0-39      Never smoker
3     1 40-55      Smoker or former smoker
4     1 56        Never smoker
5     1 40-55      Smoker or former smoker
6     1 56        Smoker or former smoker
```

vi får følgende output:

```
1 table(Surv3y, SMOKE)
```

	SMOKE	
Surv3y	Never smoker	Smoker or former smoker
0	153	117
1	68	88


Baseret på dette - er der en sammenhæng mellem donors rygestatus og patientens 3 års overlevelse. Hvis der er signifikant sammenhæng, skal det kvantificeres som en relativ risiko med tilhørende 95% konfidensinterval. Forklar hvad det betyder.



Rygende donorer - regne

SMOKE			
Surv3y	Never smoker	Smoker or former smoker	
0	153	117	
1	68	88	

Run Code



1

Hvad er sandsynligheden for død inden for de 3 år for de to grupper?

Hvad er den relative risiko?

Hvor er 95% KI?

Er det signifikant?

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$

Husk, vi regner i log.

Hvad betyder det hvis $RR = 1$?



Rygende donorer

Nu udfører vi en analyse, og får følgende output:

```
Call: glm(formula = Surv3y ~ factor(SMOKE) + factor(don_age_cat), family = 'binomial')
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.2848	0.2362	-5.439	5.36-8***
factor(SMOKE)Smoker or former smoker	0.5751	0.2066	2.783	0.00538**
factor(don_age_cat)40-55	0.4440	0.2527	1.757	0.07896.
factor(don_age_cat)56	0.9395	0.2891	3.249	0.00116**

Hvilken analyse er der tale om? hvad er respons og hvad er forklarende variable?

Det er en logistisk regression, med Surv3y som respons (den er binær) og SMOKE og don_age_cat som kategoriske forklarende variable



Rygende donorer


Hvad kan vi konkludere på baggrund af den analyse. Beregn relevante odds ratios (OR), beregn også de tilhørende 95% konfidensintervaller

```
Call: glm(formula = Surv3y ~ factor(SMOKE) +  
  factor(don_age_cat), family = 'binomial')
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.2848	0.2362	-5.439	5.36-8*
factor(SMOKE)Smoker or former smoker	0.5751	0.2066	2.783	0.00538*
factor(don_age_cat)40-55	0.4440	0.2527	1.757	0.07896
factor(don_age_cat)56	0.9395	0.2891	3.249	0.00116*

Husk - log(odds)!

Run Code



1



Rygende donorer

Endelig blev følgende regnestykke foretaget:

```
1 exp(-1.2848)/(1+exp(-1.2848))
```

```
[1] 0.2167343
```

Hvordan fortolker vi det tal?

-1.2848 er estimeret på intercept.

Det var for referencegruppen. Den patientgruppe der har fået lunger fra en donor under 40 år, der var ikke ryger.

Hvad er det så vi beregner?

$\exp(-1.2848)$ går fra

Log Odds(ratio) til:

Odds

Og brøken giver?

Den går fra odds til sandsynlighed - så vi får?

Den estimerede sandsynlighed for at dø inden for 3 år, for den patientgruppe der fik lunger fra en donor under 40, der var ikke-ryger.



DTP-vaccine

1473 børn i Guinea-Bissau blev undersøgt for at finde ud af om der, ud over gavnlig effekt af vaccination mod specifikke sygdomme, også var en generelt reduceret børne-dødelighed.

Børnene blev besøgt to gange i deres hjem. Første gang tidligt efter fødslen hvor der blev vaccineret. anden gang ca. 6 måneder senere, hvor der blev fulgt op. En del, men ikke alle børn blev vaccineret med DTP (difteri, tetanus og pertussis).

Vi får oplyst de seks første observationer i datasættet:

```
# A tibble: 6 × 5
  alder status  dtp etngr vægt
  <dbl> <dbl> <dbl> <dbl> <dbl>
1 0.592     0     1     1  5.6
2 0.425     1     1     1    6
3 0.51      0     1     1  6.2
4 0.592     0     1     1  6.2
5 0.173     0     0     1  5.6
6 0.173     0     0     1  5.2
```

Variablene i datasættet oplyses at være:
alder - alder ved vaccinationen - i år
status - status ved opfølgning. 1: død, 0: i live

dtp: blev barnet vaccineret. 1: ja, 0: nej
vægt: barnets vægt ved vaccination (i kg)
etniskgr: etnisk gruppe 0: Manjaco, Fula, 1: Mandinga og anden

Og optælling:

```
1 table(dtp, status)
```

	status	
dtp	0	1
0	526	9
1	892	46



DTP-vaccine - kort udgave

Lad os lige koge det ned til kernen

1473 observationer.

Med oplysning om alder og vægt - kontinuære variable

og

Status (død/levende), dtp (vaccine, ja/nej) og etnisk gruppe. Alle tre kategoriske og binære.

Status er den primære responsvariabel - det vi undersøger.

Og så tabellen

```
1 table(dtp,status)
```

		status	
dtp	0	1	
0	526	9	
1	892	46	

Resten er fluff, og en del af taktikken når I skal løse opgaver er at skære dem ind til benet.



DTP-vaccine

Ser det umiddelbart ud til at der er en sammenhæng mellem dødeligheden og vaccinstatus?

Hvordan vil vi gribe det an?

Vi vil sammenligne de forskellige risici. Så Risk Ratio.

Hvad skal vi bruge?

Risikoen for død blandt de vaccinerede. Og risikoen for død blandt de ikke vaccinerede.

Og så skal vi opstille en H_0 . Når vi arbejder med RR, hvordan ser den så *altid* ud?

$$H_0 : RR = 1$$

Hvad skal vi bruge der?

En test-værdi som vi kan sammenligne med 1.96

Hvordan beregner vi den?

$$\frac{\text{Estimat}}{SE}$$


Og hvordan beregner vi SE?

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$

HUSK! Vi regner på $\log(RR)$

```
status
dtp    0    1
0  526    9
1  892   46
```

Run Code



1



DTP-vaccine

Opgaven fortsætter: Hvordan vil vi undersøge sammenhængen mellem dødeligheden og vaccinstatus hvor der justeres for de øvrige variable? Angiv den tilsvarende R-kode

Den formulering er kode for: Hvilken model vil vi opstille?

Hvad er responsvariablen?

Den er død

Er det kategorisk eller kontinuært?

Det bliver ikke mere kategorisk!

Hvilken slags model skal vi så opstille?

En logistisk regression, med dødeligheden som afhængig variabel.

Hvad skal vi have med som forklarende variable? vaccinstatus. Og resten af de variable vi havde i datasættet.

Eksemplet på data var:

```
# A tibble: 6 × 5
  alder status   dtp etngr vægt
<dbl> <dbl> <dbl> <dbl> <dbl>
1 0.592     0     1     1  5.6
2 0.425     1     1     1    6
3 0.51      0     1     1  6.2
4 0.592     0     1     1  6.2
5 0.173     0     0     1  5.6
6 0.173     0     0     1  5.2
```

Så det er?

Alder, vægt (vægt) etnicitet (etngr) og vaccinstatus (dtp).

Hvad er de?

Alder og vægt er kontinuærte, etnicitet og vaccinstatus er kategoriske.

Så hvordan ser R-koden ud?

```
glm(status~vægt + alder + factor(dtp) +
factor(etngr), family = "binomial")
```



DTP-vaccine

Typisk bliver I hjulpet hvis I læser det næste spørgsmål. Der er nemlig ofte en formulering:

“Den korrekte analyse gav nedenstående resultat:”

```
# A tibble: 5 × 5
  Coefficients Estimate `Std. Error` `t value`
`Pr(>|t|)`
  <chr>          <dbl>      <dbl>      <dbl> <chr>
1 (Intercept)    0.0567    0.0287      1.98 0.048
*
2 factor(dtp)1    0.0261    0.0116      2.25 0.025
*
3 factor(etngr)1  0.0229    0.0103      2.22 0.027
*
4 alder          0.0584    0.0390      1.5  0.134
5 vaegt         -0.0114    0.00527    -2.16 0.031
*
```

Fortolk resultatet. Er der sammenhæng mellem vaccinstatus og dødeligheden?

Giv et relevant effektmål med tilhørende 95% konfidensinterval

Er dtp signifikant?


Ja, dtp er signifikant, også efter der justeres for etnicitet, alder og vægt, med $p = 0.025$

Hvad er effektmålet? Husk i den logistiske regression får vi ?

log-odds - så hvordan finder vi Odds(ratio)?

Og KI?

Run Code



1

