

Logistisk regression

WebR Status

 Ready!



Logistisk regression

Vi så den lineære regression.

Den forklarede hvordan en numerisk, kontinuær variabel afhang af andre variable.

Den logistiske regression forklarer hvordan en kategorisk variabel afhænger af andre variable.

I den lineære regression fittede vi

$$y = \beta_0 + \beta_1 x$$

Den forventede værdi af y , givet x .

i den logistiske regression er det:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 x$$

Også kaldet logit-funktionen.

Så - den forventede log-odds for et bestemt udfald, givet x .



Hvordan laves en logistisk regression?

Den logistiske regression ligner ret meget den lineære.

Den beskidte hemmelighed er, at den faktisk er lineær - hvis vi regner på log-odds.

Inde bagved er det dog ikke OLS vi bruger, men en “Maximum Likelihood” funktion. Det behøver vi ikke bekymre os om, det klarer R.

Det er endnu et eksempel på at vi i en del sammenhænge arbejder med log-odds fordi det gør matematikken enklere.

Det betyder også at vi i R kan betragte en logistisk regression som en mere *generel* udgave af den almindelige (multiple) lineære regression.

Funktionen er derfor `glm()` i stedet for `lm()`.



Hvordan ser det ud i praksis?

Vi har tidligere kigget på sammenhængen mellem fødselsvægt og mors rygning/alkohol indtag under graviditeten.

Nu ser vi på den primære responsvariabel, som var fosterdød.

Vi har et datasæt med følgende variable:

episodes: Antal episoder med feber under graviditeten (før interview)

death: Fosterdød (ja = 1, nej = 0)

mage: Moderens alder ved interview

smoke: Rygning under graviditet (1=0 cigaretter/dag, 2=1-10 cigaretter/dag, 3 = 11+ cigaretter/dag)

alco: Antal genstande pr uge under graviditet

weight: Fødselsvægt i gram

Og vi kan modellere fosterdød ved:

```
1 glm(factor(death) ~ I((mage-25)/10) + episodes + factor(smoke), data = dataset, family = "binomial")
```

Den der sære konstruktion med $I((mage-25)/10)$, hvor kom den fra? Den var oplyst i et eksamenssæt.



Hvad betyder de enkelte dele?

```
1 glm(factor(death) ~ I((mage-25)/10) + episodes + factor(smoke), data = dataset, family = "binomial")
```

Hvad får vi ved at trække 25 fra, og dividere mors alder med 10?

Mors alder målt i enheden “10 år”, med et nulpunkt på 25 år. Ikke væsensforskelligt fra at standardisere værdier, men dog ikke med middelværdi og standardafvigelse

Indpakket i “I()” som specificerer at `glm` skal behandle `(mage-25)/10` som en variabel. Uden, ville `glm` forsøge at behandle `25` som en variabel.

`episodes` er en kontinuærte variabel. Sådan da, for man har nok 1 eller 2 feberepisoder, ikke 1.5 så helt kontinuært er den ikke. Men vi behandler den som kontinuært.

`smoke` er den kategoriske variabel der beskriver rygevaner.

Men `smoke` er gemt som tal, så den er pakket ind i `factor()` for at behandle den som en kategorisk variabel. Helt som vi gjorde tidligere i den lineære regression.

Vi skal specificere hvad datasættet hedder


Og fordi `glm` er en generel funktion, der kan modellere mange forskellige ting, skal vi specificere at det er en logistisk regression. Med `family = "binomial"`



Hvordan ser resultatet ud?

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage- 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

Logistisk? “z values” i stedet for “t values”. Og opgaven fortalte at responsvariablen var fosterdød. Der er ret kategorisk.

Tolkningen af estimater vender vi tilbage til.

z value er testværdien. Hvordan hænger den sammen med Estimate og Std. Error?

p-værdien tester H_0 : At estimatet i virkeligheden er 0. Det er risikoen/sandsynligheden for at vi afviser H_0 selvom den er sand.

$p=2 \cdot P(Z \geq |z|)$. Eller: $2 \cdot (1 - \text{pnorm}(\text{abs}(z)))$



Estimaterne

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage-25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Først og fremmest - “alt andet lige”.

(Intercept) log-odds for fosterdød -5.0526 for referencegruppen.

Hvad er referencegruppen?

25 år gammel, ingen feberepisoder, ingen rygning.

De efterfølgende giver os log-odds-ratio (OR). Hvor meget stiger odds med?

I((mage-25)/10). Alt andet lige - når mors alder stiger med 10 år (hvorfor), stiger log-odds med 0.7423.

episodes. For hver ekstra feberepisode, stiger log-odds med -0.0752. Det vil sige at den falder.

Hvis mor har røget i kategori 2 (det var 1-10 cigaretter/dag), stiger log-odds med 0.2063

Hvis mor har røget i kategori 3 (>10 cigaretter/dag) stiger log-odds med 0.4364

Men kun mors alder er statistisk signifikant på 5% niveau. Eller “På et signifikansniveau $\alpha = 0.05$.”



Hvor sikre er vi på de estimer?

Hvad er et 95% KI på estimatet for “mors alder”?

Estimate $\pm 1.96 \cdot SE$

Estimate = 0.7423

SE = 0.2149

Husk, det er stadig log-oddsratio!

Så hvordan finder vi oddsratio?

Vi exponentierer!

```
Run Code
1
```



Mors rygning

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Det er en logistisk regression, så estimerterne er log-odds

For at få odds skal vi derfor

exponentiere estimerterne for at få odds.

Hvordan fandt vi en sandsynlighed ud fra odds?


$$p = \frac{\text{odds}}{1+\text{odds}}$$



Mors rygning - intercept

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

Find: Odds, sandsynlighed og 95% KI
for Intercept

Hvad repræsenterer interceptet?

Baseline - hvad er det?

Hvordan fandt vi sandsynligheden?


$$p = \frac{\text{odds}}{1 + \text{odds}}$$



Mors rygning - alder

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

Hvad sker der med oddsratio for fosterdød når mors alder stiger?

Husk at det er i enheder af 10 år

Find: Oddsratio og 95% KI for I((mage-25)/10)

Signifikant?



Mors rygning - resten

Hverken antallet af feberepisoder eller rygning har statistisk signifikant betydning.

Vi kan beregne OR på dem og konfidensintervaller.

Den der kommer tættest på er rygning niveau 3, men den er ikke signifikant ved et 5% niveau.

Bemærk også: Vi beregner odds for baseline.

Men når vi regner på alderen, så regner vi på hvordan odds ændrer sig når vi ændrer på alderen.

Derfor er det odds-*ratio* vi beregner!

Og derfor er det ikke specielt meningsfuldt at beregne sandsynligheder ved en aldersstigning.

Derfor taler vi *heller ikke* om at der er 2.1 gange højere sandsynlighed (!)


Det er 2.1 gange højere *odds* der er associeret med en stigning på 10 år i mors alder.



Mors rygning - prediktion

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

Forudsig (predikter) risiko for
fosterdød for gravid kvinde, 25 år
gammel der ikke ryger og ikke har
feberepisoder.

$$p = \frac{\text{odds}}{1 + \text{odds}}$$

eller, cowboy-trick:


`plogis(log_odds)`



Mors rygning - prediktion 2

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.0526	0.1758	-28.725	<2e-16***
I((mage - 25)/10)	0.7423	0.2149	3.454	0.0005***
episodes	-0.0752	0.2048	-0.368	0.713
factor(smoke)2	0.2063	0.2569	0.803	0.421
factor(smoke)3	0.4364	0.2569	1.699	0.089

Run Code



1

Gentag forudsigelsen for en
kvinde der er 40 år.

$$p = \frac{\text{odds}}{1 + \text{odds}}$$



Sidste note om de rygende mødre

Man kan godt beregne KI på sandsynlighederne. Men.

Det kræver adgang til det oprindelige datasæt.



Rygende donorer

Vi ser på 3 års overlevelsen af lungetransplanterede patienter. Man har brugt ældre donorer, der også kan have været rygere. Der er observationer fra 426 patienter og vi har følgende variable:

Surv3y: 3 års overlevelsen, med værdien 1 hvis patienten er død inden for tre år efter transplantationen. Ellers 0.

SMOKE: Rygestatus for donor, med værdierne "Never smoker" eller "Smoker or former smoker"

don_age_cat: Donor alder (<40, 40-55, >= 56). Den sidste kategori er kodet som 56 i data.

De første 6 observationer:

```
# A tibble: 6 × 3
  Surv3y don_age_cat SMOKE
  <dbl>   <chr>      <chr>
1     0 0-39      Never smoker
2     1 0-39      Never smoker
3     1 40-55     Smoker or former smoker
4     1 56        Never smoker
5     1 40-55     Smoker or former smoker
6     1 56        Smoker or former smoker
```

vi får følgende output:

```
1 table(Surv3y, SMOKE)
```

SMOKE		
Surv3y	Never smoker	Smoker or former smoker
0	153	117
1	68	88


Baseret på dette - er der en sammenhæng mellem donors rygestatus og patientens 3 års overlevelse. Hvis der er signifikant sammenhæng, skal det kvantificeres som en relativ risiko med tilhørende 95% konfidensinterval. Forklar hvad det betyder.



Rygende donorer - regne

SMOKE		
Surv3y	Never smoker	Smoker or former smoker
0	153	117
1	68	88

Run Code



1

Hvad er sandsynligheden for død (1)
inden for de 3 år for de to grupper?

Hvad er den relative risiko?

Hvor er 95% KI?

Er det signifikant?

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$

Husk, vi regner i log.

Hvad betyder det hvis $RR = 1$?



Rygende donorer

Nu udfører vi en analyse, og får følgende output:

```
Call: glm(formula = Surv3y ~ factor(SMOKE) + factor(don_age_cat), family = 'binomial')
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.2848	0.2362	-5.439	5.36-8***
factor(SMOKE)Smoker or former smoker	0.5751	0.2066	2.783	0.00538**
factor(don_age_cat)40-55	0.4440	0.2527	1.757	0.07896.
factor(don_age_cat)56	0.9395	0.2891	3.249	0.00116**

Hvilken analyse er der tale om? Hvad er respons og hvad er forklarende variable?

Det er en logistisk regression, med Surv3y som respons (den er binær) og SMOKE og don_age_cat som kategoriske forklarende variable.



Rygende donorer


Hvad kan vi konkludere på baggrund af den analyse? Beregn relevante odds ratios (OR), beregn også de tilhørende 95% konfidensintervaller

```
Call: glm(formula = Surv3y ~ factor(SMOKE) +  
          factor(don_age_cat), family = 'binomial')
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.2848	0.2362	-5.439	5.36-8***
factor(SMOKE)Smoker or former smoker	0.5751	0.2066	2.783	0.00538**
factor(don_age_cat)40-55	0.4440	0.2527	1.757	0.07896.
factor(don_age_cat)56	0.9395	0.2891	3.249	0.00116**

Husk - log(odds)!

Run Code



1



Rygende donorer - hvad så vi?

OR for SMOKE var 1.777308

Det vil sige ca. 1.78 gange højere odds for at dø inden for 3 år efter transplantationen, hvis donor havde røget, sammenlignet med hvis donor havde været ikke-ryger.

Har vi kontrolleret for noget?

Ja, det er for fastholdt donor-alder.

95% KI var [1.177508, 2.682100]

For donoralder 40-55 var OR 1.55893

Det vil sige, ca 1.56 gange højere odds for at dø (etc), hvis donor var i alderskategorien 40-55, sammenlignet med hvis donor havde været under 40.

Har vi kontrolleret for noget?

Ja, for fastholdt rygestatus for donor

KI var 0.9500012 2.5581696

Var det signifikant?

Nej, 1 er indeholdt i intervallet. Vi kan også se det på p-værdien.

Og for donor alder >55 år

OR var 2.558702 og KI [1.451887, 4.509273]

Det vil sige 2.56 gange højere odds for at osv. hvis donor var ældre end 55 år, sammenlignet med hvis donor havde været under 40. Igen for fastholdt rygestatus for donor.

Den effekt er signifikant (på et 5% niveau)



Rygende donorer

Endelig blev følgende regnestykke foretaget:

```
1 exp(-1.2848)/(1+exp(-1.2848))
```

```
[1] 0.2167343
```

Hvordan fortolker vi det tal?

-1.2848 er estimeret på intercept.

Det var for referencegruppen. Den patientgruppe der har fået lunger fra en donor under 40 år, der var ikke ryger.

Hvad er det så vi beregner?

$\exp(-1.2848)$ går fra

Log Odds(ratio) til:

Odds

Og brøken giver?

Den går fra odds til sandsynlighed - så vi får?

Den estimerede sandsynlighed for at dø inden for 3 år, for den patientgruppe der fik lunger fra en donor under 40, der var ikke-ryger.



DTP-vaccine

1473 børn i Guinea-Bissau blev undersøgt for at finde ud af om der, ud over gavnlig effekt af vaccination mod specifikke sygdomme, også var en generelt reduceret børne-dødelighed.

Børnene blev besøgt to gange i deres hjem. Første gang tidligt efter fødslen hvor der blev vaccineret. anden gang ca. 6 måneder senere, hvor der blev fulgt op. En del, men ikke alle børn blev vaccineret med DTP (difteri, tetanus og pertussis).

Vi får oplyst de seks første observationer i datasættet:

```
# A tibble: 6 × 5
  alder status  dtp etngr vægt
  <dbl> <dbl> <dbl> <dbl> <dbl>
1 0.592     0     1     1  5.6
2 0.425     1     1     1    6
3 0.51      0     1     1  6.2
4 0.592     0     1     1  6.2
5 0.173     0     0     1  5.6
6 0.173     0     0     1  5.2
```

Variablene i datasættet oplyses at være:
alder - alder ved vaccinationen - i år
status - status ved opfølgning. 1: død, 0: i live

dtp: blev barnet vaccineret. 1: ja, 0: nej
vægt: barnets vægt ved vaccination (i kg)
etniskgr: etnisk gruppe 0: Manjaco, Fula, 1: Mandinga og anden

Og optælling:

```
1 table(dtp, status)
```

	status	
dtp	0	1
0	526	9
1	892	46



DTP-vaccine - kort udgave

Lad os lige koge det ned til kernen

1473 observationer.

Med oplysning om alder og vægt - kontinuære variable

og

Status (død/levende), dtp (vaccine, ja/nej) og etnisk gruppe. Alle tre kategoriske og binære.

Status er den primære responsvariabel - det vi undersøger.

Og så tabellen

```
1 table(dtp,status)
```

	status	
dtp	0	1
0	526	9
1	892	46

Resten er fluff, og en del af taktikken når I skal løse opgaver er at skære dem ind til benet.



DTP-vaccine

Ser det umiddelbart ud til at der er en sammenhæng mellem dødeligheden (status 1: død) og vaccinstatus (dtp 1: vaccineret)?

Hvordan vil vi gribe det an?

Vi vil sammenligne de forskellige risici. Så Risk Ratio.

Hvad skal vi bruge?

Risikoen for død blandt de vaccinerede. Og risikoen for død blandt de ikke vaccinerede.

Og så skal vi opstille en H_0 . Når vi arbejder med RR, hvordan ser den så *altid* ud?

$$H_0 : RR = 1$$

Hvad skal vi bruge der?

En test-værdi som vi kan sammenligne med 1.96

Hvordan beregner vi den?

$$\frac{\text{Estimat}}{SE}$$


Og hvordan beregner vi SE?

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$

HUSK! Vi regner på $\log(RR)$

```
status
dtp    0    1
0  526    9
1  892   46
```

Run Code



1



DTP-vaccine

Opgaven fortsætter: Hvordan vil vi undersøge sammenhængen mellem dødeligheden og vaccinstatus hvor der justeres for de øvrige variable? Angiv den tilsvarende R-kode

Den formulering er kode for: Hvilken model vil vi opstille?

Hvad er responsvariablen?

Den er død

Er det kategorisk eller kontinuært?

Det bliver ikke mere kategorisk!

Hvilken slags model skal vi så opstille?

En logistisk regression, med dødeligheden som afhængig variabel.

Hvad skal vi have med som forklarende variable? vaccinstatus. Og resten af de variable vi havde i datasættet.

Eksemplet på data var:

```
# A tibble: 6 × 5
  alder status   dtp etngr vægt
<dbl> <dbl> <dbl> <dbl> <dbl>
1 0.592     0     1     1  5.6
2 0.425     1     1     1    6
3 0.51      0     1     1  6.2
4 0.592     0     1     1  6.2
5 0.173     0     0     1  5.6
6 0.173     0     0     1  5.2
```

Så det er?

Alder, vægt (vægt) etnicitet (etngr) og vaccinstatus (dtp).

Hvad er de?

Alder og vægt er kontinuærte, etnicitet og vaccinstatus er kategoriske.

Så hvordan ser R-koden ud?

```
glm(status~vægt + alder + factor(dtp) +
factor(etngr), family = "binomial", data = data)
```



DTP-vaccine

Typisk bliver I hjulpet hvis I læser det næste spørgsmål. Der er nemlig ofte en formulering:

“Den korrekte analyse gav nedenstående resultat:”

```
# A tibble: 5 × 5
  Coefficients Estimate `Std. Error` `t value`
`Pr(>|t|)`
  <chr>          <dbl>      <dbl>      <dbl> <chr>
1 (Intercept)    0.0567    0.0287      1.98 0.048
*
2 factor(dtp)1    0.0261    0.0116      2.25 0.025
*
3 factor(etngr)1  0.0229    0.0103      2.22 0.027
*
4 alder          0.0584    0.0390      1.5  0.134
5 vaegt         -0.0114    0.00527    -2.16 0.031
*
```

Fortolk resultatet. Er der sammenhæng mellem vaccinstatus og dødeligheden?

Giv et relevant effektmål med tilhørende 95% konfidensinterval

Er dtp signifikant?


Ja, dtp er signifikant, også efter der justeres for etnicitet, alder og vægt, med $p = 0.025$

Hvad er effektmålet? Husk i den logistiske regression får vi ?

log-odds - så hvordan finder vi Odds(ratio)?

Og KI?

Run Code



1



Glykæmisk kontrol

Vi skal undersøge om type 2 diabetes patienter med bedre glykæmisk kontrol, har et bedre selvvurderet helbred.

Vi har data på en repræsentativ gruppe ny-diagnosticerede danske type-2 diabetikere.

Der er følgende variable i datasættet:

HBA1C_dik: 1 hvis HbA1c < 9%, 0 hvis HbA1c ≥ 9%
SRH_dik: 1 hvis selvvurderet helbred er godt/meget godt. 0 hvis det er nogenlunde/dårligt/meget dårligt

AGE: Alder i år

SEX: Køn. 0: Kvinde, 1: Mand

Note til ikke-medicinen: *HBA1C_dik* = 1 indikerer god glykæmisk kontrol

Vi gør i R følgende og får:

```
1 table(SRH_dik, HBA1C_dik)
```

	HBA1C_dik	
SRH_dik	0	1
0	412	264
1	354	188



Glykæmisk kontrol

Baseret på den tabel - er der sammenhæng mellem de to variable?

```
1 table(SRH_dik, HbA1C_dik)
```


	HbA1C_dik	
SRH_dik	0	1
0	412	264
1	354	188

Hvordan kan vi gøre det?

Relativ risiko.

Så hvad er den relative risiko for godt (selvvurderet) helbred (1), hvis HbA1c er 1 - altså velreguleret.

Run Code



1



Glykæmisk kontrol

Vi fandt en RR på 0.9

Hvad betyder det?

At der er lavere sandsynlighed for selvrapporteret godt helbred hvis ens blodsukker er velreguleret.

Er det statistisk signifikant?

Hvordan afgør vi det?

En testværdi. Men lad os denne gang beregne et 95% KI i stedet

Hvordan ser det ud?

Estimat $\pm 1.96 \cdot SE$


Og hvordan beregnede vi SE?

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$

```
1 table(SRH_dik, HbA1C_dik)
```

```
      HbA1C_dik
SRH_dik  0    1
0      412 264
1      354 188
```

Run Code



1



Glykæmisk kontrol

Nu udfører vi denne analyse i R:

```
>model1 <- glm(SRH_dik ~  
factor(HbA1C_dik)+ factor(SEX) + Age, family  
= "binomial")  
>summary(model1)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.717969	0.350389	2.049	0.04046*
factor(HbA1C_dik)1	-0.188731	0.120637	-1.564	0.11771
factor(SEX)1	0.252051	0.117514	2.145	0.03196*
AGE	-0.015573	0.005099	-3.054	0.00226*

Hvad har vi gjort, og hvordan fortolker vi resultaterne?

Der er lavet en logistisk regression.

Hvad var responsvariabel?

SRH_dik - selvrapporteret, godt helbred.

Hvad var der af forklarende variable?

AGE som kontinuert og HbA1C_dik og SEX som kategoriske variable.

Er der nogen af dem der er signifikante?

Både køn og alder er signifikante, med p-værdier på hhv 0.032 og 0.0023

HbA1C - altså om patienten er i glykæmisk kontrol, er ikke signifikant.




Glykæmisk kontrol

Vi må hellere beregne nogle 95% KI også og odds-ratios også.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.717969	0.350389	2.049	0.04046*
factor(HbA1C_dik)1	-0.188731	0.120637	-1.564	0.11771
factor(SEX)1	0.252051	0.117514	2.145	0.03196*
AGE	-0.015573	0.005099	-3.054	0.00226*

Dem skal vi nemlig bruge hvis opgaven efterspørger effektestimater med tilhørende 95% KI. Og det gør den ofte.

Run Code



1



Glykæmisk kontrol

Hvad så vi så?

Køn var statistisk signifikant med tilhørende odds-ratio på

```
1 exp(0.252051)
```

```
[1] 1.286662
```

Hvad betyder det?

Mandlige diabetikere har 28% større odds for (selvrapporteret) godt helbred sammenlignet med kvindelige diabetikere.

Og med et 95% KI på

```
1 exp(0.252051 + c(-1,1)*1.96*0.117514)
```

```
[1] 1.021961 1.619923
```

Med alder og HBA1C_dik fastholdt.

Age var også statistisk signifikant med tilhørende odds-ratio på

```
1 exp(-0.015573)
```

```
[1] 0.9845476
```

Og et 95% KI på:

```
1 exp(-0.015573 +c(-1,1)*1.96*0.005099)
```

```
[1] 0.9747570 0.9944366
```

Så ved 1 års øget alder, ses ca. 1.5% reduceret odds for godt selvvurderet helbred.

Hvad hvis vi øger med 5 år?

```
1 exp(-0.015573*5)
```

```
[1] 0.9250893
```

Hvad er konfidensintervallet hvis vi øger alderen med fem år?

Koefficienten ganger vi “bare” med 5. Usikkerheden - den akkumulerer, så den skal også ganges med 5.

Så:

```
1 exp(-0.015573*5 +c(-1,1)*1.96*0.005099*5)
```

```
[1] 0.8799984 0.9724907
```



Laparotomi

Vi ser på data fra ca 1000 patienters risiko for at dø ved en operation (laparotomi). Har øget ilt-tilførsel under operationen betydning for død i en opfølgningsperiode på ca. 3 år. Patienterne blev randomiseret til et af to ilt-regimer

Vi har følgende variable:

Allokering: X - patient fik 80% ilt, Y Patient fik 30% ilt

diagn_cancer: j: cancer, n: ikke cancer

blod: j perioperativ blodtransfusion, n ikke perioperativ blodtransfusion

bmi: patientens BMI

dead: 1 patienten dør i løbet af opfølgningsperioden, 0 patienten overlever

De første 6 observationer:

```
# A tibble: 6 × 5
  Allokering diagn_cancer blod    bmi    dead
  <chr>      <chr>      <chr> <dbl> <dbl>
1 Y         n          n    29.3     0
2 X         n          n    28.1     0
3 X         j          n    21.5     1
4 X         j          n    17.3     1
5 Y         n          n    24.2     0
6 Y         n          n    18.2     0
```



Laparotomi

Hvis vi alene betragter patienternes bmi, hvordan ville vi så undersøge om den har signifikant betydning for risikoen for død efter operation.

Hvad er vores outcome?

Det er dead

Hvad er det?

Det er så kategorisk som det kan blive

Så ved vi at vi skal lave en?

Logistisk regression.

Hvad har vi som forklarende variabel?

bmi.

Hvad er det?

Det er kontinuært.

Så:

En logistisk regression med dead som kategorisk responsvariabel og bmi som kontinuært forklarende variabel.



Laparotomi

Når vi gør det, får vi følgende resultat (de synes det er sjovt at fjerne dele af output):

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.007041	0.386263	-0.018	0.98546
bmi		0.015385	-3.151	

Hvad kan vi sige ud fra det?

Estimat for bmi?

Er det i øvrigt signifikant?

Hvad er OR?

Og et 95% KI?

▶ Run Code

1



Laparotomi

Nu ser vi bort fra bmi, og undersøger om ilt-allokeringen har betydning for risikoen for død efter operation.

Vi får oplyst at følgende gøres:

```
1 table(dead,Allokering)
```

```
      Allokering  
dead  X    Y  
  0  414 418  
  1  139 107
```

Hvad kan vi konkludere ud fra det?

Vi har haft gang i en logistisk regression, så det er oplagt at kigge på OR. Men Risk Ratios ville også være korrekt.


Hvad er OR så?

Hvad er et 95% KI på den?

Her bliver vi glade for at vi valgte OR frem for RR, for SE på log-Odds(ratio) er lettere at huske.

$$SE(\log(OR)) = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

Run Code



1



Laparotomi

Tabellen deles nu op efter den opererede patients diagnose (cancer, ja/nej):

```
1 table(dead, Allokering, diagn_cancer)
```

```
, , diagn_cancer = j
```

```
      Allokering  
dead   X     Y  
  0 188 213  
  1 101  74
```


```
, , diagn_cancer = n
```

```
      Allokering  
dead   X     Y  
  0 226 205  
  1  38  33
```

Giver det anledning til at ændre den tidligere konklusion? Begrund med effektestimater og 95% konfidensintervaller.

Samme øvelse som før, men nu med OR hver gruppe.

Run Code



1



Laparotomi - opsamling

OR for cancerpatienterne var

$$OR = (101/188) / (74/213) = 1.546363$$

$$\text{Med s.e. på } \log(OR): \sqrt{1/101 + 1/188 + 1/74 + 1/213} = 0.1828346$$

og

$$KI: \exp(\log(1.546363) + c(-1,1)1.96 \cdot 0.1828346) = [1.080636; 2.212806]$$

Så for cancerpatienter er odds for at dø ved det høje ilt regime ca 55% højere, med et KI som angivet. Signifikant, da 1 ikke er med i KI.

Ikke-cancer patienter havde:

$$OR = (38/226) / (33/205) = 1.044516$$

$$\text{og se på } \log(OR) = \sqrt{1/38 + 1/226 + 1/33 + 1/205} = 0.2567521$$

og derfor:

$$KI: \exp(\log(1.044516) + c(-1,1)1.96 \cdot 0.2567521) = 0.6314854 \text{ } 1.7276943$$

Så odds er 1.04 gange større i det høje ilt-regime for ikke-cancerpatienter. Men det er ikke signifikant - for 1 er indeholdt i KI.

Så ilt-regime har betydning for cancerpatienter, men ikke for ikke-cancerpatienter.



Levertal

583 personer er henvist til undersøgelse pga mistanke om leversygdom De første seks observationer:

```
# A tibble: 6 × 8
  age albumin ratio globulin status idnr sex
  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <chr>
1 65 3.3 0.9 3.67 1 1 F
-0.105
2 62 3.2 0.74 4.32 1 2 M
-0.301
3 62 3.3 0.89 3.71 1 3 M
-0.117
4 58 3.4 1 3.4 1 4 M
0
5 72 2.4 0.4 6 1 5 M
-0.916
6 46 4.4 1.3 3.38 1 6 M
0.262
```

Der defineres en binær variabel AG.positiv som $\text{ratio} < 1.1$ Det giver os denne tabel:

Variable:

idnr: Løbenummer

sex: Køn

age: alder i år

status: leversygdom, 1=ja

albumin: serum albumin g/dL

globulin: serum globulin g/dL

ratio: ratio m. albumin og globulin

l_ratio: $\log(\text{ratio})$ (den naturlige
logaritme)

Undersøg om der er en statistisk
signifikant sammenhæng mellem
AG.positiv og status.



Levertal

Hvordan kan vi gøre det?

Vi bør nok kigge på en χ^2 test, for det har vi ikke gjort andre steder.

En lille komplikation er at vi skal have tal ind i en matrix for at bruge `chisq.test()`

Husker I det med “correct”?

Det var korrektionen vi bruger når vi har små tal i matricen. Den er som default TRUE.

Hvad var små tal?

Det er når vi når ned på 5 eller færre forventede observationer i en eller flere celler i matricen


Har vi det her?

Nej, så vi skal ikke korrigere.

Data var:

```
      status
AG.positiv  0  1
0      66 106
1      99 308
```

▶ Run Code



1



Levertal

Nu udfører vi følgende analyse i R:

```
> model <- glm(status~factor(AG.positiv) +  
factor(sex) + age, binomial)  
> summary(model)
```

Den giver dette resultat:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.446661	0.320769	-1.392	0.16378
factor(AG.positiv)1	0.594643	0.199556	2.980	0.00288**
factor(sex)M	0.407717	0.211941	1.924	0.05439.
age	0.015131	0.005927	2.553	0.01069*

Hvilken analyse er der tale om, og hvad kan vi konkludere på baggrund af det?

Hvilken analyse?

Logistisk regression

Hvordan ser vi det?

glm og “binomial”

Hvad er responsvariabel?

status

Og de forklarende variable?

AG.positiv og sex som forklarende kategoriske variable, age som forklarende kontinuært variabel

Hvad ser vi helt overordnet?

Alder og AG.positiv er signifikante i denne analyse (angiv p-værdier i besvarelsen)

Køn er ikke.

Hvad er der korrigeret for i forhold til tidligere?

Køn og alder.



Levertal

Angiv relevant størrelse der kvantificerer effekten af AG.positiv.

Beregn tilhørende 95% KI.

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.446661	0.320769	-1.392	0.16378
factor(AG.positiv)1	0.594643	0.199556	2.980	0.00288
factor(sex)M	0.407717	0.211941	1.924	0.05439
age	0.015131	0.005927	2.553	0.01069

Hvilken skala er estimerne på?

log-odds

▶ Run Code

1



Hvad så vi?

OR for AG.positiv var 1.81.

Derfor estimerer vi at odds for status 1 (at man er syg) er ?

En faktor 1.8 større for ?

AG.positive patienter

Sammenlignet med?

AG.negative patienter

Et 95% KI var:

[1.225701, 2.679882]

Er det signifikant?

Ja

Hvorfor?

Det indeholder ikke 1.

Det var heldigt, for det fortalte p-værdien også...



Levertal

Prædiker sandsynligheden for at have status 1 (syg) for en AG.positiv kvinde på 50.

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.446661	0.320769	-1.392	0.16378
factor(AG.positiv)1	0.594643	0.199556	2.980	0.00288
factor(sex)M	0.407717	0.211941	1.924	0.05439
age	0.015131	0.005927	2.553	0.01069

Husk vi er stadig på log-odds skala

Hvordan regnede vi om fra odds til sandsynlighed?

$$p = \frac{odds}{1+odds}$$

```
Run Code
1
```



Bilirubin

349 patienter med leversygdom blev randomiseret til behandlingen UDC (176 patienter), eller placebo (173) patienter.

Et udfald, “failure of medical treatment” blev defineret som enten “død” eller “levertransplantation” i en periode på 6 år.

Patienterne blev fulgt fra de blev randomiseret til enten “failure of medical treatment”, eller til der var gået 6 år.

Variable:

Y er udfaldsvariablen (1: “treatment failure”),

R angiver behandling (1 = UDC),

X den standardiserede version af logaritmen af bilirubin (umol/L), målt for hver patient ved starten af studiet

De første 6 observationer.

```
# A tibble: 6 × 3
  Y     R     X
<dbl> <dbl> <dbl>
1     1     1  1.62
2     0     1  1.99
3     0     1 -0.849
4     1     1  1.50
5     0     1  1.34
6     0     1 -0.562
```

```
1 table(Y, R) #giver
```


	R	
Y	0	1
0	118	134
1	55	42



Bilirubin

	R	
Y	0	1
0	118	134
1	55	42

Run Code



1

Baseret på ovenstående tabel ønskes beregnet relativ risiko (med tilhørende 95% KI) til belysning af effekten af behandlingen på det betragtede udfald. Husk at konkludere.

Y var udfaldet (1: failure), R var behandlingen (1: UDC, 0: placebo)

Hvordan beregner vi KI?

Estimat $\pm 1.96 \cdot SE$

Og SE på RR?

$$SE(\log(RR)) = \sqrt{\frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}}$$

Så husk - der arbejdes på log-skala



Bilirubin

Nu udførtes følgende analyse:

```
> model <- glm(Y ~ factor(R) + X, family
="binomial")
> summary(model)
```

Der gav dette output:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3922	0.2088	-6.668	2.60e-11***
factor(R)1	-0.9054	0.2967	-3.052	0.00227**
X	1.2632	0.1571	8.043	8.79e-16***

Hvilken analyse er der tale om?

Det er en logistisk regression

Hvordan ser vi det?

glm, binomial, z-value. Men det skriver vi nok ikke i besvarelsen.

Hvad er variablene?

Y er den afhængige, kategoriske responsvariabel (Treatment failure)

R er den uafhængige, kategoriske variabel, der beskriver behandling vs placebo

X er den uafhængige, kontinuerte variabel - den standardiserede logaritme af bilirubin målingerne

Hvad vil det sige at den er logaritmeret?

Vi har taget logaritmen af bilirubin værdierne

Og at den er standardiseret?

Vi har centreret til middelværdi 0 ved at trække middelværdien fra alle målingerne

Og skaleret til sd = 1 ved at dividere alle målingerne med standardafvigelsen af alle målingerne.

Er der noget signifikant?

Ja, både behandling og X er statistisk signifikante på et 5% niveau. Vi skal nok i en besvarelse huske at nævne p-værdierne.



Bilirubin

Angiv relevante effektestimater baseret på analysen og formuler konklusioner derfra.

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3922	0.2088	-6.668	2.60e-11***
factor(R)1	-0.9054	0.2967	-3.052	0.00227**
X	1.2632	0.1571	8.043	8.79e-16***


Hvilken skala er vi på når vi har en logistisk regression?

log-odds

Hvilke effekter er relevante?

Behandling er. X giver det ikke mening at tolke på. Det er en logaritmeret værdi.

Run Code



1



Hvad så vi så?

Vi fik en estimeret odds(ratio) på behandlingen på 0.404

Er der kontrolleret for noget?

Ja, der er kontrolleret for den forklarende variabel X. Det skal vi nok huske at skrive.

Det tilhørende 95% KI var [0.2260652, 0.7233457]

Og da 1 ikke er indeholdt, er estimatet signifikant

Men det vidste vi allerede fra p-værdien

Hvad svarer $OR = 0.4$ til?

En reduktion i *odds* for treatment failure på ca. 60% ved ?

Behandling sammenlignet med placebo

Når der ?

Kontrolleres for bilirubin.

