

Opgaveløsninger

Normalfordelingen

Et par hurtige øvelser

Hvis vores observationer er normalfordelte med $\mu = 0$ og $\sigma = 1$

Hvor stor en andel af observationerne er mindre end 1 (σ)?

```
pnorm(1)*100
```

```
[1] 84.13447
```

Hvor mange observationer er mindre end -2 (σ)

```
pnorm(-2)*100
```

```
[1] 2.275013
```

hvilken værdi (af) er 15.9% af observationerne mindre (end denne værdi)?

```
qnorm(0.159)
```

```
[1] -0.9985763
```

Øvelse 1

Hvilken andel af observationerne i standardnormalfordelingen er mindre end -3?

```
pnorm(-3)
```

```
[1] 0.001349898
```

Øvelse 2

Hvilken andel af observationerne i standardnormalfordelingen er mindre end 2?

```
pnorm(2)
```

```
[1] 0.9772499
```

Øvelse 3

Hvilken andel af observationerne i standardnormalfordelingen er større end 2?

```
1- pnorm(2)
```

```
[1] 0.02275013
```

Øvelse 4

Hvad er 25% af observationerne mindre end?

```
qnorm(0.25)
```

```
[1] -0.6744898
```

Øvelse 5

Hvad er 40% af observationerne større end?

```
qnorm(1-0.4)
```

```
[1] 0.2533471
```

Øvelse 6

Hvilken andel af observationerne ligger mellem 1 og 1.5?

Hvilken andel ligger under 1.5?

Hvilken andel ligger under 1?

Det er så

```
pnorm(1.5) - pnorm(1)
```

```
[1] 0.09184805
```

Øvelse 7

Hvis vi vil have 47% af observationerne, hvilket interval (centreret om 0) skal vi så have?

Hvor meget ligger så uden for det interval?

53%

Det skal fordeles ligeligt på begge sider, så $53/2=26.5$

```
qnorm(0.265)
```

```
[1] -0.628006
```

Øvelse 8 - og det vigtigste tal I skal kende!

Hvis vi vil have 95% af observationerne, hvilket interval (centreret om 0) skal vi så have?

Hvis intervallet skal indeholde 95% af observationerne - hvor meget ligger så uden for?

$1-0.95 = 0.05$

Det skal fordeles ligeligt på begge sider så $0.05/2 = 0.025$

```
qnorm(0.025)
```

```
[1] -1.959964
```

og

```
qnorm(1-0.025)
```

```
[1] 1.959964
```

Endnu en øvelse

Nappet direkte fra en eksamensopgave

For en population af normalfordelte værdier ved vi at: 40% af værdierne er større end 0.1, og 70% af værdierne er mindre end 1. Hvad er middelværdi og spredning i denne normalfordeling?

Den tager vi på tavlen.

Det er oplyst at $X \sim N(\mu, \sigma^2)$

$$P(X > 0.1) = 0.4 \quad P(X < 0.1) = 1 - 0.4 = 0.6$$

Standardiseret:

$$P(X - \mu < 0.1 - \mu) = 0.6 \quad 0.1 - \mu = \text{qnorm}(0.6) = 0.253$$

Og:

$$P(X < 1) = 0.7$$

Standardiseret:

$$P(X - \mu < 1 - \mu) = 0.7 \quad 1 - \mu = \text{qnorm}(0.7) = 0.524$$

Dermed:

$$0.1 - \mu = 0.253 \quad 0.1 - \mu = 0.253$$

og

$$1 - \mu = 0.524 \quad 1 - \mu = 0.524$$

Træk første ligning fra den anden og isoler μ :

$$(1 - \mu) - (0.1 - \mu) = 0.524 - 0.253 \quad 1 - \mu - 0.1 + \mu = (0.524 - 0.253)$$

$$1 - 0.1 = 0.271 \quad 0.90.271 = 0.271 = 3.32$$

Indsæt i en af ligningerne for at finde μ :

$$1 - \mu = 0.524 \quad 1 - \mu = 0.534 \quad 3.32 \quad 1 - 0.534 \quad 3.32 = -0.77$$

Øvelse

Vi har en normalfordelt population med $\mu = 6.52$. 40% af værdierne er mindre end 0. Hvad er så σ for denne fordeling?

$$X \sim N(6.52, \sigma^2)$$

$$P(X < 0) = 0.4$$

$$\text{Skaler: } P(Z < 0 - 6.52) = 0.4$$

$$0 - 6.52 = \text{qnorm}(0.4) = -0.2533471 \text{ Isolér}$$

Øvelse - Manglende procentil:

En normalfordelt population har middelværdi $\mu = 12.5$ og standardafvigelse $\sigma = 3.2$. Hvor stor en andel af værdierne er mindre end 10?

Med andre ord, hvad er: $P(X < 10)$

Transformer til standardnormalfordelingen: $P(Z < (10 - \mu) / \sigma)$

Indsæt

```
pnorm((10-12.5)/3.2)
```

```
[1] 0.2173277
```

Øvelse - Manglende

I en normalfordelt population er $\mu = 85$ og 25% af værdierne er større end 95. Hvad er σ for denne fordeling?

$$P(x > 95) = 0.25$$

$$P(X < 95) = 1 - 0.25$$

Standardiser

$$P(Z < \frac{95 - \mu}{\sigma}) = 0.75$$

Indsæt og brug qnorm til at komme af med P

$$(95 - 85) / \sigma = \text{qnorm}(0.75)$$

Isoler σ

$$10 / \text{qnorm}(0.75) = \sigma$$

Manglende værdi, kendt procentil:

En normalfordelt variabel har $\mu = 50$ og $\sigma = 8$. For hvilken værdi y er 90% af observationerne $< y$?

$$P(X < y) = 0.9$$

Standardiser

$$P(Z < (y - \mu) / \sigma) = 0.9$$

qnorm of at komme af med P

$$(y - \mu) / \sigma = \text{qnorm}(0.9)$$

$$\text{Indsæt } (y - 50) / 8 = \text{qnorm}(0.9)$$

Isoler y

```
y <- qnorm(0.9)*8+50  
y
```

```
[1] 60.25241
```

Manglende middelværdi (variant 2):

For en normalfordeling gælder at $\sigma = 4.5$ og 75% af værdierne er > 18 . Hvad er μ ?

$$P(X > 18) = 0.75$$

$$P(X < 18) = 1 - 0.75$$

Standardiser

$$P(Z < (18 - \mu) / \sigma) = 0.25$$

Indsæt og brug qnorm til at komme af med P

$$(18 - \mu) / 4.5 = \text{qnorm}(0.25)$$

Isoler

```
mu <- 18 - qnorm(0.25)*4.5  
mu
```

```
[1] 21.0352
```

Manglende interval-grænse En normalfordelt population har $\mu=100$ og $\sigma=15$. Hvis 80% af værdierne ligger mellem 85 og en øvre grænse x , hvad er da denne øvre grænse?

Eller: find y således at: $P(85 < X < y) = 0.8$

TAVLE

Samlet sandsynlighed op til y $P(X < y)$

Fra det skal vi trække den del hvor X er mindre end 85

$P(X < 85)$

Så: $P(X < y) - P(X < 85) = 0.80$

$P(X < 85)$ kan vi beregne

Standardiser

$P(Z < (85 - 100) / 15)$

Indsæt, og brug `pnorm` for at få sandsynligheden

```
pnorm((85-100)/15)
```

```
[1] 0.1586553
```

Så ved vi at $P(X < y) - P(X < 85) = 0.80$

bliver $P(X < y) - 0.1586553 = 0.80$

og derfor at

$P(X < y) = 0.80 + 0.1586553 = 0.9586553$

Standardiser (igen)

$P(X < (y - 100) / 15) = 0.9586553$

Af med P ved hjælp af `qnorm`, og indsæt

$(y-100)/15 = \text{qnorm}(0.9586553)$

Isoler y

$y = 15 * \text{qnorm}(0.9586553) + 100$

Normalområde - en eksamensopgave

“Summariske regnestørrelser” for plasma magnesium er givet. Og vi får lov at antage at det er normalfordelt for de to populationer stikprøverne er trukket:

A tibble: 2 × 4 gruppe Antal Gennemsnit Spredning
1 Diabetikere 227 0.719 0.068
2 Ikke-diabetikere 140 0.81 0.057
Beregn et interval, der indeholder 95% af målingerne for kontrol populationen (ikke-diabetikere).

$$0.81 + c(-1,1) \cdot 0.057$$

HVAD ER DET VI GØR MED $c(-1,1)$

Normalområde

Hvilken andel af målingerne i populationen af diabetikere vil ligge i det interval vi beregnede for ikke-diabetikerne?

Eller for: $X \sim N(0.719, 0.068)$ hvor mange ligger over værdien 0.7. og hvor mange ligger under 0.92?

$$\text{Eller: } P(0.7 < X < 0.92) = P(X < 0.92) - P(X < 0.7)$$

TAVLE!

Diabetikerne havde middel = 0.719 og spredning 0.068

Normaliser

$$P(X < 0.92) - P(X < 0.7)$$

$$P(Z < (0.92 - 0.719)/0.068) - P(Z < (0.7 - 0.719)/0.068)$$

```
pnorm((0.92-0.719)/0.068) - pnorm((0.7-0.719)/0.068)
```

```
[1] 0.6084767
```


Hypotesetests

Vi får oplyst “summeriske regnestørrelser” for plasma magnesium for diabetikere. Vi får lov at antage at plasma magnesium er normalfordelt for de to populationer stikprøverne er trukket fra:

gruppe Antal Gennemsnit Spredning Diabetikere 227 0.719 0.068 Ikke-diabetikere 140 0.810 0.057
Beregnet 95% konfidensinterval (KI) for hver af de to grupper.

Ja, det ligner noget vi har set før. Dengang skulle vi se på det interval der indeholdt 95% af observationer. Nu skal vi estimere to middelværdier.

SÅ NU SKAL VI BRUGE SEM!

$$SEM = \frac{sd}{\sqrt{n}}$$

```
SEM_dia <- 0.068/sqrt(227)
interval_dia <- 0.719 + c(-1,1)*1.96*SEM_dia
interval_dia
```

```
[1] 0.7101539 0.7278461
```

```
SEM_ikke <- 0.057/sqrt(140)
interval_non_dia <- 0.8100 + c(-1,1)*1.96*SEM_ikke
interval_non_dia
```

```
[1] 0.8005579 0.8194421
```

Er der forskel? Ja, for de to intervaller overlapper ikke. Og vigtigere, gennemsnittet for ikke-diabetikere er ikke indeholdt i intervallet for diabetikere, og omvendt.

Det er i hvert fald en konklusion de stiller sig tilfredse med i en modelbesvarelse. Det holder ikke helt (men er nu rigtigt alligevel). Vi kommer til den korrekte måde at teste det på.

Ændring i blodtryk

En gruppe patienter deles op i to, kontrol (318 patienter) og behandling (intervention, 323 patienter). Der måles blodtryk før behandling (baseline), og efter 12 måneders behandling. Forskellen i systolisk blodtryk mellem baseline og efter 12 måneder, oplyses som “diff”. For kontrolgruppen får vi oplyst at forskellen er -16.6 mmHg og spredningen er 19.9

For interventionsgruppen er de tilsvarende tal -19.6 og 17.4

Vi skal nu finde ud af om der er et signifikant fald i blodtrykket for interventionsgruppen.

Det ser jo ud til at det falder. Forskellen er -19.6, men er det signifikant? Kunne det tænkes at den sande middelværdi er 0?

Hvad er konfidensintervallet på forskellen?

For interventionsgruppen (323 patienter) : Fald: -19.6 Spredning: 17.4

```
SEM_intervention <- 17.4/sqrt(323)
```

Interval

```
-19.6 + c(-1,1)*1.96*SEM_intervention
```

```
[1] -21.4976 -17.7024
```

0 er ikke indeholdt. faldet er signifikant på et 5% niveau (95% konfidens).

For kontrollen

```
SEM_kontrol <- 19.9/sqrt(318)
```

Interval

```
-16.6 + c(-1,1)*1.96*SEM_kontrol
```

```
[1] -18.78724 -14.41276
```

Her er 0 heller ikke indeholdt. Faldet er signifikant.

Bredde af konfidensinterval

Vi får oplyst et konfidensinterval for fødselsvægte (g): [3561.5; 3583.4]. Beregnet baseret på 11279 kvinder.

Hvor meget bredere havde konfidensintervallet været, hvis vi kun havde haft data for 200 kvinder?

Hvad er det der styrer bredden? Ja, bredden er fra det nedre til det øvre. sd er ukendt. Men bredden er ækvivalent med kvadratroden af n

Så - bredden er 2 gange $1.96 \cdot \text{SEM}$

Eller ca. $4SEM$. Eller $4sd/\sqrt{11279}$

Nu går vi til 200 kvinder.

Så er bredden ca. $4*sd/\sqrt{200}$

Hvor meget bredere er det sidste end det første? TAVLE

```
sqrt(11279)/sqrt(200)
```

```
[1] 7.50966
```

Blodtrykssænkende

Vi undersøger effekten af et blodtrykssænkende præparat i sammenligning med placebo.

Vi får oplyst regnestørrelser for det systoliske blodtryk i mmHg for de to grupper:

A tibble: 2 × 4 Gruppe n gennemsnit spredning

1 Behandling 82 152.5 18.4

2 Placebo 90 156.5 19.1

Er der en signifikant forskel?

Hvad prøver vi at estimere?

Vi prøver at estimere en forskel Der er to grupper. De er ikke parrede

Hvad er diff?

```
152.5-156.5
```

```
[1] -4
```

hvad er SEM på den ene gruppe?

```
SEM_b <- 18.4/sqrt(82)  
SEM_b
```

```
[1] 2.03194
```

Og på den anden?

```
SEM_p <- 19.1/sqrt(90)
SEM_p
```

```
[1] 2.013317
```

Så den samlede SE er:

```
se_diff <- sqrt(SEM_b^2 + SEM_p^2)
se_diff
```

```
[1] 2.860459
```

Testværiden er så:

```
-4/se_diff
```

```
[1] -1.398377
```

Ikke signifikant.

Hvad med KI?

```
-4 + c(-1,1)*1.96*se_diff
```

```
[1] -9.606499  1.606499
```

Her ser vi også at det ikke er signifikant, da 0 er indeholdt. Det beregnede 95% KI indeholder med 95% sandsynlighed den sande forskel.

Videre - ønsket størrelse af konfidensinterval

TAVLE

Hvis $21.96SE = 8$, skal SE være lig $8/(2 \cdot 1.96)$

$$SE_{diff} = \sqrt{\left(\frac{s_0}{n_0}\right)^2 + \left(\frac{s_1}{n_1}\right)^2}$$

$$SE_{diff} = \sqrt{\left(\frac{s_0}{n_0}\right)^2 + \left(\frac{s_1}{n_1}\right)^2}$$

Indsæt $n_0 = 2n_1$

$$SE_{diff} = \sqrt{\left(\frac{s_0}{2n_1}\right)^2 + \left(\frac{s_1}{n_1}\right)^2}$$

Indsæt resten

$$4/1.96 = \sqrt{\left(\frac{19.1}{2n_1}\right)^2 + \left(\frac{18.4}{n_1}\right)^2}$$

$$(4/1.96)^2 = \frac{19.1^2}{2n_1^2} + \left(\frac{18.4}{n_1}\right)^2$$

$$(4/1.96)^2 = \frac{19.1^2}{4n_1^2} + \frac{18.4^2}{n_1^2}$$

Endnu en eksamensopgave

Antag at fordelingen af hæmoglobin(koncentrationen) i en population er normalfordelt, med $\mu = 13.3$ g/100 ml. Spredning $\sigma = 1.12$ g/100 ml.

Vi udtager stikprøver af størrelsen n . For hver stikprøve beregnes stikprøvegennemsnittet. Disse stikprøvegennemsnit er normalfordelte med middelværdi μ (hvis vi udtager uendeligt mange stikprøver)

Hvad er spredningen i fordelingen af stikprøvegennemsnittene?

Det er SEM. Den beregner vi ved $\frac{\sigma}{\sqrt{n}}$

Hvis vi sætter n til 15, hvilken andel af stikprøverne vil ligge mellem 13.0 og 13.6 g/100ml?

Vi skal ikke bruge sd, det er SEM for det er andelen af stikprøverne!

$$= 13.3$$

$$= 1.12$$

$$P(13.0 < X < 13.6)$$

$$P(X < 13.6) - P(X < 13.0)$$

$$P(Z < (13.6 - 13.3)/SEM) - P(Z < (13 - 13.3)/SEM)$$

$$SEM = 1.12/\sqrt{15}$$

svaret er ca 70%

Resten af opgaven

Hvor stor skal n være hvis 95% af stikprøverne skal have et snit der ligger mellem -0.2 og $+0.2$

$$\mu \pm 1.96SEM$$

$$\text{Så } 1.96SEM = 0.2$$

$$1.96 \cdot \sigma = 0.2 \sqrt{n}$$

Hoppeksamensopgave

Man har undersøgt 249 børn for hvor langt de kan hoppe. Der er følgende variable i datasættet:

idnr: løbenummer for personen gender: Køn, 1 dreng, 2 pige age: barnets alder height: barnets højde i cm cohR: Længde af hop på højre ben (cm) cohL: Længde af hop på venstre ben (cm) diff: forskel på cohR og cohL

Vi får også oplyst de første fire observationer:

A tibble: 4 × 7 idnr gender age height cohR cohL diff

1 1 1 10 148.2 185.9 207.3 -21.4

2 2 2 9 136.2 257.4 223 34.4

3 3 1 9 139.4 203.5 250.3 -46.8

4 4 2 9 137.6 347 388.4 -41.4

Og noget summarisk data: >mean(cohR) 270.441 >mean(cohL) 265.3871 >mean(diff) 5.053815
 >sd(cohR) 74.69524 >sd(cohL) 79.73807 >sd(diff) 37.87201

Er der overordnet forskel på hoppelængde på højre og venstre ben?

Hop videre

$$SEM = sd_diff / \sqrt{n}$$

$$\text{testværdi } 5.05381 / SEM$$

Sidste Hop - for denne gang Gennemsnit og spredning for diff for pigerne beregnes til hhv 12.51 og 36.15

Når Berit hopper 250 cm på højre ben, men kun 200 cm på venstre ben er der så grund til at tro at der er noget galt med hendes venstre ben?

normalområdet er så

$12.51 \pm 1.96 \cdot SE$

for forskellen.

Berits forskel er 50 cm. Det er indenfor normalområde.

Diabetikere - fra et interval til et andet

Vi får oplyst data for 18 tilfældigt valgte insulin-afhængige diabetikere. Data er procent af ideelvægt. 95 betyder at pågældende individ fjer 5% mindre end ideelvægten. 120 beetyder at vedkommende vejer 20% mere end ideelvægten.

```
c(107,119,99,114,120,104,88,114,124,116,101,121,152,100,125,114,95,117) |> sd()
```

```
[1] 14.42447
```

Vi får oplyst at et 90% reference interval kan beregnes til (89.1; 136.5)

a. Beregn et 95% konfidensinterval for den sande middelfrocent af ideelvægt.

Et referenceinterval er centreret om middelværdien. Så middel finder vi ved: $(89.1+136.5)/2 = 112.8$

Så skal vi finde spredningen. Det er et 90% interval. så den kvantil der er brugt er ikke 95% kvantilen (1.96), men 90% kvantilen:

```
qnorm(0.95)
```

```
[1] 1.644854
```

0.95 i stedet for 0.975 fordi der skal være 5% på hver side, ikke 2.5%

Intervallet er $\pm$ på hver side af middelværdien så: $136.5-112.8 = 1.644854 \cdot s \rightarrow s = (136.5-112.8)/1.644854 = 14.4$

Så ved vi hvad standardafvigelsen er på data. Nu skal vi have konfidensintervallet på middelværdien - så vi skal bruge SEM:

$14.4/\sqrt{18} = 3.394113$

Og så finder vi konfidensintervallet ved: $112.8 + c(-1,1)1.9614.4/\sqrt{18}$

Og her er der altså en regnefejl i modelløsningen...

- b. Indeholder det konfidensinterval vi har beregnet 100%? Hvad fortæller svaret på det spørgsmål? Angiv relevant nullhypotese, samt eventuelt relevant estimat.

fra a ser vi at 95% konfidensintervallet ikke indeholder 100 - så vi må afvise nullhypotesen $H_0: \mu = 100$, hvor μ angiver den sande middelfrocent af ideelvægt for populationen af insulin-afhængige diabetikere. Estimatet for μ er 112.8 med et 95% KI på det vi tidligere beregnede.

Danske og polske piger

Histogrammerne

```
library(tidyverse)

set.seed(47)

n <- 100

# højreskæv
right_skew <- rgamma(n, shape = 2, scale = 2)

# venstreskæv (spejlet højreskæv)
left_skew <- max(right_skew) - right_skew

# tilnærmelsesvist normal
normal <- rnorm(n, mean = 10, sd = 2)

# log-transformerede
log_right <- log(right_skew)
log_left <- log(max(left_skew) + 1 - left_skew)

df <- tibble(
  value = c(right_skew, left_skew, normal, log_right, log_left),
  type = rep(
    c(
      "Højreskæv",
      "Venstreskæv",
      "Tilnærmelsesvist normal",
      "Log(højreskæv)",
      "Log(venstreskæv)"
    ),
    each = n
  )
)
```




```

    each = n
  )
)

ggplot(df, aes(x = value)) +
  geom_histogram(bins = 10, fill = "steelblue", color = "white") +
  facet_wrap(~type, scales = "free") +
  theme_minimal()

```



Ud over at vi nok vil blive bedt om at forholde os til hvor gennemsnittene sådan på øjemål ligger, og om der er mere eller mindre spredning i den ene frem for den anden. Så skal vi kunne fortælle at “denne er højreskæv” “denne er venstreskæv” og de log-transformerede data er tilnærmelsesvist normalfordelte.

Danske og polske piger

Vi skal se på data fra en undersøgelse af D-vitaminniveauet for danske og polske piger.

Vi får følgende log-transformerede data oplyst:

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61 Beregn variationen på gennemsnittene (SEM) for det log-transformerede D-vitaminniveau for hhv de danske og

polske piger. Vi får, om logtransformerede data oplyst; Danske piger: $\log(\text{D-vitaminniveau})$
gennemsnit: 3.211 sd = 0.492 n = 59

Polske piger: $\log(\text{D-vitaminniveau})$ gennemsnit: 3.389 sd = 0.418 n = 61

Beregn variationen på gennemsnittene for det log-transformerede D-vitaminniveau for hhv de danske og polske piger.

Danske: $0.495/\sqrt{59}$ polske: $0.418/\sqrt{61}$

Danske og polske piger

Beregn 95% KI for de danske og polske piger separat. Hvordan fortolker vi resultaterne? Kan vi konkludere noget om forskellen i D-vitaminniveau mellem de danske og polske piger? Er den signifikant?

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61 Givet

$SEM = s/\sqrt{n}$

Hvordan beregner vi så et 95% KI?

- c) Beregn 95% KI for de danske og polske piger separat. Hvordan fortolker vi resultaterne? Kan vi konkludere noget om forskellen i D-vitaminniveau mellem de danske og polske piger? Er den signifikant?

danske:

```
3.211 + c(-1,1)*1.96*0.495/sqrt(59)
```

```
[1] 3.084691 3.337309
```

```
3.389 + c(-1,1)*1.96*0.418/sqrt(61)
```

```
[1] 3.284102 3.493898
```

Hvert KI indeholder med 95% sandsynlighed den sande værdi for den log-transformerede D-vitaminkoncentration for de to grupper. Intervallerne overlapper, men ingen af de to gennemsnit ligger i det andet KI, og vi kan derfor ikke konkludere om der er en signifikant forskel.

Danske og polske piger

Udregn teststørrelsen for den approksimative t-test for sammenligning af log(D-vitaminniveua). Brug de beregnede variationer på gennemsnittene. Brug teststørrelsen til at konkludere om forskellen på D-vitaminniveauet er statistisk signifikant på et 5% niveau.

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61

forskel:

```
diff <- 3.21-3.389
```

samlet SEM

```
SEM_samlet <- sqrt((0.495/sqrt(59))^2 + (0.418/sqrt(61))^2)
```

Testværdien:

```
diff/SEM_samlet
```

```
[1] -2.136821
```

Testværdien er større end 1.96 (i absolutte værdier). Og forskellen er derfor signifikant.

p-værdi:

```
2*pt(diff/SEM_samlet, 59+61)
```

```
[1] 0.03464261
```

Og der skal ganges med to...

Danske og polske piger

Vi får nu at vide at vi kan beskrive $\log(\text{D-vitaminniveau})$ i begge lande ved en normalfordeling. Beregn et 95% reference interval for $\log(\text{D-vit})$ for danske piger.

Hvordan beregner vi referenceintervallet?

± 1.96

Skal vi bruge SEM?

Nej, for nu antager vi at tallene er normalfordelte.

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61

Det danske referenceinterval:

```
3.211+c(-1,1)*1.96*0.492
```

```
[1] 2.24668 4.17532
```

Danske og polske piger

TAVLE Brug derefter `og` for de polske piger til at beregne hvor stor en andel af dem der forventes at ligge inden for det danske referenceinterval.

Hvis referenceintervallet for de danske piger er [nedre, øvre], hvordan finder vi andelen af polske piger der ligger inden for det?

Hvis X er normalfordelt med middelværdi 3.389 og spredning 0.418, skal vi beregne: $P(2.24668 < X < 4.17532) \Leftrightarrow P(X < 4.17532) - P(X < 2.24668)$

Vi kan bruge `pnorm` direkte (cowboytricket)

```
pnorm(4.17532, 3.389, 0.418) - pnorm(2.24668, 3.389, 0.418)
```

```
[1] 0.9668844
```

Eller vi kan standardisere så vi kan bruge standardnormalfordelingen.

Kategorisk

En opgave

Vi skal se på prævalensen af tuberkulose blandt stiknarkomaner og om den er afhængig af om der deles sprøjter med andre narkomaner. I en gruppe med 97 narkomaner der deler sprøjte med andre narkomaner, testede 24.7% positiv for TB. I en gruppe på 161 narkomaner der ikke delte sprøjte, testede 17.4% positive for TB.

Hvis vi antager at prævalensen ikke afhænger af om der deles sprøjter - hvad estimerer vi så prævalensen til at være?

ja så er det alle tb positive divideret med alle.

Antal positive:

$$0.247 \cdot 97 + 0.174 \cdot 161$$

$$[1] \quad 51.973$$

vi regner med 52...

Og hvor mange var der ialt? $161 + 97$

Så andelen er

$$52/258$$

$$[1] \quad 0.2015504$$

Hvor sikker var vi?

Hvad er et 95% KI for prævalensen af TB blandt stiknarkomaner, hvis vi antager at den ikke afhænger af om man deler sprøjte eller ej?

Proportionen beregnede vi til 0.2015504

Standardfejlen er givet ved:

$$SE_{prop} = \sqrt{\frac{p(1-p)}{n}}$$

Der var 258 observationer i stikprøven

estimat ± 1.96 SE

```
prop <- 0.2015504
se_prop <- sqrt((prop*(1-prop)/285))
se_prop
```

```
[1] 0.02376256
```

```
prop + c(-1,1)*1.96*se_prop
```

```
[1] 0.1549758 0.2481250
```

Så kan vi regne

Prævalens af TB blandt de 97 der delte sprøjter: 24.7% Prævalens af TB blandt de 161 der ikke delte sprøjter: 17.4%

```
SE_deler <- sqrt(0.247*(1-0.247)/97)
SE_deler_ikke <- sqrt(0.174*(1-0.174)/161)
SE_diff <- sqrt(SE_deler^2 + SE_deler_ikke^2)
dif <- 0.247-0.174
test <- dif/SE_diff
test
```

```
[1] 1.377082
```

Modelbesvarelsen bytter om på 161 og 97 i beregningen af SE, og giver derfor en forkert testværdi. Men dog samme konklusion.

Ved et 5% signifikansniveau (kritisk værdi 1.96) er testværdien 1.38 mindre end den kritiske værdi. Vi kan derfor *ikke* forkaste nullhypotesen, $H_0 : p_{deler} - p_{deler_{ikke}} = 0$ og konkluderer at der i data ikke er evidens for den alternative hypotese, at der skulle være forskel i prævalens for de to grupper.

Forholdet mellem de to prævalenser RR

og så er vi ca. klar til at regne

Hvordan finder vi tabellen?

```
0.247*97
```

```
[1] 23.959
```

```
97-0.247*97
```

```
[1] 73.041
```

```
0.174*161
```

```
[1] 28.014
```

```
161-0.174*161
```

```
[1] 132.986
```

Konklusionen bliver den samme uanset om vi dividerer den ene risiko med den anden eller omvendt. Men tolkningen af resultatet vil være forskellig.

```
SE_log_rr <- sqrt(1/24 - 1/(24+73) + 1/28 - 1/(28+133))
risk_deler <- 24/(24+73)
risk_deler_ikke <- 28/(28+133)
rr <- risk_deler/risk_deler_ikke
testværdi <- log(rr)/SE_log_rr
ki_log <- log(rr) + c(-1,1)*1.96*SE_log_rr
ki <- exp(ki_log)
```

Vi estimerer at RR er 1.42, hvilket svarer til at de der deler sprøjter har ca. 42% højere risiko for TB end de der ikke deler sprøjter. Vi finder et 95% konfidens interval til [0.8772285, 2.3072887]. Da 1 er indeholdt i intervallet, kan vi ikke afvise H_0 på et 5% signifikansniveau. Null-hypotesen var $H_0 : RR = 1$. Alternativt finder vi testværdien til at være ca 1.43 hvilket er mindre end den kritiske værdi 1.96 ved et 5% signifikansniveau. Vi kan derfor ikke forkaste H_0 , og må også på denne baggrund konkludere at der ikke i data er evidens for forskel i prævalensen for TB mellem de to grupper.

Odds-ratio

```

odds_deler <- 24/73
odds_deler_ikke <- 28/133
OR <- odds_deler/odds_deler_ikke
SE_log_OR <- sqrt(1/24 + 1/73 + 1/28 + 1/133)
test_værdi <- log(OR)/SE_log_OR
KI_log_OR <- log(OR) + c(-1,1)*1.96*SE_log_OR
KI_OR <- exp(KI_log_OR)

```

χ^2

```

tab <- matrix(
  c(24, 73,
    28, 133),
  nrow = 2,
  byrow = TRUE
)

dimnames(tab) <- list(
  Exposure = c("Deler", "Deler_ikke"),
  TB = c("Ja", "Nej")
)

chisq.test(tab, correct = FALSE)

```

Pearson's Chi-squared test

```

data:  tab
X-squared = 2.0325, df = 1, p-value = 0.154

```

p-værdien er 0.154. p-værdien er sandsynligheden for at

For tidlig fødsel

Et studie i England undersøgte faktorer for tidlig fødsel blandt gravide kvinder og fandt at incidensen for tidlig fødsel var 7.5% blandt de 1513 kvinder der var med i studiet.

Beregn 95% KI for insidensen for tidlig fødsel baseret på disse tal. $\text{phat}(E) = 0.075$. $\text{se}(\text{phate}) = \sqrt{p(1-p)/n} = \sqrt{0.075(1-0.075)/1513}$


```
se_gb <- sqrt(0.075*(1-0.075)/1513)
se_gb
```

```
[1] 0.006771456
```

Der er et 0 for lidt i modelbesvarelsen...

```
0.075+c(-1,1)*1.96*sqrt(0.075*(1-0.075)/1513)
```

```
[1] 0.06172795 0.08827205
```

For tidlig fødsel

- b) Et tilsvarende studie i Danmark fandt en incidens på 4.5% blandt 51851 kvinder der deltog. Estimer forskellen i incidensen for tidlig fødsel i England vs Danmark. Er der signifikant forskel?

forskel:

```
diff <- 0.075-0.045
diff
```

```
[1] 0.03
```

se_dk:

```
se_dk <- sqrt(0.045*(1-0.045)/51851)
```

```
se_diff <- sqrt(se_dk^2 + se_gb^2)
se_diff
```

```
[1] 0.006832381
```

et 95% ki for diffen:

```
diff + c(-1,1)*1.96*se_diff
```

```
[1] 0.01660853 0.04339147
```

Intervaller indeholder *ikke* 0, og vi kan konkludere at der er en statistisk signifikant forskel.

Lineær regression

Blodtryk i Ghana

Vi skal se på blodtryksmålinger fra 641 forsøgspersoner i Ghana. Det er et interventionsstudie, der skulle undersøge om en ny behandling kunne sænke blodtrykket for patienter med ukontrolleret hypertension. Der er to behandlingsgrupper: control og treatment. Begge grupper har fået standard behandling med primærpleje, medicinsk konsultation, test og medicin. treatmentgruppen har dertil fået en personligt tilpasset behandling af sygeplejersker med speciale i hypertensionsbehandling. Behandlingen blev randomiseret, og vi har blodtryksmålinger fra baseline (før behandling) og efter 12 måneder. Vi kender patienternes køn. Der var 323 individer i treatment gruppen.

Data har følgende variable:

SBPbl: systolisk blodtryk ved baseline (mmHg) SBP12: systolisk blodtryk efter 12 måneder
group (control/treatment) sex (male/female) diff: differensen mellem SBP12 og SBPbl

Gennemsnit og spredning for diff i kontrolgruppen er -16.6 hhv 19.9 De tilsvarende tal i interventionsgruppen er -19.6 og 17.4

- a) Er der et signifikant fald i blodtrykket i interventionsgruppen i den undersøgte periode.
Besvar samme spørgsmål for kontrolgruppen.

Vi starter med SEM for de to grupper:

Intervention: $n = 323$

```
SEM_intervention <- 17.4/sqrt(323)
```

```
SEM_kontrol <- 19.9/sqrt(641-323)
```

Så kan vi beregne 95% KI beregnes for de to grupper:

intervention:

```
-19.6+c(-1,1)*1.96*SEM_intervention
```

```
[1] -21.4976 -17.7024
```

kontrol:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-16.988	1.3556	-12.527	<2e-16***
factor(group[sex=='female'])treatment	-5.915	1.901	-3.112	0.002**

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-15.893	1.594	-9.968	<2e-16***
factor(group[sex=='male'])treatment	1.692	2.264	0.747	0.456

```
-16.6+c(-1,1)*1.96*SEM_kontrol
```

```
[1] -18.78724 -14.41276
```

Ingen af de to KI indeholder 0, så vi kan konkludere at begge behandlinger sænker det systoliske blodtryk signifikant.

- b) Er faldt i blodtryk signifikant forskelligt i de to grupper? hvad kan vi konkludere vedrørende effekten af præcisionsbehandlingen på blodtrykket på baggrund af de beregninger vi har udført indtil videre?

De to KI overlapper, men ingen af dem indeholder gennemsnittet fra det andet KI. så vi kan ikke bruge KI til at konkludere. Vi beregner SEM for differensen:

```
SEM_diff <- sqrt(SEM_intervention^2 + SEM_kontrol^2)
```

Det giver os en teststørrelse på forskellen på de to differenser på:

```
(-19.6- -16.6)/SEM_diff
```

```
[1] -2.030622
```

Som (i absolutte tal) er større end 1.96 - der er en signifikant forskel.

- c) Nu udførtes følgende analyser for mænd og kvinder hver for sig: `> summary(lm(diff[sex=="female"]~factor(group[sex=="female"])))`
- `summary(lm(diff[sex=="male"]~factor(group[sex=="male"])))`

Hvilke analyser er der tale om, og hvad kan vi konkludere på baggrund af disse? Der ønskes en fortolkning af værdierne i "Estimate" søjlerne. Giver det anledning til en anden konklusion end den vi fik lige før?

Der er tale om to multiple lineære regressioner, med diff som kontinuert responsvariabel og group som forklarende, kategorisk (og binær) variabel.

For kvinderne ser vi at blodtrykket i gennemsnit falder med ca 17 mmHg under kontrolbehandling (signifikant, med $p \sim 0$), og yderligere ca 6 mmHg ved præcisionsbehandlingen (signifikant med $p = 0.002$)

For mændene ser vi at blodtrykket i gennemsnit falder med ca. 16 mmHg under kontrolbehandling, men at der ikke er signifikant forskel på effekten af de to behandlinger ($p=0.456$)

Leversygdom

Vi har data fra 583 personer, der er blevet henvist til undersøgelse pga mistanke om leversygdom. De første 6 observationer er:

```
library(tidyverse)
tribble(~age, ~albumin, ~ratio, ~globulin, ~status, ~idnr, ~sex, ~l_ratio,
65, 3.3, 0.90, 3.666667, 1, 1, "F", -0.1053605,
62, 3.2, 0.74, 4.324324, 1, 2, "M", -0.3011051,
62, 3.3, 0.89, 3.707865, 1, 3, "M", -0.1165338,
58, 3.4, 1.00, 3.400000, 1, 4, "M", 0,
72, 2.4, 0.4, 6, 1, 5, "M", -0.9162907,
46, 4.4, 1.3, 3.384615, 1, 6, "M", 0.2623643
)
```

A tibble: 6 x 8

	age	albumin	ratio	globulin	status	idnr	sex	l_ratio
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<chr>	<dbl>
1	65	3.3	0.9	3.67	1	1	F	-0.105
2	62	3.2	0.74	4.32	1	2	M	-0.301
3	62	3.3	0.89	3.71	1	3	M	-0.117
4	58	3.4	1	3.4	1	4	M	0
5	72	2.4	0.4	6	1	5	M	-0.916
6	46	4.4	1.3	3.38	1	6	M	0.262

Variable: idnr: Løbenummer sex: Køn age: alder i år status: leversygdom, 1=ja albumin: serum albumin g/dL globulin: serum globulin g/dL ratio: ratio m. albumin og globulin l_ratio: log(ratio) (den naturlige logaritme)

Vi får denne tabel:

```
status <- c(rep(0, 50 + 117),
            rep(1, 92 + 324))

sex <- c(rep("F", 50), rep("M", 117),
        rep("F", 92), rep("M", 324))
table(status, sex)
```

```
      sex
status F  M
  0    50 117
  1    92 324
```

Og opyst at log-ratio er normalfordelt.

For status = 0 får vi:

	Gennemsnit	Spredning (sd)
l_ratio	-0.011	0.289
age	41.2	17.0

og for status = 1

	Gennemsnit	Spredning (sd)
l_ratio	-0.152	0.358
age	46.2	15.7

a) er der forskel i log-ratio mellem syge og raske, når der ikke tages højde for forskell i alder og køn.

Vi skal bestemme ki for log-ratio mellem syge og raske. Det skal vi bruge SEM til. Raske der er $50+117 = 167$, $SEM = 0.289/\sqrt{167} = 0.02236349$ for syge: $92+324 = 416$, $SEM = 0.358/\sqrt{416} = 0.01755239$

den poolede sem er derfor: $\sqrt{0.02236349^2 + 0.01755239^2} = 0.02842907$

Vi skal se om forskellen er 0. forskellen observerer vi til: $-0.152 - -0.011 = -0.141$ Det giver en teststørrelse på: $-0.141/0.02842907 = -4.96$

det er klart signifikant (den er næsten fem standardafvigelser fra 0). der er en signifikant lavere l_ratio blandt de syge.

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.1730998	0.0488724	3.542	0.000430***
factor(status)1	-0.1196883	0.0310025	-3.861	0.000126***
factor(sex)M	0.0042939	0.0324442	0.132	0.894756
age	-0.0045177	0.0008616	-5.241	2.24e-7***

- b) undersøg om kønsfordelingen er den samme for de syge og de raske. Sandsynligheden for at være kvinde blandt de raske: $p_0 = 50/(50+117) = 0.2994012$ Sandsynligheden for at være kvinde blandt de syge: $p_1 = 92/(92+324) = 0.2211538$

Hvordan beregnes standardfejlen på det?

s.e. for en andel finder vi ved $\sqrt{p(1-p)/n}$

så $se_0 = \sqrt{0.2994012(1-0.2994012)/(50+117)} = 0.03544078$ og $se_1 = \sqrt{0.2211538(1-0.2211538)/(92+324)} = 0.02034822$

Er den sande værdi af forskellen på de to andele (af kvinder i hhv syg og rask-grupperne) i virkeligheden 0?

Vi ved ikke om spredningen er ens i de to grupper. Så vi skal bruge den poolede se.: $se_p = \sqrt{0.03544078^2 + 0.02034822^2} = 0.04086684$

forskellen er: $0.2994012 - 0.2211538 = 0.0782474$

og den ligger så: $0.0782474/0.04086684 = 1.914692$ standardfejl fra 0. Og det er ikke signifikant - fordi det er mindre end 1.96.

- c) Er aldersfordelingen den samme for syge som for raske? Hvordan vil vi undersøge det?

two-sample t-test. så er forskellen på gennemsnitlig alder forskellig fra 0? Her nævnte eksamensspørgsmålet specifikt at man blot skulle forklare hvad man ville gøre - man skulle ikke regne.

- d) Nu laver vi denne analyse i R, hvor vi inddrager alder og køn:

```
> analyse1 <- lm(l_ratio~factor(status)+factor(sex)+age)
```

```
> summary(analyse1)
```

Det gav dette output:

Hvilken analyse er der tale om, og hvad kan vi konkludere på baggrund af den? Fortolk værdier i søjlen "Estimate" svarende til variablene status og age.

Det er en multipel lineær regression med l_ratio som responsvariabel og status, sex og age som forklarende variable. age er kontinuer, status og sex er kategoriske (det ser vi blandt andet af "factor"). Syge har i gennemsnit, alt andet lige, en signifikant lavere l_ratio end raske. Den estimerer vi til at være ca. 0.12 lavere, jsuteret for køn og alder. Den tilhørende p-værdi er

0.0001 og derfor signifikant. Alderseffekten er også signifikant ($p < 0.001$), og `l_ratio` falder, i gennemsnit, med 0.0045 pr år. Justeret for status og køn.

- e) predikter median-ratio for de syge i studiepopulationen med en alder på 50 år, som er kvinder.

middelværdien kan vi beregne ved: $0.1730998 + (-0.1196883 + 50 * -0.0045177) = -0.17$ Vi har fået oplyst at `l_ratio` er normalfordelt. I så fald er median og middel ens, så det er medianen vi har fundet. Der efterspørges ratio, ikke `l_ratio`, så vi skal beregne $\exp(-0.17) = 0.8436648$

- f) Hvordan ville vi undersøge om alder, køn og `l_ratio` er signifikante prædiktorer for sygdomsstatus? Angiv relevant R-kode

Sygdomsstatus er en kategorisk, binær variabel. Så vi ville lave en logistisk regression: `glm(status~age+factor(sex1)+l_ratio, family="binomial")`.

Og så ville vi se om p-værdierne var tilstrækkeligt små til at vi kan konkludere at de er signifikante.

Drenge - hormoner

Vi har undersøgt koncentrationen af et hormon hos ellers sunde og raske drenge. Vi ønsker at undersøge sammenhængen mellem denne koncentration og drengenes alder og BMI.

- a. Hvilken analyse er der udført.

ud fra "`model = lm(osv)`" kan vi se at det er en lineær regression. Den er multipel fordi der er mere end en forklarende variabel. Vi har alder som kategorisk forklarende variabel, og BMI som kontinuert forklarende variabel.

- b. fortolk resultaterne. vi ser at hormonniveauet tilsyneladende stiger med stigende alder (og fastholdt BMI). Eksempelvis er hormonniveauet for alderskategorien (11,12] 1.08688 højere end for referencen (5,8]. Stigningen er statistisk signifikant for næsten alle aldersgrupper. Der er dog en vis variation i hvor meget hormonniveauet stiger med alderen. BMI er også klart signifikant med en middel stigning i hormonniveauet på 0.058 pr BMI-point (ved fastholdt alder)
- c. Prædikter (forudsig) hormonniveauet for en dreng på 6 år med et BMI på 17 og for en dreng på 14 med et BMI på 18.

Det finder vi ved: Den 6-årige: $5.40 + 0.058 * 17$

for den 14-årige $5.40 + 0.229 + 0.058 * 18$

transplanteret lungevolumen

Vi ser på data for lungetransplanterede patienter. Man har været nødt til at bruge ældre donorer, der også kan have været rygere. Vi har observationer for 426 patienter.

De første 6 observationer er givet:

```
tribble(~fevl_prior_to_tx, ~fevl_after, ~fevl_diff, ~SMOKE,  
1.40, 3.8, 2.4, "Never smoker",  
0.56, 0.95, 0.39, "Smoker or former smoker",  
0.37, 1.25, 0.88, "Smoker or former smoker",  
0.54, 2.35, 1.81, "Smoker or former smoker",  
0.71, 1.60, 0.89, "Never smoker",  
1.78, 2.08, 0.30, "Never smoker")
```

```
# A tibble: 6 x 4  
  fevl_prior_to_tx fevl_after fevl_diff SMOKE  
      <dbl>      <dbl>    <dbl> <chr>  
1         1.4         3.8        2.4 Never smoker  
2         0.56        0.95        0.39 Smoker or former smoker  
3         0.37        1.25        0.88 Smoker or former smoker  
4         0.54        2.35        1.81 Smoker or former smoker  
5         0.71         1.6         0.89 Never smoker  
6         1.78        2.08         0.3 Never smoker
```

fevl_prior_to_tx: fevl målt før transplantation fevl_after: fevl målet efter transplantation
fevl_diff: differencen mellem fevl_after og fevl_prior_to_tx SMOKE: Rygstatus for donor.

Vi får oplyst følgende:

	mean	sd
fevl_prior_to_tx	0.835086	0.5365149
fevl_after	2.122762	0.9459951
fevl_diff	1.279024	0.9411598

Undersøg ved brug af relevant statistik metode om patienternes lungefunktion (fevl) har ændret sig efter transplantationen.

Det er en parret t-test (for vi har målinger på samme patient både før og efter)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.36970	0.06646	20.61	<2e-16***
factor(SMOKE)Smoker or former smoker	-0.19092	0.09644	-1.98	0.0485*

```
1.279024/(0.9411598/sqrt(426))
```

```
[1] 28.04918
```

Det er større end 1.96, så statistisk signifikant (nogen føler trang til at sige “klart signifikant”)

b) Nu udførtes følgende analyse: `> model <- lm(fevl_diff~factor(SMOKE))` `> summary(model)`

Hvilken analyse er der tale om, og hvad kan vi konkludere på baggrund af denne?

Det er en multipel lineær regression med en forklarende kategorisk (og binær) variabel; SMOKE. Responsvariabel er fevl_diff. Ændringen i lungefunktion efter transplantationen er afhængig af om donor var ryger eller ikke-ryger. Det estimeres at lungefunktionen er lavere hvis donor var ryger - denne forskel er statistisk signifikant med $p = 0.0485$.

c) Fortolk værdierne i søjlen “Estimate”. Beregn tilhørende 95% KI

Intercept er den estimerede ændring i lungefunktion (før vs efter transplantation) for patienter med en donor som var ikke-ryger. Den estimerede ændring er i gennemsnit 1.3697, med et 95% KI på:

```
1.36970 + c(-1,1)*1.96*0.06646
```

```
[1] 1.239438 1.499962
```

Forbedringen i lungefunktion er lidt mindre for patienter med en donor som var ryger (eller ex-ryger). Forbedringen estimeres til i gennemsnit at være 0.19092 laverem, med det tilhørende 95% KI på:

```
-0.19092+c(-1,1)*1.96*0.09644
```

```
[1] -0.3799424 -0.0018976
```

Logistisk

Levertal

583 personer er henvist til undersøgelse pga mistanke om leversygdom De første seks observationer:

```
library(tidyverse)
tribble(~age, ~albumin, ~ratio, ~globulin, ~status, ~idnr, ~sex, ~l_ratio,
65, 3.3, 0.90, 3.666667, 1, 1, "F", -0.1053605,
62, 3.2, 0.74, 4.324324, 1, 2, "M", -0.3011051,
62, 3.3, 0.89, 3.707865, 1, 3, "M", -0.1165338,
58, 3.4, 1.00, 3.400000, 1, 4, "M", 0,
72, 2.4, 0.4, 6, 1, 5, "M", -0.9162907,
46, 4.4, 1.3, 3.384615, 1, 6, "M", 0.2623643
)
```

A tibble: 6 x 8

	age	albumin	ratio	globulin	status	idnr	sex	l_ratio
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<chr>	<dbl>
1	65	3.3	0.9	3.67	1	1	F	-0.105
2	62	3.2	0.74	4.32	1	2	M	-0.301
3	62	3.3	0.89	3.71	1	3	M	-0.117
4	58	3.4	1	3.4	1	4	M	0
5	72	2.4	0.4	6	1	5	M	-0.916
6	46	4.4	1.3	3.38	1	6	M	0.262

Variable: idnr: Løbenummer sex: Køn age: alder i år status: leversygdom, 1=ja albumin: serum albumin g/dL globulin: serum globulin g/dL ratio: ratio m. albumin og globulin l_ratio: log(ratio) (den naturlige logaritme)

Der defineres en binær variabel AG.positiv som $\text{ratio} < 1.1$ Det giver os denne tabel:

```
status <- c(rep(0, 99 + 66),
            rep(1, 308 + 106))

AG.positiv <- c(rep(1, 99), rep(0, 66),
               rep(1, 308), rep(0, 106))
table(AG.positiv, status)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.446661	0.320769	-1.392	0.16378
factor(AG.postiv)1	0.594643	0.199556	2.980	0.00288**
factor(sex)M	0.407717	0.211941	1.924	0.05439.
age	0.015131	0.005927	2.553	0.01069*

```

      status
AG.postiv  0   1
      0  66 106
      1  99 308

```

a) Undesøg om der er en statistisk signifikant sammenhæng mellem de to variable.

Her kører vi en χ^2 test:

input:

```

input <- matrix(c(66,106,99,308), ncol = 2, byrow = TRUE)
chisq.test(input, correct = FALSE)

```

Pearson's Chi-squared test

```

data:  input
X-squared = 11.709, df = 1, p-value = 0.0006219

```

Det giver en teststørrelse på 11.7. Vi sætter `correct = FALSE` fordi de forventede værdier i tabellen er “store”, som i større end 5.

Det svarer til en p-værdi der er < 0.001 . Så der er signifikant forskel. modelbesvarlsær bruger ofte formuleringen “klart signifikant”. teknisk set er der ikke noget der er mere signifikant end andet. det er signifikant på et bestemt niveau. Eller også er det ikke. Det er ikke “næsten” eller “meget” signifikant.

b) Nu udfører vi følgende analyse i R: `> model <- glm(status~factor(AG.postiv)+factor(sex)+age, binomial)` `> summary(model)`

Den giver dette resultat:

Hvilken analyse er der tale om, og hvad kan vi konkludere på baggrund af det? Angiv relevant størrelse der kvantificerer effekten af AG.postiv. beregn tilhørende 95% KI.

Det er en logistisk regression med status som responsvariabel og AG.positiv og køn som kategoriske forklarende variable, og alder som kontinuær forklarende variabel. Alder og AG.positiv er signifikante i denne justerede analyse, kønnet er ikke.

OR for AG.positiv $\exp(0.594643) = 1.812384$ og vi estimerer derfor at odds for at status er 1 (at man er syg) er en faktor 1.8 større hvis AG.positive patienter, sammenlignet med AG.negative. KI: $\exp(0.594643 + c(-1,1)1.960.199556)$ Da det ikke indeholder 1, er resultatet signifikant (i overensstemmelse med hvad vi så fra p-værdien)

c) Prædikter sandsynligheden for at have status 1 (syg) for en AG.positiv kvinde på 50.

Vi beregner: $-0.446661 + 0.594643 + 50 \cdot 0.015131 = 0.904532$

Det er logodds. Så vi finder sandsynligheden ved: odds er så: $\exp(0.904532) = 2.470775$ Og sandsynligheden finder vi ved: $\text{odds}/(1+\text{odds}) = 2.470775/(1+2.470775) = 0.7118799$

Bilirubin

Vi skal se på et randomiseret klinisk studie udført på seks forskellige europæiske hospitaler. 349 patienter med leversygdom blev randomiseret til enten den eksperimentelle behandling UDC (176 patienter) eller placebo (173 patienter)

Udfaldet “failure of medical treatment” blev defineret som enten død eller levertransplantation i den 6 årige undersøgelsesperiode. Patienter blev fulgt fra randomiseringstidspunktet til ovenstående udfald - eller til de 6 år var gået.

Vi får de første 6 observationer i sættet. Y er udfaldsvariablen (1 “treatment failure”), R angiver behandling (1 = UDC), X den standardiserede version af logaritmen af bilirubin (umol/L), målt for hver patient ved starten af studiet

```
library(tidyverse)
tribble(~Y, ~R, ~X,
1, 1, 1.616854293,
0, 1, 1.990367802,
0, 1, -0.849360224,
1, 1, 1.496709981,
0, 1, 1.335441834,
0, 1, -0.561678151)
```

```
# A tibble: 6 x 3
      Y     R     X
  <dbl> <dbl> <dbl>
1     1     1  1.62
2     0     1  1.99
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3922	0.2088	-6.668	2.60e-11***
factor(R)1	-0.9054	0.2967	-3.052	0.00227**
X	1.2632	0.1571	8.043	8.79e-16***

```

3      0      1 -0.849
4      1      1  1.50
5      0      1  1.34
6      0      1 -0.562

```

table(Y,R) giver:

```

      R
Y      0      1
0 118 134
1  55  42

```

- a) baseret på ovenstående table ønske beregnet relativ risiko (med tilhørende 95% KI) til belysning af effekten af behandlingen på det betragtede udfald. Husk at konkludere.

Risiko ved behandling: $42/(134+42) = 0.2386364$

Risiko ved placebo: $55/(118+55) = 0.3179191$

$RR = 0.2386364/0.3179191 = 0.7506199$

$\log(RR) = \log(0.7506199) = -0.2868559$

$se.(\log(rr)) = \sqrt{1/42-1/176+1/55-1/173} = 0.174726$

et 95% ki for $\log(rr)$ findes til: $-0.2868559 + c(-1,1)1.960.174726 = -0.62931886 \ 0.05560706$

Derfor er 95% ki for RR: $\exp(c(-0.62931886, 0.05560706)) = 0.5329547 \ 1.0571822$

RR er 0.75. Så vi estimerer at behandlingen reducerer treatment failure med 25% med et 95% KI på 0.5329547 1.0571822 Da 1 er indeholdt i KI er der dermed ikke tale om en signifikant effekt.

- b) Nu udførtes følgende analyse:

```
> model <- glm(Y ~ factor(R) + X, family = "binomial")
summary(model)
```

der gav dette output:

Hvilken analyse er der tale om. Angiv relevante effektestimater baseret på analysen og formuler konklusioner derfra.

Der er tale om en logistisk regressions analyse, med Y (Treatment failure) som afhængig variabel, og behandling/randomisering som kategorisk uafhængig, forklarende variable, samt X (den standardiserede logartime af bilirubin) som kontinuært forklarende variabel. Såvel behandlingen som X er statistisk signifikante på et 5% niveua.

For den forklarende variabel X får vi en estimeret odds ratio (OR) på behandlingen på $\exp(-0.9054) = 0.4043801$ når der kontrolleres for den forklarende variabel X.

Det tilhørende 95% konfidensinterval findes ved: $\exp(-0.9054 + c(-1,1)1.960.2967)$

OR på 0.4 svarer til en reduktion i odds for treatment failure på ca 60%, ved aktiv behandling vs. placebo, når der kontrolleres for bilirubin. Da KI ikke indeholder 1, er effekten signifikant.

Laparotomi

Vi ser på data fra ca 1000 patienters risiko for at dø ved en operation (laparotomi). Har øget ilt-tilførsel under operationen betydning for død i en opfølgingsperiode på ca. 3 år. Patienterne blev randomiseret til et af to ilt-regimer

Vi har følgende variable Allokering: X - patient fik 80% ilt, Y Patient fik 30% ilt diagn_cancer: j: cancer, n: ikke cancer blod: j perioperativ blodtransfusion, n ikke perioperativ blodtransfusion bmi: patientens BMI dead: 1 patienten dør i løbet af opfølgingsperioden, 0 patienten overlever

De første 6 observationer:

```
head(ilt_data)
```

```
# A tibble: 6 x 5
  Allokering diagn_cancer blod    bmi  dead
  <chr>      <chr>      <chr> <dbl> <dbl>
1 Y         n          n    29.3     0
2 X         n          n    28.1     0
3 X         j          n    21.5     1
4 X         j          n    17.3     1
5 Y         n          n    24.2     0
6 Y         n          n    18.2     0
```

- Hvis vi alene betragter patienternes bmi, hvordan ville vi så undersøge om den har signifikant betydning for risikoen for død efter operation. Outcome - dead er binær og bmi er kontinuært. Så vi vil modellere et kategorisk outcome med kontinært forklarende variabel: logistisk regression
- Når vi gør det, får vi følgende resultat (de fortsætter deres juleleg med at fjerne dele af output):

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.007041	0.386263	-0.018	0.98546
bmi		0.015385	-3.151	

Hvad kan vi sige ud fra det?

Vi mangler et estimat for bmi. Det kan vi beregne, fordi z-value finder vi ved at dividere estimatet med standardfejlen. Derfor kan vi finde estimatet ved at gange standardfejl med z value.

```
-3.151*0.015385
```

```
[1] -0.04847813
```

Teststørrelsen er klart signifikant

```
2*pnorm(-3.151)
```

```
[1] 0.001627125
```

Vi kan beregne OR:

```
exp(-0.04847813)
```

```
[1] 0.9526782
```

Så holdes alt andet konstant, vil en patient med et bmi der er 1 større end en anden patient, have vil odds for død reduceres med ca 5% for patienten med det højeste bmi.

Vi kan beregne et 95% KI:

```
exp(-0.04847813 + c(-1,1)*1.96*0.015385)
```

```
[1] 0.9243794 0.9818433
```

1 er ikke indeholdt i intervallet, og forskellen er derfor signifikant. Det så vi også fra p-værdien vi beregnede tidligere.

c) Nu ser vi bort fra bmi, og betragter ilt-allokering.

```
table(dead,Allokering)
```

```
      Allokering
dead  X    Y
  0 414 418
  1 139 107
```

Hvad kan vi konkludere ud fra det?

Vi sammenligner død (1) for de to ilt-regimer X og Y: $\text{odds}_X = 139/414 = 0.3357488$ $P_Y = 107/418 = 0.2559809$

OR (X mod Y) = $0.3357488/0.2559809 = 1.311617$ dvs at odds for at dø estimeres at være ca. 31% højere ved det høje ilt-regime, sammenlignet med det lave (alt andet fastholdt)

95% KI: standardfejlen på log(OR): $\sqrt{1/139 + 1/414 + 1/107 + 1/418} = 0.146109$

$\exp(\log(1.311617) + c(-1,1)1.960.146109)$

Det indeholder 1 og estimatet er derfor ikke statistisk signifikant (de er dog i modelbesvarelser glade for at nævne at det er tæt på at være signifikant)

BETON FORSKEL PÅ OR OG RR!

d) Tabellen deles nu op efter den opererede patients diagnose (cancer, ja,nej):

```
table(dead, Allokering, diagn_cancer)
```

```
, , diagn_cancer = j
```

```
      Allokering
dead  X    Y
  0 188 213
  1 101  74
```

```
, , diagn_cancer = n
```

```
      Allokering
dead  X    Y
  0 226 205
  1  38  33
```


Giver det anledning til at ændre den tidligere konklusion? Begnd med effektestimater og 95% konfidensintervaller.

Samme øvelse som før, men nu på hver gruppe: Cancerpatienter: $OR = (101/188) / (74/213) = 1.546363$ s.e. på $\log(OR)$: $\sqrt{1/101 + 1/188 + 1/74 + 1/213} = 0.1828346$ KI: $\exp(\log(1.546363) + c(-1,1)1.960.1828346) = 1.080636 \text{ } 2.212806$

Så for cancerpatienter er odds for at dø ved det høje ilt regime ca 55% højere, med et KI som angivet. Signifikant, da 1 ikke er med i KI.

non-cancer-patienter:

$OR = (38/226) / (33/205) = 1.044516$ se på $\log(OR) = \sqrt{1/38 + 1/226 + 1/33 + 1/205} = 0.2567521$ KI: $\exp(\log(1.044516) + c(-1,1)1.96 \cdot 0.2567521) = 0.6314854 \text{ } 1.7276943$ Så odds er 1.04 gange større i det høje ilt-regime for ikke-cancerpatienter. Men det er ikke signifikant - for 1 er indeholdt i KI.

Så ilt-regime har betydning for cancerpatienter.

Glykæmisk kontrol

Vi skal undersøge om type 2 diabetes patienter med bedre glykæmisk kontrol, har et bedre selvvurderet helbred.

Vi har følgende variable

HBA1C_dik: 1 hvis HbAlc < 9%, 0 hvis HbAlc >= 9% (note til ikke-medicineren. 1 er godt helbred) SRH_dik: 1 hvis selvvurderet helbred er godt/meget godt. 0 hvis det er nogenlunde/dårligt/meget dårligt AGE: Alder i år SEX: Køn. 0: Kvinde, 1: Mand

Vi gør i R følgende og får: `>table(SRH_dik, HBA1C_dik)`

	HBA1C_dik	
SRH_dik	0	1
0	412	264
1	354	188

a) Baseret på den tabel - er der sammenhæng mellem de to variable?

Hvad er den relative risiko for at have godt helbred hvis HbAlc er 1 - altså velreguleret.

Den relative risiko finder vi ved: $(188/(188+264))/(354/(354+412)) = 0.900005$ pas på paranteserne!

Der er dermed reduceret sandsynlighed for godt selvvurderet helbred hvis man er velreguleret. Er det statistisk signifikant?

Det kræver vi har s.e. for rr $\sqrt{1/188 - 1/(188+264) + 1/354 - 1/(354+412))} = 0.0680157$

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.717969	0.350389	2.049	0.04046*
factor(HbA1C_dik)1	-0.188731	0.120637	-1.564	0.11771
factor(SEX)1	0.252051	0.117514	2.145	0.03196*
AGE	-0.015573	0.005099	-3.054	0.00226**

deter standardfejlen på log RR $\exp(\log(0.900005) + c(-1,1)1.960.0680157)$ Da det omfatter 1, er den reducerede sandsynlighed ikke signifikant.

Man kan også bruge χ^2

b) Nu udfører vi denne analyse i R: `>model1 <- glm(SRH_dik ~ factor(HbA1C_dik)+ factor(SEX) + Age, family = "binomial") >summary(model1)`

Hvad har vi gjort, og hvordan fortolker vi resultaterne?

Vi har gennemført en logistisk regression, med tre forklarende variable, AGE som kontinuert og HbA1C_dik og SEX som kategoriske variabel. Vi ser at HbA1C ikke er signifikant. Både køn og alder er signifikante med tilhørende Odds-ratio på $\exp(0.252051) = 1.28$ for køn, med et 95%KI på $\exp(0.252051 + c(-1,1)1.960.117514)$ Mandlige diabetikere har derfor 28% større odds for godt helbred (selvrapporteret) sammenlignet med kvindelige diabetikere, og et KI på med alder og HbA1C fastholdt.

Alder er også statistisk signifikant med odds ratio på $\exp(-0.015573) = 0.9845476$ diabetikere har derfor ~1.2% reduceret odds for godt helbred (med fastholdt køn og HbA1C) ved en 1 års øgning i alder. KI:

$\exp(-0.015573 + c(-1,1)1.960.005099)$

Hvis vi ønsker hvad det er for eg 5 år, skal der ganges med 5 på både estimatet og standardfejlen

opgave

1473 børn i Guinea-Bissau blev undersøgt for at finde ud af om der, ud over gavnlige effekt af vaccination mod specifikke sygdomme, også var en generelt reduceret børne-dødelighed.

Børnene blev besøgt to gange i deres hjem. Første gang tidligt efter fødslen hvor der blev vaccineret. anden gang ca. 6 måneder senere, hvor der blev fulgt op. En del, men ikke alle børn blev vaccineret med DTP (difteri, tetanus og pertussis).

Variablene i datasættet oplyses at være: alder - alder ved vaccinationen - i år status - status ved opfølgning. 1: død, 0: i live dtp: blev barnet vaccineret. 1: ja, 0: nej vægt: barnets vægt ved vaccination (i kg) etniskgr: etnisk gruppe 0: Manjaco, Fula, 1: Mandinga og anden

Vi får også oplyst de seks første observationer i datasættet:

```
tribble(~alder, ~status, ~dtp, ~etngr, ~vaegt,  
0.592, 0, 1, 1, 5.6,  
0.425, 1, 1, 1, 6.0,  
0.510, 0, 1, 1, 6.2,  
0.592, 0, 1, 1, 6.2,  
0.173, 0, 0, 1, 5.6,  
0.173, 0, 0, 1, 5.2)
```

```
# A tibble: 6 x 5  
  alder status dtp etngr vaegt  
  <dbl> <dbl> <dbl> <dbl> <dbl>  
1 0.592     0     1     1  5.6  
2 0.425     1     1     1  6.0  
3 0.51      0     1     1  6.2  
4 0.592     0     1     1  6.2  
5 0.173     0     0     1  5.6  
6 0.173     0     0     1  5.2
```

Og optælling: `< table(dtp,status)`

status dtp 0 1 0 526 9 1 892 46

- a) Ser det umiddelbart ud til at der er en sammenhæng mellem dødeligheden og vaccinstatus?

Vi har tælledata. Hvad er sandsynligheden for død ved dtp lig 0 og 1?

$p_0 = 9/(526+9) = 1.7\%$ $p_1 = 46/(46+892) = 4.9\%$

Den relative risiko: $RR_{1:0} = 4.9/1.7 = 2.88$.

3 gange så høj risiko for død

Hvad er det tilhørende 95% konfidens interval?

$\text{Log}(RR) = 1.06$, standardfejlen på $\log(rr) = \sqrt{1/9 + 1/46 - 1/(526+9) - 1/(46+892)}$

DETTE UDLØSER ET HELT NYT SÆT SLIDES og modelløsnignen har tastefejl... $\exp(1.06 + c(-1,1)1.960.36)$. Under alle omstændigheder - 1 - som ville være at der ikke var forskel, er ikke indeholdt. for H_0 er at $RR = 1$

- b) Hvordan vil vi undersøge sammenhængen mellem dødeligheden og vaccinstatus?, hvor der justeres for de øvre variable?

Det er et binært udfald. Så en logistisk regression. Det gør vi i glm, med family binomial
`glm(status~vaegt + alder + factor(dtp) + factor(etngr), family = "binomial")`

Den korrekte analyse gav nedenstående resultat:

```
tribble(~Coefficients, ~Estimate, ~`Std. Error`, ~`t value`, ~`Pr(>|t|)` ,
"(Intercept)", 0.05666, 0.02866, 1.98, "0.048 *",
"factor(dtp)1", 0.02609, 0.01162, 2.25, "0.025 *",
"factor(etngr)1", 0.02294, 0.01033, 2.22, "0.027 *",
"alder", 0.05845, 0.03897, 1.50, "0.134",
"vaegt", -0.01140, 0.00527, -2.16, "0.031 *")
```

A tibble: 5 x 5

Coefficients	Estimate	Std. Error	t value	Pr(> t)
<chr>	<dbl>	<dbl>	<dbl>	<chr>
1 (Intercept)	0.0567	0.0287	1.98	0.048 *
2 factor(dtp)1	0.0261	0.0116	2.25	0.025 *
3 factor(etngr)1	0.0229	0.0103	2.22	0.027 *
4 alder	0.0584	0.0390	1.5	0.134
5 vaegt	-0.0114	0.00527	-2.16	0.031 *

Fortolk resultatet. Er der sammenhæng mellem vaccinstatus og dødeligheden? Giv et relevant effektmål med tilhørende 95% konfidensinterval

dtp er signifikant, også efter der justeres for etnicitet, alder og vægt, med $p = 0.025$

OR estimeres til $\exp(0.026) = 1.026$ med et 95% konfidensinterval på: $\exp(0.026 + c(-1,1)1.960.012)$

Vaccinerede har ca. 2.6% højere odds for død end ikke-vaccinerede

Rygende donorer

Hvad kan vi konkludere på baggrund af den analyse. Beregn relevante odds ratios (OR), beregn også de tilhørende 95% konfidensintervaller

Begge de forklarende variable er signifikante.

SMOKE har en OR på $\exp(0.5751) = 1.777308$ det tilhørende konfidensinterval finder vi ved: $\exp(0.575 + c(-1,1)1.960.21)$

dvs 1.77 gange højere odds for at dø inden for 3 år efter transplantation sammen lignet med ikkeryger donor (og fastholdt donoralder). KI indeholder ikke 1, og det er signifikant.

donoralder. Her har vi to. $OR_{40-55} = \exp(0.444) = 1.55893$ og KI: $\exp(0.444 + c(-1,1)1.960.2527) = 0.9500012 \text{ } 2.5581696$

og $OR_{56} = \exp(0.9395) = 2.558702$ og KI: $\exp(0.9395 + c(-1,1)1.960.2891) = 1.451887 \text{ } 4.509273$

Dvs 1.55 gange højere odds for at dø indenfor 3 år efter transplantation for en patient med en donor der var 40-55 sammenlignet med en donor der var under 40. Ved fastholdt rygestatus for donor. KI indeholder 1, og er derfor ikke signifikant.

og 2.56 gange højere odds for at dø indenfor 3 år efter transplantation for en patient med en donor der var over 56, sammenlignet med en donor der var under 40. Ved fastholdt rygestatus for donor. KI indeholder ikke 1, og er derfor signifikant.

Endelig blev følgende regnestykke foretaget:

```
exp(-1.2848)/(1+exp(-1.2848))
```

[1] 0.2167343

Hvordan fortolker vi det tal?

-1.2848 er estimatet på intercept.

Det var for referencegruppen. Den patientgruppe der har fået lunger fra en donor under 40 år, der var ikke ryger.

Hvad er det så vi beregner?

$\exp(-1.2848)$ går fra

Log Odds(ratio) til:

Odds

Og brøken giver?

Den går fra odds til sandsynlighed - så vi får?

Den estimerede sandsynlighed for at dø inden for 3 år, for den patientgruppe der fik lunger fra en donor under 40, der var ikke-ryger.