

Opgaveløsninger

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.0      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.2      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.1
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

Hypotesetests

Opgave

Vi får oplyst data for 18 tilfældigt valgte insulin-afhængige diabetikere. Data er procent af ideelvægt. 95 betyder at pågældende individ fjer 5% mindre end ideelvægten. 120 beetyder at vedkommende vejer 20% mere end ideelvægten.

```
c(107,119,99,114,120,104,88,114,124,116,101,121,152,100,125,114,95,117) |> sd()
```

```
[1] 14.42447
```

Vi får oplyst at et 90% reference interval kan beregnes til (89.1; 136.5)

- Beregn et 95% konfidensinterval for den sande middelpcent af ideelvægt.

Et referenceinterval er centreret om middelværdien. Så middel finder vi ved: $(89.1+136.5)/2 = 112.8$

Så skal vi finde spredningen. Det er et 90% interval. så den kvantil der er brugt er ikke 95% kvantilen (1.96), men 90% kvantilen:

```
qnorm(0.95)
```

```
[1] 1.644854
```

0.95 i stedet for 0.975 fordi der skal være 5% på hver side, ikke 2.5%

Intervallet er +/- på hver side af middelværdien så: $136.5-112.8 = 1.644854*s \rightarrow s = (136.5-112.8)/1.644854 = 14.4$

Så ved vi hvad standardafvigelsen er på data. Nu skal vi have konfidensintervallet på middelværdien - så vi skal bruge SEM:

$14.4/\sqrt{18} = 3.394113$

Og så finder vi konfidensintervallet ved: $112.8 + c(-1,1)1.9614.4/\sqrt{18}$

Og her er der altså en regnefejl i modelløsningen...

- b. Indeholder det konfidensinterval vi har beregnet 100%? Hvad fortæller svaret på det spørgsmål? Angiv relevant nullhypotese, samt eventuelt relevant estimat.

fra a ser vi at 95% konfidensintervallet ikke indeholder 100 - så vi må afvise nullhypotesen H_0 : $\mu = 100$, hvor μ angiver den sande middelfrocent af ideelvægt for populationen af insulin-afhængige diabetikere. Estimatet for μ er 112.8 med et 95% KI på det vi tidligere beregnede.

Kategorisk

eksamensopgave

Et studie i England undersøgte faktorer for tidlig fødsel blandt gravide kvinder og fandt at incidensen for tidlig fødsel var 7.5% blandt de 1513 kvinder der var med i studiet.

- a) Beregn 95% KI for insidensen for tidlig fødsel baseret på disse tal. $\text{phat}(E) = 0.075$.
 $\text{se}(\text{phate}) = \sqrt{p(1-p)/n} = \sqrt{0.075(1-0.075)/1513}$

```
se_gb <- sqrt(0.075*(1-0.075)/1513)
se_gb
```

```
[1] 0.006771456
```

Der er et 0 for lidt i modelbesvarelsen...

```
0.075+c(-1,1)*1.96*sqrt(0.075*(1-0.075)/1513)
```

```
[1] 0.06172795 0.08827205
```

- b) Et tilsvarende studie i Danmark fandt en incidens på 4.5% blandt 51851 kvinder der deltog. Estimer forskellen i incidensen for tidlig fødsel i England vs Danmark. Er der signifikant forskel?

forskel:

```
diff <- 0.075-0.045  
diff
```

```
[1] 0.03
```

se_dk:

```
se_dk <- sqrt(0.045*(1-0.045)/51851)
```

```
se_diff <- sqrt(se_dk^2 + se_gb^2)  
se_diff
```

```
[1] 0.006832381
```

et 95% ki for diffen:

```
diff + c(-1,1)*1.96*se_diff
```

```
[1] 0.01660853 0.04339147
```

Intervaller indeholder *ikke* 0, og vi kan konkludere at der er en statistisk signifikant forskel.

Lineær regression

Drenge - hormoner

Vi har undersøgt koncentrationen af et hormon hos ellers sunde og raske drenge. Vi ønsker at undersøge sammenhængen mellem denne koncentration og drengenes alder og BMI.

a. Hvilken analyse er der udført.

ud fra “model = lm(osv)” kan vi se at det er en lineær regression. Den er multipel fordi der er mere end en forklarende variabel. Vi har alder som kategorisk forklarende variabel, og BMI som kontinuert forklarende variabel.

b. fortolk resultaterne. vi ser at hormonniveauet tilsyneladende stiger med stigende alder (og fastholdt BMI). Eksempelvis er hormonniveauet for alderskategorien (11,12] 1.08688 højere end for referencen (5,8]. Stigningen er statistisk signifikant for næsten alle aldersgrupper. Der er dog en vis variation i hvor meget hormonniveauet stiger med alderen. BMI er også klart signifikant med en middel stigning i hormonniveauet på 0.058 pr BMI-point (ved fastholdt alder)

c. Prædikter (forudsig) hormonniveauet for en dreng på 6 år med et BMI på 17 og for en dreng på 14 med et BMI på 18.

Det finder vi ved: Den 6-årige: $5.40 + 0.058 \cdot 17$

for den 14-årige $5.40 + 0.229 + 0.058 \cdot 18$

transplanteret lungevolumen

Vi ser på data for lungetransplanterede patienter. Man har været nødt til at bruge ældre donorer, der også kan have været rygere. Vi har observationer for 426 patienter.

De første 6 observationer er givet:

```
tribble(~fevl_prior_to_tx, ~fevl_after, ~fevl_diff, ~SMOKE,
1.40, 3.8, 2.4, "Never smoker",
0.56, 0.95, 0.39, "Smoker or former smoker",
0.37, 1.25, 0.88, "Smoker or former smoker",
0.54, 2.35, 1.81, "Smoker or former smoker",
0.71, 1.60, 0.89, "Never smoker",
1.78, 2.08, 0.30, "Never smoker")
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.36970	0.06646	20.61	<2e-16***
factor(SMOKE)Smoker or former smoker	-0.19092	0.09644	-1.98	0.0485*

```
# A tibble: 6 x 4
  fevl_prior_to_tx fevl_after fevl_diff SMOKE
      <dbl>         <dbl>    <dbl> <chr>
1         1.4         3.8      2.4 Never smoker
2         0.56        0.95     0.39 Smoker or former smoker
3         0.37        1.25     0.88 Smoker or former smoker
4         0.54        2.35     1.81 Smoker or former smoker
5         0.71        1.6      0.89 Never smoker
6         1.78        2.08     0.3  Never smoker
```

fevl_prior_to_tx: fevl målt før transplantation fevl_after: fevl målet efter transplantation
fevl_diff: differencen mellem fevl_after og fevl_prior_to_tx SMOKE: Rygstatus for donor.

Vi får oplyst følgende:

	mean	sd
fevl_prior_to_tx	0.835086	0.5365149
fevl_after	2.122762	0.9459951
fevl_diff	1.279024	0.9411598

Undersøg ved brug af relevant statistik metode om patienternes lungefunktion (fevl) har ændret sig efter transplantationen.

Det er en parret t-test (for vi har målinger på samme patient både før og efter)

```
1.279024/(0.9411598/sqrt(426))
```

```
[1] 28.04918
```

Det er større end 1.96, så statistisk signifikant (nogen føler trang til at sige “klart signifikant”)

b) Nu udførtes følgende analyse: `> model <- lm(fevl_diff~factor(SMOKE)) > summary(model)`

Hvilken analyse er der tale om, og hvad kan vi konkludere på baggrund af denne?

Det er en multipel lineær regression med en forklarende kategorisk (og binær) variabel; SMOKE. Responsvariabel er fevl_diff. Ændringen i lungefunktion efter transplantationen er afhængig af om donor var ryger eller ikke-ryger. Det estimeres at lungefunktionen er lavere hvis donor var ryger - denne forskel er statistisk signifikant med $p = 0.0485$.

c) Fortolk værdierne i søjlen "Estimate". Beregn tilhørende 95% KI

Intercept er den estimerede ændring i lungefunktion (før vs efter transplantation) for patienter med en donor som var ikke-ryger. Den estimerede ændring er i gennemsnit 1.3697, med et 95% KI på:

```
1.36970 + c(-1,1)*1.96*0.06646
```

```
[1] 1.239438 1.499962
```

Forbedringen i lungefunktion er lidt mindre for patienter med en donor som var ryger (eller ex-ryger). Forbedringen estimeres til i gennemsnit at være 0.19092 laverem, med det tilhørende 95% KI på:

```
-0.19092+c(-1,1)*1.96*0.09644
```

```
[1] -0.3799424 -0.0018976
```

Logistisk

Rygende donorer

Hvad kan vi konkludere på baggrund af den analyse. Beregn relevante odds ratios (OR), beregn også de tilhørende 95% konfidensintervaller

Begge de forklarende variable er signifikante.

SMOKE har en OR på $\exp(0.5751) = 1.777308$ det tilhørende konfidensinterval finder vi ved: $\exp(0.575 + c(-1,1)1.960.21)$

dvs 1.77 gange højere odds for at dø inden for 3 år efter transplatation sammen lignet med ikkeryger donor (og fastholdt donoralder). KI indeholder ikke 1, og det er signifikant.

donoralder. Her har vi to. $OR_{40-55} = \exp(0.444) = 1.55893$ og KI: $\exp(0.444 + c(-1,1)1.960.2527) = 0.9500012 \ 2.5581696$

og $OR_{56} = \exp(0.9395) = 2.558702$ og KI: $\exp(0.9395 + c(-1,1)1.960.2891) = 1.451887$
4.509273

Dvs 1.55 gange højere odds for at dø indenfor 3 år efter transplantation for en patient med en donor der var 40-55 sammenlignet med en donor der var under 40. Ved fastholdt rygestatus for donor. KI indeholder 1, og er derfor ikke signifikant.

og 2.56 gange højere odds for at dø indenfor 3 år efter transplantation for en patient med en donor der var over 56, sammenlignet med en donor der var under 40. Ved fastholdt rygestatus for donor. KI indeholder ikke 1, og er derfor signifikant.

Endelig blev følgende regnestykke foretaget:

```
exp(-1.2848)/(1+exp(-1.2848))
```

[1] 0.2167343

Hvordan fortolker vi det tal?

-1.2848 er estimatet på intercept.

Det var for referencegruppen. Den patientgruppe der har fået lunger fra en donor under 40 år, der var ikke ryger.

Hvad er det så vi beregner?

$\exp(-1.2848)$ går fra

Log Odds(ratio) til:

Odds

Og brøken giver?

Den går fra odds til sandsynlighed - så vi får?

Den estimerede sandsynlighed for at dø inden for 3 år, for den patientgruppe der fik lunger fra en donor under 40, der var ikke-ryger.