Opgaveløsninger

Normalfordelingen

Et par hurtige øvelser

Hvis vores observationer er normalfordelte med $\mu = 0$ og $\sigma = 1$

Hvor stor en andel af observationerne er mindre end 1 (σ)?

```
pnorm(1)*100
```

```
[1] 84.13447
```

Hvor mange observationer er mindre end -2 (σ)

```
pnorm(-2)*100
```

```
[1] 2.275013
```

hvilken værdi (af) er 15.9% af observationerne mindre (end denne værdi)?

```
qnorm(0.159)
```

```
[1] -0.9985763
```

Øvelse 1

Hvilken andel af observationerne i standardnormalfordelingen er mindre end -3?

```r
pnorm(-3)
```

```
[1] 0.001349898
```

Øvelse 2

Hvilken andel af observationerne i standardnormalfordelingen er mindre end 2?

```r
pnorm(2)
```

```
[1] 0.9772499
```

Øvelse 3

Hvilken andel af observationerne i standardnormalfordelingen er større end 2?

```r
1- pnorm(2)
```

```
[1] 0.02275013
```

Øvelse 4

Hvad er 25% af observationerne mindre end?

```r
qnorm(0.25)
```

```
[1] -0.6744898
```

Øvelse 5

Hvad er 40% af observationerne større end?

```r
qnorm(1-0.4)
```

```
[1] 0.2533471
```

Øvelse 6

Hvilken andel af observationerne ligger mellem 1 og 1.5?

Hvilken andel ligger under 1.5?

Hvilken andel ligger under 1?

Det er så

```
pnorm(1.5) - pnorm(1)
```

```
[1] 0.09184805
```

Øvelse 7

Hvis vi vil have 47% af observationerne, hvilket interval (centreret om 0) skal vi så have?

Hvor meget ligger så uden for det interval?

53%

Det skal fordeles ligeligt på begge sider, så 53/2=26.5

```
qnorm(0.265)
```

```
[1] -0.628006
```

Øvelse 8 - og det vigtigste tal I skal kende!

Hvis vi vil have 95% af observationerne, hvilket interval (centreret om 0) skal vi så have?

Hvis intervallet skal indeholde 95% af observationerne - hvor meget ligger så uden for?

1-0.95 = 0.05

Det skal fordeles ligeligt på begge sider så 0.05/2 = 0.025

```
qnorm(0.025)
```

```
[1] -1.959964
```

og

```r
qnorm(1-0.025)
```

```
[1] 1.959964
```

Endnu en øvelse

Nappet direkte fra en eksamensopgave

For en population af normalfordelte værdier ved vi at: 40% af værdierne er større end 0.1, og 70% af værdierne er mindre end 1. Hvad er middelværdi og spredning i denne normalfordeling?

Den tager vi på tavlen.

Det er oplyst at X N(,)

P(X>0.1)=0.4 P(X<0.1)=1−0.4=0.6

Standardiseret:

P(X− <0.1−)=0.6 0.1− =qnorm(0.6)=0.253

Og:

P(X<1)=0.7

Standardiseret:

P(X− <1−)=0.7 1− =qnorm(0.7)=0.524

Dermed:

0.1− =0.253 0.1− =0.253

og

1− =0.524 1− =0.524

Træk første ligning fra den anden og isoler :

(1−)−(0.1−)=0.524 −0.253 1− −0.1+ =(0.524−0.253)

1−0.1=0.271 0.90.271= =3.32

Indsæt i en af ligningerne for at finde :

1− =0.524 1− =0.534 3.32 1−0.534 3.32= =−0.77

Øvelse

Vi har en normalfordelt population med =6.52 . 40% af værdierne er mindre end 0. Hvad er så for denne fordeling?

X N(,6.52)

P(X<0) = 0.4

Skaler: P(Z<0− 6.52)=0.4

0−μ/6.52=qnorm(0.4)=−0.2533471 Isoler μ

Øvelse - Manglende procentil:

En normalfordelt population har middelværdi μ=12.5 og standardafvigelse σ=3.2 . Hvor stor en andel af værdierne er mindre end 10?

Med andre ord, hvad er: P(X<10)

Transformer til standardnormalfordelingen: P(Z<(10−μ)/σ)

Indsæt

```
pnorm((10-12.5)/3.2)
```

```
[1] 0.2173277
```

Øvelse - Manglende

I en normalfordelt population er μ=85 og 25% af værdierne er større end 95. Hvad er for denne fordeling?

P(x > 95) = 0.25

P(X < 95) = 1-0.25

Standardiser

$P(Z < \frac{95-\mu}{\sigma}) = 0.75$

Indsæt og brug qnorm til at komme af med P

$(95 - 85)/\sigma = qnorm(0.75)$

Isoler σ

$10/qnorm(0.75) = \sigma$

Manglende værdi, kendt procentil:

En normalfordelt variabel har =50 og =8 . For hvilken værdi y er 90% af observationerne < y?

P(X < y) = 0.9

Standardiser

P(Z < (y-)/) = 0.9

qnorm of at komme af med P

(y-)/ = qnorm(0.9)

Indsæt (y-50)/8 = qnorm(0.9)

Isoler y

```
y <- qnorm(0.9)*8+50
y
```

```
[1] 60.25241
```

Manglende middelværdi (variant 2):

For en normalfordeling gælder at =4.5 og 75% af værdierne er > 18. Hvad er ?

P(X > 18) = 0.75

P(X < 18) = 1- 0.75

Standardiser

P(Z < (18-)/) = 0.25

Indsæt og brug qnorm til at komme af med P

(18-)/4.5 = qnorm(0.25)

Isoler

```
mu <- 18-  qnorm(0.25)*4.5
mu
```

```
[1] 21.0352
```

Manglende interval-grænse En normalfordelt population har =100 og =15 . Hvis 80% af værdierne ligger mellem 85 og en øvre grænse x , hvad er da denne øvre grænse?

Eller: find y således at: P(85 < X < y) = 0.8

TAVLE

Samlet sandsynlighed op til y P(X < y)

Fra det skal vi trække den del hvor X er mindre end 85

P(X < 85)

Så: P(X < y) - P(X < 85) = 0.80

P(X < 85) kan vi beregne

Standardiser

P(Z < (85-)/))

Indsæt, og brug pnorm for at få sandsynligheden

```
pnorm((85-100)/15)
```

```
[1] 0.1586553
```

Så ved vi at P(X < y) - P(X < 85) = 0.80

bliver P(X < y) - 0.1586553 = 0.80

og derfor at

P(X < y) = 0.80 + 0.1586553 = 0.9586553

Standardiser (igen)

P(X < (y-)) = 0.9586553

Af med P ved hjælp af qnorm, og indsæt

(y-100)/15 = qnorm(0.9586553)

Isoler y

y = 15*qnorm(0.9586553) +100

Normalområde - en eksamensopgave

"Summariske regnestørrelser" for plasma magnesium er givet. Og vi får lov at antage at det er normalfordelt for de to populationer stikprøverne er trukket:

A tibble: 2 × 4 gruppe Antal Gennemsnit Spredning 1 Diabetikere 227 0.719 0.068 2 Ikke-diabetikere 140 0.81 0.057 Beregn et interval, der indeholder 95% af målingerne for kontrol populationen (ikke-diabetikere).

0.81 + c(-1,1)*0.057

HVAD ER DET VI GØR MED c(-1,1)

Normalområde

Hvilken andel af målingerne i populationen af diabetikere vil ligge i det interval vi beregnede for ikke-diabetikerne?

Eller for: X ~ N(0.719, 0.068) hvor mange ligger over værdien 0.7. og hvor mange ligger under 0.92?

Eller: P(0.7 < X < 0.92) = P(X < 0.92) - P(X < 0.7)

TAVLE!

Diabetikerne havde middel = 0.719 og spredning 0.068

Normaliser

P(X < 0.92) - P(X < 0.7)

P(Z < (0.92-0.719)/0.068) - P(Z < (0.7-0.719)/0.068)

```
pnorm((0.92-0.719)/0.068) - pnorm((0.7-0.719)/0.068)
```

```
[1] 0.6084767
```

Hypotesetests

Vi får oplyst "summariske regnestørrelser" for plasma magnesium for diabetikere. Vi får lov at antage at plasma magnesium er normalfordelt for de to populationer stikprøverne er trukket fra:

gruppe Antal Gennemsnit Spredning Diabetikere 227 0.719 0.068 Ikke-diabetikere 140 0.810 0.057 Beregn 95% konfidensinterval (KI) for hver af de to grupper.

Ja, det ligner noget vi har set før. Dengang skulle vi se på det interval der indeholdt 95% af observationer. Nu skal vi estimere to middelværdier.

SÅ NU SKAL VI BRUGE SEM!

$SEM = \frac{sd}{\sqrt{n}}$

```
SEM_dia <- 0.068/sqrt(227)
interval_dia <- 0.719 + c(-1,1)*1.96*SEM_dia
interval_dia
```

```
[1] 0.7101539 0.7278461
```

```
SEM_ikke <- 0.057/sqrt(140)
interval_non_dia <- 0.8100 + c(-1,1)*1.96*SEM_ikke
interval_non_dia
```

```
[1] 0.8005579 0.8194421
```

Er der forskel? Ja, for de to intervaller overlapper ikke. Og vigtigere, gennemsnittet for ikke-diabetikere er ikke indeholdt i intervallet for diabetikere, og omvendt.

Det er i hvert fald en konklusion de stiller sig tilfredse med i en modelbesvarelse. Det holder ikke helt (men er nu rigtigt alligevel). Vi kommer til den korrekte måde at teste det på.

Ændring i blodtryk

En gruppe patienter deles op i to, kontrol (318 patienter) og behandling (intervention, 323 patienter). Der måles blodtryk før behandling (baseline), og efter 12 måneders behandling. Forskellen i systolisk blodtryk mellem baseline og efter 12 måneder, oplyses som "diff". For kontrolgruppen får vi oplyst at forskellen er -16.6 mmHg og spredningen er 19.9

For interventionsgruppen er de tilsvarende tal -19.6 og 17.4

Vi skal nu finde ud af om der er et signifikant fald i blodtrykket for interventionsgruppen.

Det ser jo ud til at det falder. Forskellen er -19.6, men er det signifikant? Kunne det tænkes at den sande middelværdi er 0?

Hvad er konfidensintervallet på forskellen?

For interventionsgruppen (323 patienter) : Fald: -19.6 Spredning: 17.4

```
SEM_intervention <- 17.4/sqrt(323)
```

Interval

```
-19.6 + c(-1,1)*1.96*SEM_intervention
```

```
[1] -21.4976 -17.7024
```

0 er ikke indeholdt. faldet er signifikant på et 5% niveau (95% konfidens).

For kontrollen

```
SEM_kontrol <- 19.9/sqrt(318)
```

Interval

```
-16.6 + c(-1,1)*1.96*SEM_kontrol
```

```
[1] -18.78724 -14.41276
```

Her er 0 heller ikke indeholdt. Faldet er signifikant.

Bredde af konfidensinterval

Vi får oplyst et konfidensinterval for fødselsvægte (g): [3561.5; 3583.4]. Beregnet baseret på 11279 kvinder.

Hvor meget bredere havde konfidensintervallet været, hvis vi kun havde haft data for 200 kvinder?

Hvad er det der styrer bredden? Ja, bredden er fra det nedre til det øvre. sd er ukendt. Men bredden er ækvivalent med kvadratroden af n

Så - bredden er 2 gange 1.96*SEM

Eller ca. 4*SEM. Eller 4*sd/sqrt(11279)

Nu går vi til 200 kvinder.

Så er bredden ca. 4*sd/sqrt(200)

Hvor meget bredere er det sidste end det første? TAVLE

```
sqrt(11279)/sqrt(200)
```

```
[1] 7.50966
```

Blodtrykssænkende

Vi undersøger effekten af et blodtrykssænkende præparat i sammenligning med placebo.

Vi får oplyst regnestørrelser for det systoliske blodtryk i mmHg for de to grupper:

A tibble: 2 × 4 Gruppe n gennemsnit spredning

1 Behandling 82 152.5 18.4
2 Placebo 90 156.5 19.1
Er der en signifikant forskel?

Hvad prøver vi at estimere?

Vi prøver at estimere en forskel Der er to grupper. De er ikke parrede

Hvad er diff?

```
152.5-156.5
```

```
[1] -4
```

hvad er SEM på den ene gruppe?

```
SEM_b <- 18.4/sqrt(82)
SEM_b
```

```
[1] 2.03194
```

Og på den anden?

```r
SEM_p <- 19.1/sqrt(90)
SEM_p
```

```
[1] 2.013317
```

Så den samlede SE er:

```r
se_diff <- sqrt(SEM_b^2 + SEM_p^2)
se_diff
```

```
[1] 2.860459
```

Testværiden er så:

```r
-4/se_diff
```

```
[1] -1.398377
```

Ikke signifikant.

Hvad med KI?

```r
-4 + c(-1,1)*1.96*se_diff
```

```
[1] -9.606499  1.606499
```

Her ser vi også at det ikke er signifikant, da 0 er indeholdt. Det beregnede 95% KI indeholder med 95% sandsynlighed den sande forskel.

Videre - ønsket størrelse af konfidensinterval

TAVLE

Hvis 2*1.96*SE = 8, skal SE være lig 8/(2*1.96)

$SE_{diff} = \sqrt{(\frac{s_0}{n_0})^2 + (\frac{s_1}{n_1})^2}$

$SE_{diff} = \sqrt{(\frac{s_0}{n_0})^2 + (\frac{s_1}{n_1})^2}$

Indsæt n_0 = 2n_1

$SE_{diff} = \sqrt{(\frac{s_0}{2n_1})^2 + (\frac{s_1}{n_1})^2}$

Indsæt resten

$4/1.96 = \sqrt{(\frac{19.1}{2n_1})^2 + (\frac{18.4}{n_1})^2}$

$(4/1.96)^2 = \frac{19.1}{2n_1})^2 + (\frac{18.4}{n_1})^2$

$(4/1.96)^2 = \frac{19.1^2}{4n_1^2} + \frac{18.4^2}{n_1^2}$

Endnu en eksamensopgave

Antag at fordelingen af hæmoglobin(koncentrationen) i en population er normalfordelt, med μ = 13.3 g/100 ml. Spredning σ = 1.12 g/100 ml.

Vi udtager stikprøver af størrelsen n. For hver stikprøve beregnes stikprøvegennemsnittet. Disse stikprøvegennemsnit er normalfordelte med middelværdi μ (hvis vi udtager uendeligt mange stikprøver)

Hvad er spredningen i fordelingen af stikprøvegennemsnittene?

Det er SEM. Den beregner vi ved $\frac{\sigma}{\sqrt{n}}$

Hvis vi sætter n til 15, hvilken andel af stikprøverne vil ligge mellem 13.0 og 13.6 g/100ml?

Vi skal ikke bruge sd, det er SEM for det er andelen af stikprøverne!

=13.3

=1.12

P(13.0 < X < 13.6)

P(X < 13.6) - P(X< 13.0)

P(Z < (13.6 - 13.3)/SEM) - P(Z < (13-13.3)/SEM)

SEM = 1.12/sqrt(15)

svaret er ca 70%

Resten af opgaven

Hvor stor skal n være hvis 95% af stikprøverne skal have et snit der ligger mellem -0.2 og $+0.2$

$\mu \pm 1.96SEM$

Så $1.96SEM = 0.2$

1.96*sigma = 0.2 sqrt(n)

Hoppeeksamensopgave

Man har undersøgt 249 børn for hvor langt de kan hoppe. Der er følgende variable i datasættet:

idnr: løbenummer for personen gender: Køn, 1 dreng, 2 pige age: barnets alder height: barnets højde i cm cohR: Længde af hop på højre ben (cm) cohL: Længde af hop på venstre ben (cm) diff: forskel på cohR og cohL

Vi får også oplyst de første fire observationer:

A tibble: 4×7 idnr gender age height cohR cohL diff

1 1 1 10 148.2 185.9 207.3 -21.4
2 2 2 9 136.2 257.4 223 34.4
3 3 1 9 139.4 203.5 250.3 -46.8
4 4 2 9 137.6 347 388.4 -41.4
Og noget summarisk data: >mean(cohR) 270.441 >mean(cohL) 265.3871 >mean(diff) 5.053815 >sd(cohR) 74.69524 >sd(cohL) 79.73807 >sd(diff) 37.87201

Er der overordnet forskel på hoppelængde på højre og venstre ben?

Hop videre

SEM = sd_diff/sqrt(n)

testværdi 5.05381/SEM

Sidste Hop - for denne gang Gennemsnit og spredning for diff for pigerne beregnes til hhv 12.51 og 36.15

Når Berit hopper 250 cm på højre ben, men kun 200 cm på venstre ben er der så grund til at tro at der er noget galt med hendes venstre ben?

normalområdet er så

12.51 +/- 1.96*SE

for forskellen.

Berits forfskel er 50 cm. Det er indenfor normalområde.

Diabetikere - fra et interval til et andet

Vi får oplyst data for 18 tilfældigt valgte insulin-afhængige diabetikere. Data er procent af idealvægt. 95 betyder at pågældende individ fjer 5% mindre end idealvægten. 120 beetyder at vedkommende vejer 20% mere end idealvægten.

```
c(107,119,99,114,120,104,88,114,124,116,101,121,152,100,125,114,95,117) |> sd()
```

```
[1] 14.42447
```

Vi får oplyst at et 90% reference interval kan beregnes til (89.1; 136.5)

a. Beregn et 95% konfidensinterval for den sande middelprocent af idealvægt.

Et referenceinterval er centreret om middelværdien. Så middel finder vi ved: (89.1+136.5)/2 = 112.8

Så skal vi finde spredningen. Det er et 90% interval. så den kvantil der er brugt er ikke 95% kvantilen (1.96), men 90% kvantilen:

```
qnorm(0.95)
```

```
[1] 1.644854
```

0.95 i stedet for 0.975 fordi der skal være 5% på hver side, ikke 2.5%

Intervallet er +/- på hver side af middelværdienm så: 136.5-112.8 = 1.644854*s -> s = (136.5-112.8)/1.644854 = 14.4

Så ved vi hvad standardafvigelsen er på data. Nu skal vi have konfidensintervallet på middelværdien - så vi skal bruge SEM:

14.4/sqrt(18) = 3.394113

Og så finder vi konfidensintervallet ved: 112.8 + c(-1,1)*1.96*14.4/sqrt(18)

Og her er der altså en regnefejl i modelløsningen…

b. Indeholder det konfidensinterval vi har beregnet 100%? Hvad fortæller svaret på det spørgsmål? Angiv relevant nullhypotese, samt eventuelt relevant estimat.

fra a ser vi at 95% konfidensintervallet ikke indeholder 100 - så vi må afvise nullhypotesen H_0: mu = 100, hvor mu angiver den sande middelprocent af idealvægt for populationen af insulin-afhængige diabeetikere. Estimatet for mu er 112.8 med et 95% KI på det vi tidligere beregnede.

Danske og polske piger

Histogrammerne

```
library(tidyverse)

set.seed(47)

n <- 100

# højreskæv
right_skew <- rgamma(n, shape = 2, scale = 2)

# venstreskæv (spejlet højreskæv)
left_skew <- max(right_skew) - right_skew

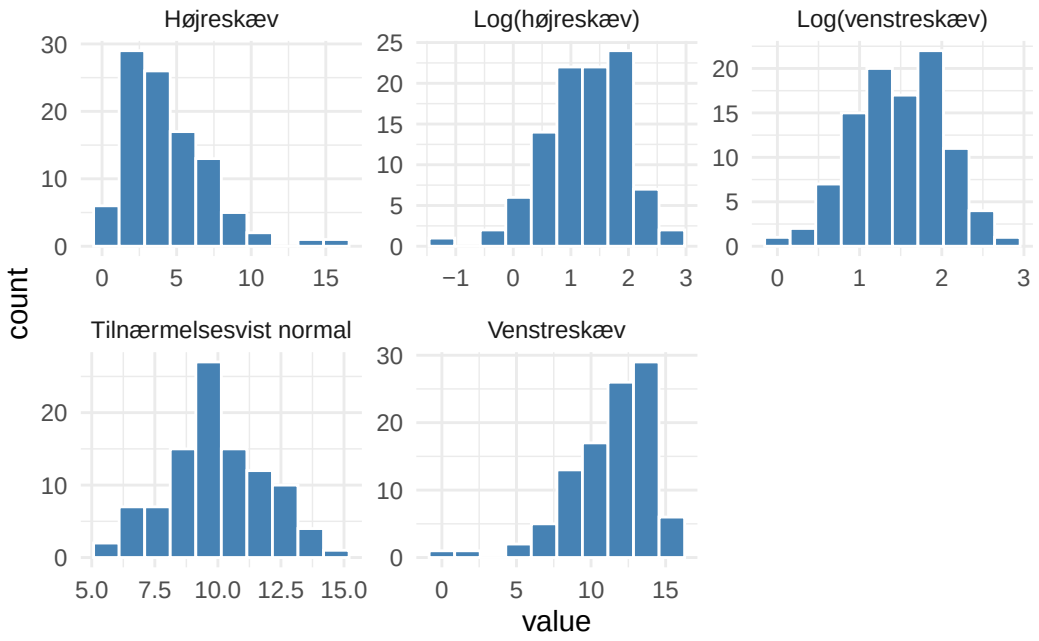
# tilnærmelsesvist normal
normal <- rnorm(n, mean = 10, sd = 2)

# log-transformerede
log_right <- log(right_skew)
log_left  <- log(max(left_skew) + 1 - left_skew)

df <- tibble(
  value = c(right_skew, left_skew, normal, log_right, log_left),
  type = rep(
    c(
      "Højreskæv",
      "Venstreskæv",
      "Tilnærmelsesvist normal",
      "Log(højreskæv)",
      "Log(venstreskæv)"
    ),
```

```
    each = n
  )
)

ggplot(df, aes(x = value)) +
  geom_histogram(bins = 10, fill = "steelblue", color = "white") +
  facet_wrap(~type, scales = "free") +
  theme_minimal()
```



Ud over at vi nok vil blive bedt om at forholde os til hvor gennemsnittene sådan på øjemål ligger, og om der er mere eller mindre spredning i den ene frem for den anden. Så skal vi kunne fortælle at "denne er højreskæv" "denne er venstreskæv" og de log-transformerede data er tilnærmelsesvist normalfordelte.

Danske og polske piger

Vi skal se på data fra en undersøgelse af D-vitaminniveuaet for danske og polske piger.

Vi får følgende log-transformerede data oplyst:

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61 Beregn variationen på gennemsnittene (SEM) for det log-transformerede D-vitaminniveau for hhv de danske og

polske piger. Vi får, om logtransformerede data oplyst; Danske piger: log(D-vitaminniveau) gennemsnit: 3.211 sd = 0.492 n = 59

Polske piger: log(D-vitaminniveau) gennemsnit: 3.389 sd = 0.418 n = 61

Beregn variationen på gennemsnittene for det log-transformerede D-vitaminniveau for hhv de danske og polske piger.

Danske: 0.495/sqrt(59) polske: 0.418/sqrt(61)

Danske og polske piger

Beregn 95% KI for de danske og polske piger separat. Hvordan fortolker vi resultaterne? Kan vi konkludere noget om forskellen i D-viatminniveau mellem de danske og polske piger? Er den signifikant?

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61 Givet

SEM=sdn√

Hvordan beregner vi så et 95% KI?

c) Beregn 95% KI for de danske og polske piger separat. Hvordan fortolker vi resultaterne? Kan vi konkludere noget om forskellen i D-viatminniveau mellem de danske og polske piger? Er den signifikant?

danske:

```
3.211 + c(-1,1)*1.96*0.495/sqrt(59)
```

```
[1] 3.084691 3.337309
```

```
3.389 + c(-1,1)*1.96*0.418/sqrt(61)
```

```
[1] 3.284102 3.493898
```

Hvert KI indeholder med 95% sandsynlighed den sande værdi for den log-transformerede D-vitaminkoncentration for de to grupper. Intervallerne overlapper, men ingen af de to gennemsnit ligger i det andet KI, og vi kan derfor ikke konkludere om der er en signifikant forskel.

Danske og polske piger

Udregn teststørrelsen for den approksimative t-test for sammenligning af log(D-vitaminniveua). Brug de beregnede variationer på gennemsnittene. Brug teststørrelsen til at konkludere om forskellen på D-vitaminniveauet er statistisk signifikant på et 5% niveau.

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61

forskel:

```
diff <- 3.21-3.389
```

samlet SEM

```
SEM_samlet <- sqrt((0.495/sqrt(59))^2 + (0.418/sqrt(61))^2)
```

Testværdien:

```
diff/SEM_samlet
```

```
[1] -2.136821
```

Testværdien er større end 1.96 (i absolutte værdier). Og forskellen er derfor signifikant.

p-værdi:

```
2*pt(diff/SEM_samlet, 59+61)
```

```
[1] 0.03464261
```

Og der skal ganges med to…

Danske og polske piger

Vi får nu at vide at vi kan beskrive log(D-vitaminniveau) i begge lande ved en normalfordeling. Beregn et 95% reference interval for log(D-vit) for danske piger.

Hvordan beregner vi referenceintervallet?

± 1.96

Skal vi bruge SEM?

Nej, for nu antager vi at tallene er normalfordelte.

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61

Det danske referenceinterval:

```
3.211+c(-1,1)*1.96*0.492
```

```
[1] 2.24668 4.17532
```

Danske og polske piger

TAVLE Brug derefter og for de polske piger til at beregne hvor stor en andel af dem der forventes at ligge inden for det danske referenceinterval.

Hvis referenceintervallet for de danske piger er [nedre, øvre], hvordan finder vi andelen af polske piger der ligger inden for det?

Hvis X er normalfordelt med middelværdi 3.389 og spredning 0.418, skal vi beregne: P(2.24668 < X < 4.17532) <=> P(X < 4.17532) - P(X < 2.24668)

Vi kan bruge pnorm direkte (cowboytricket)

```
pnorm(4.17532, 3.389, 0.418) - pnorm(2.24668, 3.389, 0.418)
```

```
[1] 0.9668844
```

Eller vi kan standardisere så vi kan bruge standardnormalfordelingen.

Kategorisk

En opgave

Vi skal se på prævalensen af tuberkulose blandt stiknarkomaner og om den er afhængig af om der deles sprøjter med andre narkomaner. I en gruppe med 97 narkomaner der deler sprøjte med andre narkomaner, testede 24.7% positiv for TB. I en gruppe på 161 narkomaner der ikke delte sprøjte, testede 17.4% positive for TB.

Hvis vi antager at prævalensen ikke afhænger af om der deles sprøjter - hvad estimerer vi så prævalensen til at være?

ja så er det alle tb positive divideret med alle.

Antal positive:

```
0.247*97 + 0.174*161
```

```
[1] 51.973
```

vi regner med 52...

Og hvor mange var der ialt? 161+97

Så andelen er

```
52/258
```

```
[1] 0.2015504
```

Hvor sikker var vi?

Hvad er et 95% KI for prævalensen af TB blandt stiknarkomaner, hvis vi antager at den ikke afhænger af om man deler sprøjte eller ej?

Proportionen beregnede vi til 0.2015504

Standardfejlen er givet ved:

$SE_{prop} = \sqrt{\frac{9(1-p)}{n}}$

Der var 258 observationer i stikprøven

estimat$\pm$1.96 SE

```r
prop <- 0.2015504
se_prop <- sqrt((prop*(1-prop)/285))
se_prop
```

```
[1] 0.02376256
```

```r
prop + c(-1,1)*1.96*se_prop
```

```
[1] 0.1549758 0.2481250
```

Så kan vi regne

Prævalens af TB blandt de 97 der delte sprøjter: 24.7% Prævalens af TB blandt de 161 der ikke delte sprøjter: 17.4%

```r
SE_deler <- sqrt(0.247*(1-0.247)/97)
SE_deler_ikke <- sqrt(0.174*(1-0.174)/161)
SE_diff <- sqrt(SE_deler^2  + SE_deler_ikke^2)
dif <- 0.247-0.174
test <- dif/SE_diff
test
```

```
[1] 1.377082
```

Modelbesvarelsen bytter om på 161 og 97 i beregningen af SE, og giver derfor en forkert testværdi. Men dog samme konklusion.

Ved et 5% signifikansniveau (kritisk værdi 1.96) er testværdien 1.38 mindre end den kritiske værdi. Vi kan derfor *ikke* forkaste nullhypotesen, $H_0 : p_deler - p_deler_ikke = 0$ og konkluderer at der i data ikke er evidens for den alternative hypotese, at der skulle være forskel i prævalens for de to grupper.

Forholdet mellem de to prævalenser RR

og så er vi ca. klar til at regne

Hvordan finder vi tabellen?

```
0.247*97
```

```
[1] 23.959
```

```
97-0.247*97
```

```
[1] 73.041
```

```
0.174*161
```

```
[1] 28.014
```

```
161-0.174*161
```

```
[1] 132.986
```

Konklusionen bliver den samme uanset om vi dividerer den ene risiko med den anden eller omvendt. Men tolkningen af resultatet vil være forskellig.

```
SE_log_rr <- sqrt(1/24 - 1/(24+73) + 1/28 - 1/(28+133))
risk_deler <- 24/(24+73)
risk_deler_ikke <- 28/(28+133)
rr <- risk_deler/risk_deler_ikke
testværdi <- log(rr)/SE_log_rr
ki_log <- log(rr) + c(-1,1)*1.96*SE_log_rr
ki <- exp(ki_log)
```

Vi estimerer at RR er 1.42, hvilket svarer til at de der deler sprøjter har ca. 42% højere risiko for TB end de der ikke deler sprøjter. Vi finder et 95% konfidens interval til [0.8772285, 2.3072887]. Da 1 er indeholdt i intervallet, kan vi ikke afvise H_0 på et 5% signifikansniveau. Null-hypotesen var $H_0 : RR = 1$. Alternativt finder vi testværdien til at være ca 1.43 hvilket er mindre end den kritiske værdi 1.96 ved et 5% signifikansniveau. Vi kan derfor ikke forkaste H_0, og må også på denne baggrund konkludere at der ikke i data er evidens for forskel i prævalensen for TB mellem del to grupper.

Odds-ratio

```r
odds_deler <- 24/73
odds_deler_ikke <- 28/133
OR <- odds_deler/odds_deler_ikke
SE_log_OR <- sqrt(1/24 + 1/73 + 1/28 + 1/133)
test_værdi <- log(OR)/SE_log_OR
KI_log_OR <- log(OR) + c(-1,1)*1.96*SE_log_OR
KI_OR <- exp(KI_log_OR)
```

χ^2

```r
tab <- matrix(
  c(24, 73,
    28, 133),
  nrow = 2,
  byrow = TRUE
)

dimnames(tab) <- list(
  Exposure = c("Deler", "Deler_ikke"),
  TB = c("Ja", "Nej")
)
chisq.test(tab, correct = FALSE)
```

```
    Pearson's Chi-squared test

data:  tab
X-squared = 2.0325, df = 1, p-value = 0.154
```

p-værdien er 0.154. p-værdien er sandsynligheden for at

For tidlig fødsel

Et studie i England undersøgte faktorer for tidlig fødsel blandt gravide kvinder og fandt at incidensen for tidlig fødsel var 7.5% blandt de 1513 kvinder der var med i studiet.

Beregn 95% KI for insidensen for tidlig fødsel baseret på disse tal. phat(E) = 0.075. se(phate) = sqrt(p*(1-p)/n) = *sqrt(0.075*(1-0.075)/1513)

```r
se_gb <- sqrt(0.075*(1-0.075)/1513)
se_gb
```

```
[1] 0.006771456
```

Der er et 0 for lidt i modelbesvarelsen...

```r
0.075+c(-1,1)*1.96*sqrt(0.075*(1-0.075)/1513)
```

```
[1] 0.06172795 0.08827205
```

For tidlig fødsel

b) Et tilsvarende studie i Danmark fandt en incidens på 4.5% blandt 51851 kvinder der deltog Estimer forskellen i incidensen for tidlig fødsel i England vs danmark. Er der signifikant forskel?

forskel:

```r
diff <- 0.075-0.045
diff
```

```
[1] 0.03
```

se_dk:

```r
se_dk <- sqrt(0.045*(1-0.045)/51851)
```

```r
se_diff <- sqrt(se_dk^2 + se_gb^2)
se_diff
```

```
[1] 0.006832381
```

et 95% ki for diffen:

```r
diff + c(-1,1)*1.96*se_diff
```

```
[1] 0.01660853 0.04339147
```

Intervallet indeholder *ikke* 0, og vi kan konkludere at der er en statistisk signifikant forskel.

Lineær regression

Fedme og blodtryk

Vi skal se på sammenhængen mellem blodtryk og fedme. Vi får oplyst at der er et datasæt med 102 individer, 44 mænd, 58 kvinder.

Der er variabler:
KØN (1=kvinde, 0= mand)
FEDME: Fedmegrad - vægt i forhold til idealvægt. 1.2 betyder at man vejer 20% mere end man burde. Svarende til 120% af idealvægten
BLODTRYK: Systolisk blodtryk (i mmHg)

De første 6 observationer, og nogle deskriptive størrelser:

```
KØN FEDME BLODTRYK
```

1 0 1.31 130
2 0 1.31 148
3 0 1.19 146
4 0 1.11 122
5 0 1.34 140
6 0 1.17 146

mean(BLODTRYK[KØN==0]) 127.9545
mean(BLODTRYK[KØN==1]) 126.3103
sd(BLODTRYK[KØN==0]) 16.59077
sd(BLODTRYK[KØN==1]) 19.41893

Reference interval for blodtykket for kvinder.

```
126.3103 + c(-1,1)*1.96*19.41893
```

```
[1]  88.2492 164.3714
```

Fedme og blodtryk - t-test

```
SEM_m <- 16.59077/sqrt(44)
SEM_f <- 19.41893/sqrt(58)
SE_diff <- sqrt(SEM_m^2  + SEM_f^2)
diff <- 127.9545-126.3103
test_value <- diff/SE_diff
```

Det vil jeres eksaminatorer som regel kalde "klart signifikant". Hardcore statistiskere vil sige at der ikke er noget er hedder "klart signifikant". Det er signifikant. Eller også er det ikke signifikant. Og det kan det så være på forskellige niveauer.

Fedme og blodtryk - manglende estimat

Køn:

```
-7.730/3.715
```

```
[1] -2.080754
```

Det er statistisk signifikant (på et 5% niveau)

FEDME:

```
7.172*4.049
```

```
[1] 29.03943
```

Er det signifikant?

Hoppemålinger genbesøgt

```
intercept <- -3.775 + c(-1,1)*1.96*3.471
factor_gender <- 16.283+c(-1,1)*1.96*4.714
```

Drenge - hormoner - prediktion

c. Prædikter (forudsig) hormonniveauet for en dreng på 6 år med et BMI på 17 og for en dreng på 14 med et BMI på 18.

Det finder vi ved: Den 6-årige: 5.40 + 0.058*17

for den 14-årige 5.40+0.229+0.058*18

transplanteret lungevolumen

```
1.279024/(0.9411598/sqrt(426))
```

```
[1] 28.04918
```

Det er større end 1.96, så statistisk signifikant (nogen føler trang til at sige "klart signifikant")

transplanteret lungevolumen - fortolk

Fortolk værdierne i søjlen "Estimate". Beregn tilhørende 95% KI

Intercept er den estimerede ændring i lungefunktion (før vs efter transplantation) for patienter med en donor som var ikke-ryger. Den estimerede ændring er i gennemsnit 1.3697, med et 95% KI på:

```
1.36970 + c(-1,1)*1.96*0.06646
```

```
[1] 1.239438 1.499962
```

Forbedringen i lungefunktion er lidt mindre for patienter med en donor som var ryger (eller ex-ryger). Forbedringen estimeres til i gennemsnit at være 0.19092 laverem, med det tilhørende 95% KI på:

```
-0.19092+c(-1,1)*1.96*0.09644
```

```
[1] -0.3799424 -0.0018976
```

Leversygdom

```
sem_0 <- 0.289/sqrt(167)
sem_1 <- 0.358/sqrt(416)
se_diff <- sqrt(sem_0^2 + sem_1^2)
diff <- -0.011--0.152
diff/se_diff
```

```
[1] 4.959711
```

det er klart signifikant (den er næsten fem standardafvigelser fra 0). der er en signifikant lavere l_ratio blandt de syge.

Leversygdom - kønsfordeling

```
# Sandsynligheden for at være kvinde blandt de raske:
p_0 = 50/(50+117)
p_0
```

```
[1] 0.2994012
```

```
# Sandsynligheden for at være kvinde blandt de syge:
p_1 = 92/(92+324)
p_1
```

```
[1] 0.2211538
```

```
se_0 <- sqrt(0.2994012*(1-0.2994012)/(50+117))
se_0
```

```
[1] 0.03544078
```

```
se_1 <- sqrt(0.2211538*(1-0.2211538)/(92+324))
se_1
```

```
[1] 0.02034822
```

Er den sande værdi af forskellen på de to andele (af kvinder i hhv syg og rask-grupperne) i virkeligheden 0? samlet se

```r
se_p <- sqrt(se_0^2 + se_1^2)
se_p
```

```
[1] 0.04086684
```

Og så testværdien:

```r
diff <- 0.2994012-0.2211538
diff/se_p
```

```
[1] 1.914692
```

Og det er så ikke signifikant. Null-hypotesen var at der ikke var forskel. Den kan vi ikke forkaste.

Leversygdom - aldersfordeling

Er aldersfordelingen den samme for syge som for raske?

two-sample t-test. så er forskellen på gennemsnitlig alder forskellig fra 0? Her nævnte eksamensspørgsmålet specifikt at man blot skulle forklare hvad man ville gøre - man skulle ikke regne.

```r
diff <- 46.2-41.2
sem_0 <- 17.0/sqrt(167)
sem_1 <- 15.7/sqrt(416)
sem_diff <- sqrt(sem_0^2 + sem_1^2)
diff/sem_diff
```

```
[1] 3.280496
```

Vi kan afvise 0-hypotesen

Leversygdom - prediktion

predikter median-ratio for de syge i studiepopulationen med en alder på 50 år, som er kvinder.

vores estimat på en middelværdi for l_ration - som altså er log er:

```
0.1730998+-0.1196883+50*-0.0045177
```

```
[1] -0.1724735
```

Og så skal vi eksponentiere:

```
exp(-0.17)
```

```
[1] 0.8436648
```

Blodtryk i Ghana

Er der et signifikant fald i blodtrykket i interventionsgruppen i den undersøgte periode. Besvar samme spørgsmål for kontrolgruppen.

Vi starter med SEM for de to grupper: Intervention: n= 323

```
SEM_intervention <- 17.4/sqrt(323)
```

```
SEM_kontrol <- 19.9/sqrt(641-323)
```

Så kan vi beregne 95% KI beregnes for de to grupper:

intervention:

```
-19.6+c(-1,1)*1.96*SEM_intervention
```

```
[1] -21.4976 -17.7024
```

kontrol:

```
-16.6+c(-1,1)*1.96*SEM_kontrol
```

```
[1] -18.78724 -14.41276
```

Ingen af de to KI indeholder 0, så vi kan konkludere at begge behandlinger sænker det systoliske blodtryk signifikant.

Blodtryk i Ghana

Er faldet i blodtryk signifikant forskelligt i de to gruypper? hvad kan vi konkludere vedrønde effekten af præcisionsbehandlingen på blodtrykket pååå baggrund af de beregninger vi har udført indtil videre?

```
SEM_diff <- sqrt(SEM_intervention^2 + SEM_kontrol^2)
```

Det giver os en teststørrelse på forskellen på de to differenser på:

```
(-19.6- -16.6)/SEM_diff
```

```
[1] -2.030622
```

Som (i absolutte tal) er større end 1.96 - der er en signifikant forskel.

Blodtryk i Ghana

c) Nu udførtes følgende analyser for mænd og kvinder hver for sig: > summary(lm(diff[sex==“female”]~factor(group[sex==“female”]))) Hvilke analyser er er tale om, og hvad kan vi konkludere på baggrund af disse? Der ønskes en fortolkning af værdierne i “Estimate” søjlerne. Giver det anledning til en anden konlusion end den vi fik lige før?

Der er tale om to multiple lineære rgressioner, med diff som kontinuært responsvariabel og group som forklarende, kategorisk (og binær) variabel.

For kvinderne ser vi at blodtrykket i gennemsnit falder med ca 17 mmHg under kontrolbehandling (signifikant, med $p \sim 0$), og yderligere ca 6 mmHg ved præcisionsbehandlingen (signifikant med $p = 0.002$)

For mændene ser vi at blodtrykket i gennemsnit falder med ca. 16 mmHg under kontrolbehandling, men at der ikke er signifikant forskel på effekten af de to behandlinger (p=0.456)

Logistisk

Hvordan ser resultatet ud?

Vi skal lave et regnestykke der illustrerer sammenhængen mellem estimat, fejl og z value

Hvor sikre er vi på de estimater?

```
0.7423 + c(-1,1)*1.96*0.2149
```

```
[1] 0.321096 1.163504
```

```
exp(0.7423)
```

```
[1] 2.100762
```

```
exp(0.7423 + c(-1,1)*1.96*0.2149)
```

```
[1] 1.378638 3.201130
```

Så - vores estimat er at en stigning i alder p å 10 år er associeret med 2.1 gange højere odds. Og et konfidensinterval på det estimat mellem 38% og 220% højere odds.

Mors rygning - intercept

Interceptet er log-odds for fosterdød for baseline.

Baseline er en 25 årig kvinde. Uden feber episoder, der ikke har røget under graviditeten

odds:

```
(odds <- exp(-5.0526))
```

```
[1] 0.006392691
```

Meget lav.

95% KI. Vi finder det først på log-odds skala

```
(log_ki <- -5.0526 + c(-1,1)*1.96*0.1758)
```

```
[1] -5.397168 -4.708032
```

Og så på odds skala

```
(ki <- exp(log_ki))
```

```
[1] 0.004529390 0.009022516
```

Sandsynlighed:

```
(p <- odds/(1+odds))
```

```
[1] 0.006352084
```

Gang med 100 for at få procent

Den hurtige vej fra ki-odds til ki p:

```
ki/(1+ki)
```

```
[1] 0.004508967 0.008941839
```

Ved meget små odds er sandsynlighed og odds næsten det samme. Hvorfor? fordi vi dividerer med noget der er næste 1, ford i odds er ret lille.

Mors rygning alder

Det er samme regnestykker som sidst.

Oddratio (RATIO!)

```
(OR <- exp(0.7423))
```

```
[1] 2.100762
```

log-ki for log-OR for alder:

```
(log_ki <- 0.7423 + c(-1,1)*1.96*0.2149)
```

```
[1] 0.321096 1.163504
```

og ki for or:

```
exp(log_ki)
```

```
[1] 1.378638 3.201130
```

Estimatet var 2.1, det vil sige 2.1 gange så høje odds for fosterdød når mors alder stiger med 10 år.

Og den sande effekt ligger plausibelt mellem 38 og 220% højere odds

Mors rygning - prediktion 25 år

Det er baseline.

```
(log_odds <- -5.0526 + 0*0.7423)
```

```
[1] -5.0526
```

```
(odds <- exp(log_odds))
```

```
[1] 0.006392691
```

```
odds/(1+odds)
```

```
[1] 0.006352084
```

```
plogis(log_odds)
```

```
[1] 0.006352084
```

Mors rygning - prediktion 40 år

Det er baseline.

```
(log_odds <- -5.0526 + (40-25)/10*0.7423)
```

```
[1] -3.93915
```

```
(odds <- exp(log_odds))
```

```
[1] 0.01946475
```

```
odds/(1+odds)
```

```
[1] 0.01909311
```

```
plogis(log_odds)
```

```
[1] 0.01909311
```

Rygende donorer - regne

For død inden for tre år Ikkerygerdonor

```
p_NS <- 68/(68+153)
```

rygerdonor

```
p_SM <- 117/(117+153)
```

```
(RR <- p_SM/p_NS)
```

```
[1] 1.408333
```

Og det er smoker divideret med non-smoker fordi vi ser på den øgede risiko for død hvis donor har været ryger.

1.4 gange højere risiko for død inden for tre år - sammenlignet med hvis donor ikke havde været ryger.

```
(se_log_rr <- sqrt(1/68 - 1/(153+68) + 1/88 - 1/(88+117)))
```

```
[1] 0.1290991
```

KI for log(RR)

```
(KI_log_rr <- log(RR) + c(-1,1)*1.96*se_log_rr)
```

```
[1] 0.08937269 0.59544125
```

Og KI for RR

```
exp(KI_log_rr)
```

```
[1] 1.093488 1.813831
```

1 er ikke indeholdt - så signifikant sammenhæng.

Rygende donorer - regressionen

Vi kan konkludere at der er signifikant effekt af begge forklarende variable, rygestatus for donor og alderskategorien for donor.

SMOKE har en OR på

```
exp(0.5751)
```

```
[1] 1.777308
```

KI:

```
exp(0.575 + c(-1,1)*1.96*0.21)
```

```
[1] 1.177508 2.682100
```

det tilhørende konfidensinterval finder vi ved: exp(0.575 + c(-1,1)*1.96*0.21)

dvs 1.77 gange højere odds for at dø inden for 3 år efter transplatation sammen lignet med ikkeryger donor (og fastholdt donoralder). KI indeholder ikke 1, og det er signifikant.

donoralder. Her har vi to. OR_40-55

```
exp(0.444)
```

```
[1] 1.55893
```

og KI:

```
exp(0.444 + c(-1,1)*1.96*0.2527)
```

```
[1] 0.9500012 2.5581696
```

og OR_56

```
exp(0.9395)
```

```
[1] 2.558702
```

KI

```
exp(0.9395 + c(-1,1)*1.96*0.2891)
```

```
[1] 1.451887 4.509273
```

Dvs 1.55 gange højere odds for at dø indenfor 3 år efter transplantation for en patient med en donor der var 40-55 sammenlignet med en donoer der var under 40. Ved fastholdt rygestatus for donor. KI indeholder 1, og er derfor ikke signifikant.

og 2.56 gange højere odds for at dø indenfor 3 år efter transplatatione for en patient med en donor der var over 56, sammenlignet med en donor der var under 40. Ved fastholdt rygestatus for donor. KI indeholder ikke 1, og er derfor signifikant.

rygende donorer endeligt regnestykke

```
exp(-1.2848)/(1+exp(-1.2848))
```

```
[1] 0.2167343
```

Det I skal opdage her er at vi har omregningen fra odds til sandsynlighed!

Hvordan fortolker vi det tal?

-1.2848 er estimatet på intercept.

Det var for referencegruppen. Den patientguppe der har fået lunger fra en donor under 40 år, der var ikke ryger.

Hvad er det så vi beregner?

exp(-1.2848) går fra

Log Odds(ratio) til:

Odds

Og brøken giver?

Den går fra odds til sandsynlighed - så vi får?

Den estimerede sandsynlighed for at dø inden for 3 år, for den patientgruppe der fik lunger fra en donor under 40, der var ikke-ryger.

DTP-vaccine umiddelbar sammenhæng?

Ser det umiddelbart ud til at der er en sammenhæng mellem dødeligheden og vaccinestatus?

Sandsynlighed for død ved de to vaccine-statuser

```
(p_0 <- 9/(526+9))
```

```
[1] 0.01682243
```

```
(p_1 <- 46/(46+892))
```

```
[1] 0.04904051
```

RR

```
(RR <- p_1/p_0)
```

```
[1] 2.915186
```

Det vil sige ca. 2.9 gange så høj risiko for død. Ved vaccine!

SE-log-rr

```
(SE_log_rr <- sqrt(1/9 - 1/(9+526) + 1/46 -1/(46+892)))
```

```
[1] 0.3604372
```

testværdien

```
log(RR)/SE_log_rr
```

```
[1] 2.968433
```

Resultatet er derfor statistisk signifikant på et 5% niveua. Vi kan nok også beregne et KI på RR

DTP-vaccine

OR for effekten af vaccinestatus estimeres til

```
exp(0.0261)
```

```
[1] 1.026444
```

Med et KI på:

```
exp(0.0261 + c(-1,1)*1.96*0.0116)
```

```
[1] 1.003370 1.050048
```

Vaccinerede har ca. 2.6% højere odds for død end ikke-vaccinerede

Glykæmisk kontrol

Baseret på den tabel - er der sammenhæng mellem de to variable?

Hvad er den relative risiko for at have godt helbred hvis HbAlc er 1 - altså velreguleret.

```
(R_velreg <- 188/(188+264))
```

```
[1] 0.4159292
```

```
(R_ejreg <- 354/(354+412))
```

```
[1] 0.462141
```

```
(RR <- R_velreg/R_ejreg)
```

```
[1] 0.900005
```

Så - den relative risiko for at have et godt selvvurdereet helbred er reduceret for diabetikere under glykæmisk kontrol, sammenlignet med diabetere der ikke er under glykæmisk kontrol.

Det er kontraintuitivt for ikke-medicineren her.

glykæmisk kontrol - Er det signifikant?

se_log_rr

```
(se_log_rr <- sqrt(1/188 - 1/(188+264) + 1/354 - 1/(354+412)) )
```

```
[1] 0.0680157
```

Så KI er

```
log_ki <- log(RR) + c(-1,1)*1.96*se_log_rr
exp(log_ki)
```

```
[1] 0.7876781 1.0283502
```

1 er indeholdt i intervallet, og estimatet på RR er derfor ikke signifikant.

Glykæmisk kontrol - model

Glykæmisk kontrol har vi allerede regnet på.

Køn. OR

```r
exp(0.252051)
```

```
[1] 1.286662
```

Mandlige diabetikere har derfor 28% større odds for godt helbred (selvrapporteret) sammenlignet med kvindelige diabetikere, og et KI på med alder og HBAlC fastholdt:

```r
exp(0.252051 + c(-1,1)*1.96*0.117514)
```

```
[1] 1.021961 1.619923
```

Alder, der også var statistisk signifikant (p-værdien)

OR:

```r
exp(-0.015573)
```

```
[1] 0.9845476
```

ved fastholdt køn og HBAlC. ca. 1.2% reduceret odds for selvrapporteret godt helbred for hver øgning af alder med 1 år

Ved fastholddt køn og hbalc

Hvis vi ønsker hvad det er for eg 5 år, skal der ganges med 5 på både estimatet og standardfejlen

Laparotomi

Vi starter med at finde et estimat for bmi

```r
(OR_bmi <- -3.151*0.015385)
```

```
[1] -0.04847813
```

Vi mangler også en p-værdi. Men teststørrelsen fortæller os at det er klart signifikant.

```r
2*pnorm(-3.151)
```

```
[1] 0.001627125
```

Det giver ikke mening at regne på intercept. Hvorfor? Fordi det svarer til et bmi på 0.

Kunne vi have fået et intercept der var meningsfuldt? Hvis vi husker hvordan vi håndterede mors alder i de rygende mødre - der satte vi et nulpunkt. Vi kunne gøre det samme med BMI, så havde vi fået en reference, hvor intercept havde været log-odds for risikoen for død ved et bestemt BMI.

Det gør vi ikke i denne opgave.

OR på BMI

```r
exp(OR_bmi)
```

```
[1] 0.9526782
```

Så holdes alt andet konstant, vil en patient med et bmi der er 1 større end en anden patient, have vil odds for død reduceres med ca 5% for patienten med det højeste bmi.

Vi kan beregne et 95% KI for:

```r
exp(-0.04847813 + c(-1,1)*1.96*0.015385)
```

```
[1] 0.9243794 0.9818433
```

1 er ikke indeholdt i intervallet, og forskellen er derfor signifkant. Det så vi også fra p-værdien vi beregnede tidligere.

Laparotomi - ilt

Vi sammenligner død (1) for de to ilt-regimer X og Y:

odds for død

```r
(odds_x <- 139/414)
```

```
[1] 0.3357488
```

```
(odds_y <- 107/418)
```

```
[1] 0.2559809
```

OR - vi er interesserede i det høje iltregime

```
(OR <- odds_x/odds_y)
```

```
[1] 1.311617
```

```
(SE_log_OR <- sqrt(1/414 + 1/139 + 1/418 + 1/107))
```

```
[1] 0.146109
```

95% KI:

```
(log_odds_ki <- log(OR) + c(-1,1)*1.96*SE_log_OR)
```

```
[1] -0.0151131  0.5576342
```

```
exp(log_odds_ki)
```

```
[1] 0.9850005 1.7465357
```

Så vi estimereer at odds for at dø ved det høje ilt regime (X) er ca 31% højere end ved det lave, med et 95% KI på xx, der indeholder 1, og derfor ikke er signifikant.

Husk forskellen på OR og RR - det er odds, ikke risiko!

Laparotomi - diagnose

Tabellen deles nu op efter den opererede patients diagnose (cancer, ja,nej):

Nu laver vi samme øvelse, men på hver gruppe.

Cancer patienter:

```r
(odds_x <- 101/188)
```

```
[1] 0.537234
```

```r
(odds_y <- 74/213)
```

```
[1] 0.3474178
```

```r
(OR <- odds_x/odds_y)
```

```
[1] 1.546363
```

```r
(SE_log_or <- sqrt(1/101 + 1/74 + 1/188 + 1/213))
```

```
[1] 0.1828346
```

```r
(log_ki <- log(OR) + c(-1,1)*1.96*SE_log_or)
```

```
[1] 0.07754983 0.79426143
```

```r
exp(log_ki)
```

```
[1] 1.080636 2.212806
```

odds for at dø for cancerpatienter er ca. 1.55 gange højere ved det høje iltregime end ved det lave. 1 er ikke indeholdt i 95% KI for OR, og estimatet er derfor signifikant på et 5% niveau. Vi ser det også ved at log_ki ikke indeholder 0.

For ikke-cancerpatienter

```r
(odds_x <- 38/226)
```

```
[1] 0.1681416
```

```r
(odds_y <- 33/205)
```

```
[1] 0.1609756
```

```r
(OR <- odds_x/odds_y)
```

```
[1] 1.044516
```

```r
(SE_log_or <- sqrt(1/38 + 1/226 + 1/33 + 1/205))
```

```
[1] 0.2567521
```

```r
(log_ki <- log(OR) + c(-1,1)*1.96*SE_log_or)
```

```
[1] -0.4596806  0.5467877
```

```r
exp(log_ki)
```

```
[1] 0.6314853 1.7276943
```

Her estimerer vi at odds for at dø er 1.04 (4%) højer for at dø ved det høje ilt-regime sammenlignet med det lave for ikke-cancerpatienter, med det fundne 95% KI. Da 1 er indeholdt i KI, kan vi konkludere at estimatet ikke er signifikant.

Så ilt-regimet har betyding for cancer patienter, men ikke for ikke-cancerpatienter.

Levertal

Undersøg om der er en statistisk signifikant sammenhæng mellem de to variable.

Her kører vi en chi^2 test:

input:

```r
input <- matrix(c(66,106,99,308), ncol = 2, byrow = TRUE)
chisq.test(input, correct = FALSE)
```

```
    Pearson's Chi-squared test

data:  input
X-squared = 11.709, df = 1, p-value = 0.0006219
```

Det svarer til en p-værdi der er <0.001. Så der er signifikant forskel. modelbesvarlsaer bruger ofte formuleringen "klart signifikant". teknisk set er der ikke noget der er mere signifikant end andet. det er signifikant på et bestemt niveua. Eller også er det ikke. Det er ikke "næsten" eller "meget" signifikant.

Levertal - regression

Nu udfører vi følgende analyse i R: > model <- glm(status~factor(AG.positiv)+factor(sex)+age, binomial) > summary(model)

OR for AG.positiv

```
(OR <- exp(0.594643))
```

```
[1] 1.812384
```

og vi estimerer derfor at odds for at status er 1 (at man er syg) er en faktor 1.8 større

hvis AG.positive patienter, sammenlignet med AG.negative.

KI:

```
(KI_log_or <- 0.594643 + c(-1,1)*1.96*0.199556)
```

```
[1] 0.2035132 0.9857728
```

```
exp(KI_log_or)
```

```
[1] 1.225701 2.679882
```

Og det vi så svarer er: ORE for AG.positiv estimerer vi til

Da det ikke indeholder 1, er resultatet signifikant (i overensstemmelse med hvad vi så fra p-værdien)

Levertal - prediktion

Prædikter sandsynlighednen for at have status 1 (syg) for en AG.positiv kvinde på 50.

```
(log_odds_syg <- -0.446661 +  0.594643 + 50*0.015131 )
```

```
[1] 0.904532
```

```
(odds_syg <- exp(log_odds_syg))
```

```
[1] 2.470775
```

```
(sandsynlighed <- odds_syg/(1+odds_syg))
```

```
[1] 0.7118799
```

Så sandsynligheden for at være syg, hvis man er AG.positiv 50-årig kvinde er 71%

Bilirubin

a) baseret på ovenstående table ønske beregnet relativ risiko (med tilhørende 95% KI) til belysning af effekten af behandlingen på det betragtede udfald. Husk at konkludere.

Risiko ved behandling:

```
(R_udc <- 42/(134+42))
```

```
[1] 0.2386364
```

```
(R_pla <- 55/(118+55))
```

```
[1] 0.3179191
```

```
(RR <- R_udc/R_pla)
```

```
[1] 0.7506198
```

RR er 0.75 - det betyder at der er en ca. 25% reduceret risiko for treatment failure ved UDC behandlingen. KI

```
(SE_log_rr <- sqrt(1/42 - 1/(134+42) + 1/55 - 1/(118+55)))
```

```
[1] 0.174726
```

```
(KI_log <- log(RR) + c(-1,1)*1.96*SE_log_rr)
```

```
[1] -0.6293189  0.0556070
```

```
exp(KI_log)
```

```
[1] 0.5329547 1.0571821
```

Bilirun - regression

Nu udførtes følgende analyse: > model <- glm(Y ~ factor(R) + X, family =“binomial”) summary(model)

Såvel behandlingen som X er statistisk signifikante på et 5% niveua.

Det giver ikke mening at tolke på X, der er en standardiseret udgave af logaritmen af bilirubin (målt i umol/L). Så det er en stigning i OR for hver stigning på en standardafvigelse af logaritmen af bilirubin, relativt til middelværdien.

For den forklarende variabel R, der er det vi faktisk kan styre selv - det var behandling UDC vs. placebo

OR

```
exp(-0.9054)
```

```
[1] 0.4043801
```

Når der kontrolleres for bilirubin. når den er ca. 0.4, så svarer det til en reduktion på ca. 60% i odds for treatment failure ved aktiv behandling kontra placebo.

KI

```
(KI_log <- -0.9054 + c(-1,1)*1.96*0.2967)
```

```
[1] -1.486932 -0.323868
```

```
exp(KI_log)
```

```
[1] 0.2260652 0.7233457
```

For den forklarende variabel X får vi en estimeret odds ratio (OR) på behandlingen på exp(-0.9054) = 0.4043801 når der kontrolleres for den forklarende variabel X.

Det tilhøreden 95% konfidensinterval findes ved: exp(-0.9054 + c(-1,1)*1.96*0.2967)

OR påp 0.4 svarer til en reduktion i odds for treatment failure på ca 60%, ved aktiv behandling vs. placebo, når der kontrolleres for bilirubin. Da KI ikke indeholder 1, er effekten signifikant.

Powerberegninger

$\frac{\sigma}{\sigma\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}} = z_{1-0.05/2} + z_{1-0.2}$

n_1 = 100

```
qnorm(0.975) + qnorm(0.8)
```

```
[1] 2.801585
```

1 = 2.8* kvadratroden

Af med kvadratroden

1 = 2.8^2 * (1/100 + 1/n_2)
1/2.8^2 = 1/100 + 1/n_2

1/2.8^2 - 1/100 = 1/n
1/(1/2.8^2 - 1/100) = n

```
1/(1/2.8^2 - 1/100)
```

```
[1] 8.506944
```

Vi runder op!

powerrelationen opstilles

```
qnorm(0.975) + qnorm(0.9)
```

```
[1] 3.241516
```

3.2 = 300/(430/sqrt(n)) 3.2*430/sqrt(n) = 300 sqrt(n)*300 = 3.2*430 sqrt(n) = 3.2*430/300 n = (3.2*430/300)^2

```
(3.2*430/300)^2
```

```
[1] 21.03751
```

og vi runder op!

Isoler delta

```
qnorm(0.975) + qnorm(0.9)
```

```
[1] 3.241516
```

3.2 = delta/(430/sqrt(100))

3.2 = delta/(430/10) delta = 43*3.2

```
43*(qnorm(0.975) + qnorm(0.9))
```

```
[1] 139.3852
```