

Opgaveløsninger

Normalfordelingen

Et par hurtige øvelser

Hvis vores observationer er normalfordelte med $\mu = 0$ og $\sigma = 1$

Hvor stor en andel af observationerne er mindre end 1 (σ)?

```
pnorm(1)*100
```

```
[1] 84.13447
```

Hvor mange observationer er mindre end -2 (σ)

```
pnorm(-2)*100
```

```
[1] 2.275013
```

hvilken værdi (af) er 15.9% af observationerne mindre (end denne værdi)?

```
qnorm(0.159)
```

```
[1] -0.9985763
```

Øvelse 1

Hvilken andel af observationerne i standardnormalfordelingen er mindre end -3?

```
pnorm(-3)
```

```
[1] 0.001349898
```

Øvelse 2

Hvilken andel af observationerne i standardnormalfordelingen er mindre end 2?

```
pnorm(2)
```

```
[1] 0.9772499
```

Øvelse 3

Hvilken andel af observationerne i standardnormalfordelingen er større end 2?

```
1- pnorm(2)
```

```
[1] 0.02275013
```

Øvelse 4

Hvad er 25% af observationerne mindre end?

```
qnorm(0.25)
```

```
[1] -0.6744898
```

Øvelse 5

Hvad er 40% af observationerne større end?

```
qnorm(1-0.4)
```

```
[1] 0.2533471
```

Øvelse 6

Hvilken andel af observationerne ligger mellem 1 og 1.5?

Hvilken andel ligger under 1.5?

Hvilken andel ligger under 1?

Det er så

```
pnorm(1.5) - pnorm(1)
```

```
[1] 0.09184805
```

Øvelse 7

Hvis vi vil have 47% af observationerne, hvilket interval (centreret om 0) skal vi så have?

Hvor meget ligger så uden for det interval?

53%

Det skal fordeles ligeligt på begge sider, så $53/2=26.5$

```
qnorm(0.265)
```

```
[1] -0.628006
```

Øvelse 8 - og det vigtigste tal I skal kende!

Hvis vi vil have 95% af observationerne, hvilket interval (centreret om 0) skal vi så have?

Hvis intervallet skal indeholde 95% af observationerne - hvor meget ligger så uden for?

$1-0.95 = 0.05$

Det skal fordeles ligeligt på begge sider så $0.05/2 = 0.025$

```
qnorm(0.025)
```

```
[1] -1.959964
```

og

```
qnorm(1-0.025)
```

```
[1] 1.959964
```

Endnu en øvelse

Nappet direkte fra en eksamensopgave

For en population af normalfordelte værdier ved vi at: 40% af værdierne er større end 0.1, og 70% af værdierne er mindre end 1. Hvad er middelværdi og spredning i denne normalfordeling?

Den tager vi på tavlen.

Det er oplyst at $X \sim N(\mu, \sigma^2)$

$$P(X > 0.1) = 0.4 \quad P(X < 0.1) = 1 - 0.4 = 0.6$$

Standardiseret:

$$P(X - \mu < 0.1 - \mu) = 0.6 \quad 0.1 - \mu = \text{qnorm}(0.6) = 0.253$$

Og:

$$P(X < 1) = 0.7$$

Standardiseret:

$$P(X - \mu < 1 - \mu) = 0.7 \quad 1 - \mu = \text{qnorm}(0.7) = 0.524$$

Dermed:

$$0.1 - \mu = 0.253 \quad 0.1 - \mu = 0.253$$

og

$$1 - \mu = 0.524 \quad 1 - \mu = 0.524$$

Træk første ligning fra den anden og isoler μ :

$$(1 - \mu) - (0.1 - \mu) = 0.524 - 0.253 \quad 1 - \mu - 0.1 + \mu = (0.524 - 0.253)$$

$$1 - 0.1 = 0.271 \quad 0.90.271 = 0.271 = 3.32$$

Indsæt i en af ligningerne for at finde μ :

$$1 - \mu = 0.524 \quad 1 - \mu = 0.524 \quad 3.32 \quad 1 - 0.524 \quad 3.32 = -0.77$$

Øvelse

Vi har en normalfordelt population med $\mu = 6.52$. 40% af værdierne er mindre end 0. Hvad er så σ for denne fordeling?

$$X \sim N(6.52, \sigma^2)$$

$$P(X < 0) = 0.4$$

$$\text{Skaler: } P(Z < 0 - 6.52) = 0.4$$

$$0 - 6.52 = \text{qnorm}(0.4) = -0.2533471 \text{ Isolér}$$

Øvelse - Manglende procentil:

En normalfordelt population har middelværdi $\mu = 12.5$ og standardafvigelse $\sigma = 3.2$. Hvor stor en andel af værdierne er mindre end 10?

Med andre ord, hvad er: $P(X < 10)$

Transformer til standardnormalfordelingen: $P(Z < (10 - \mu) / \sigma)$

Indsæt

```
pnorm((10-12.5)/3.2)
```

```
[1] 0.2173277
```

Øvelse - Manglende

I en normalfordelt population er $\mu = 85$ og 25% af værdierne er større end 95. Hvad er σ for denne fordeling?

$$P(x > 95) = 0.25$$

$$P(X < 95) = 1 - 0.25$$

Standardiser

$$P(Z < \frac{95 - \mu}{\sigma}) = 0.75$$

Indsæt og brug qnorm til at komme af med P

$$(95 - 85) / \sigma = \text{qnorm}(0.75)$$

Isoler σ

$$10 / \text{qnorm}(0.75) = \sigma$$

Manglende værdi, kendt procentil:

En normalfordelt variabel har $\mu = 50$ og $\sigma = 8$. For hvilken værdi y er 90% af observationerne $< y$?

$$P(X < y) = 0.9$$

Standardiser

$$P(Z < (y - \mu) / \sigma) = 0.9$$

qnorm of at komme af med P

$$(y - \mu) / \sigma = \text{qnorm}(0.9)$$

$$\text{Indsæt } (y - 50) / 8 = \text{qnorm}(0.9)$$

Isoler y

```
y <- qnorm(0.9)*8+50  
y
```

```
[1] 60.25241
```

Manglende middelværdi (variant 2):

For en normalfordeling gælder at $\sigma = 4.5$ og 75% af værdierne er > 18 . Hvad er μ ?

$$P(X > 18) = 0.75$$

$$P(X < 18) = 1 - 0.75$$

Standardiser

$$P(Z < (18 - \mu) / \sigma) = 0.25$$

Indsæt og brug qnorm til at komme af med P

$$(18 - \mu) / 4.5 = \text{qnorm}(0.25)$$

Isoler

```
mu <- 18 - qnorm(0.25)*4.5  
mu
```

```
[1] 21.0352
```

Manglende interval-grænse En normalfordelt population har $\mu=100$ og $\sigma=15$. Hvis 80% af værdierne ligger mellem 85 og en øvre grænse x , hvad er da denne øvre grænse?

Eller: find y således at: $P(85 < X < y) = 0.8$

TAVLE

Samlet sandsynlighed op til y $P(X < y)$

Fra det skal vi trække den del hvor X er mindre end 85

$P(X < 85)$

Så: $P(X < y) - P(X < 85) = 0.80$

$P(X < 85)$ kan vi beregne

Standardiser

$P(Z < (85 - 100) / 15)$

Indsæt, og brug `pnorm` for at få sandsynligheden

```
pnorm((85-100)/15)
```

```
[1] 0.1586553
```

Så ved vi at $P(X < y) - P(X < 85) = 0.80$

bliver $P(X < y) - 0.1586553 = 0.80$

og derfor at

$P(X < y) = 0.80 + 0.1586553 = 0.9586553$

Standardiser (igen)

$P(X < (y - 100) / 15) = 0.9586553$

Af med P ved hjælp af `qnorm`, og indsæt

$(y-100)/15 = \text{qnorm}(0.9586553)$

Isoler y

$y = 15 * \text{qnorm}(0.9586553) + 100$

Normalområde - en eksamensopgave

“Summariske regnestørrelser” for plasma magnesium er givet. Og vi får lov at antage at det er normalfordelt for de to populationer stikprøverne er trukket:

A tibble: 2 × 4 gruppe Antal Gennemsnit Spredning
1 Diabetikere 227 0.719 0.068
2 Ikke-diabetikere 140 0.81 0.057
Beregn et interval, der indeholder 95% af målingerne for kontrol populationen (ikke-diabetikere).

$$0.81 + c(-1,1) \cdot 0.057$$

HVAD ER DET VI GØR MED $c(-1,1)$

Normalområde

Hvilken andel af målingerne i populationen af diabetikere vil ligge i det interval vi beregnede for ikke-diabetikerne?

Eller for: $X \sim N(0.719, 0.068)$ hvor mange ligger over værdien 0.7. og hvor mange ligger under 0.92?

$$\text{Eller: } P(0.7 < X < 0.92) = P(X < 0.92) - P(X < 0.7)$$

TAVLE!

Diabetikerne havde middel = 0.719 og spredning 0.068

Normaliser

$$P(X < 0.92) - P(X < 0.7)$$

$$P(Z < (0.92 - 0.719)/0.068) - P(Z < (0.7 - 0.719)/0.068)$$

```
pnorm((0.92-0.719)/0.068) - pnorm((0.7-0.719)/0.068)
```

```
[1] 0.6084767
```


Hypotesetests

Vi får oplyst “summeriske regnestørrelser” for plasma magnesium for diabetikere. Vi får lov at antage at plasma magnesium er normalfordelt for de to populationer stikprøverne er trukket fra:

gruppe Antal Gennemsnit Spredning Diabetikere 227 0.719 0.068 Ikke-diabetikere 140 0.810 0.057
Beregnet 95% konfidensinterval (KI) for hver af de to grupper.

Ja, det ligner noget vi har set før. Dengang skulle vi se på det interval der indeholdt 95% af observationer. Nu skal vi estimere to middelværdier.

SÅ NU SKAL VI BRUGE SEM!

$$SEM = \frac{sd}{\sqrt{n}}$$

```
SEM_dia <- 0.068/sqrt(227)
interval_dia <- 0.719 + c(-1,1)*1.96*SEM_dia
interval_dia
```

```
[1] 0.7101539 0.7278461
```

```
SEM_ikke <- 0.057/sqrt(140)
interval_non_dia <- 0.8100 + c(-1,1)*1.96*SEM_ikke
interval_non_dia
```

```
[1] 0.8005579 0.8194421
```

Er der forskel? Ja, for de to intervaller overlapper ikke. Og vigtigere, gennemsnittet for ikke-diabetikere er ikke indeholdt i intervallet for diabetikere, og omvendt.

Det er i hvert fald en konklusion de stiller sig tilfredse med i en modelbesvarelse. Det holder ikke helt (men er nu rigtigt alligevel). Vi kommer til den korrekte måde at teste det på.

Ændring i blodtryk

En gruppe patienter deles op i to, kontrol (318 patienter) og behandling (intervention, 323 patienter). Der måles blodtryk før behandling (baseline), og efter 12 måneders behandling. Forskellen i systolisk blodtryk mellem baseline og efter 12 måneder, oplyses som “diff”. For kontrolgruppen får vi oplyst at forskellen er -16.6 mmHg og spredningen er 19.9

For interventionsgruppen er de tilsvarende tal -19.6 og 17.4

Vi skal nu finde ud af om der er et signifikant fald i blodtrykket for interventionsgruppen.

Det ser jo ud til at det falder. Forskellen er -19.6, men er det signifikant? Kunne det tænkes at den sande middelværdi er 0?

Hvad er konfidensintervallet på forskellen?

For interventionsgruppen (323 patienter) : Fald: -19.6 Spredning: 17.4

```
SEM_intervention <- 17.4/sqrt(323)
```

Interval

```
-19.6 + c(-1,1)*1.96*SEM_intervention
```

```
[1] -21.4976 -17.7024
```

0 er ikke indeholdt. faldet er signifikant på et 5% niveau (95% konfidens).

For kontrollen

```
SEM_kontrol <- 19.9/sqrt(318)
```

Interval

```
-16.6 + c(-1,1)*1.96*SEM_kontrol
```

```
[1] -18.78724 -14.41276
```

Her er 0 heller ikke indeholdt. Faldet er signifikant.

Bredde af konfidensinterval

Vi får oplyst et konfidensinterval for fødselsvægte (g): [3561.5; 3583.4]. Beregnet baseret på 11279 kvinder.

Hvor meget bredere havde konfidensintervallet været, hvis vi kun havde haft data for 200 kvinder?

Hvad er det der styrer bredden? Ja, bredden er fra det nedre til det øvre. sd er ukendt. Men bredden er ækvivalent med kvadratroden af n

Så - bredden er 2 gange $1.96 \cdot \text{SEM}$

Eller ca. $4SEM$. Eller $4sd/\sqrt{11279}$

Nu går vi til 200 kvinder.

Så er bredden ca. $4*sd/\sqrt{200}$

Hvor meget bredere er det sidste end det første? TAVLE

```
sqrt(11279)/sqrt(200)
```

```
[1] 7.50966
```

Blodtrykssænkende

Vi undersøger effekten af et blodtrykssænkende præparat i sammenligning med placebo.

Vi får oplyst regnestørrelser for det systoliske blodtryk i mmHg for de to grupper:

A tibble: 2 × 4 Gruppe n gennemsnit spredning

1 Behandling 82 152.5 18.4

2 Placebo 90 156.5 19.1

Er der en signifikant forskel?

Hvad prøver vi at estimere?

Vi prøver at estimere en forskel Der er to grupper. De er ikke parrede

Hvad er diff?

```
152.5-156.5
```

```
[1] -4
```

hvad er SEM på den ene gruppe?

```
SEM_b <- 18.4/sqrt(82)  
SEM_b
```

```
[1] 2.03194
```

Og på den anden?

```
SEM_p <- 19.1/sqrt(90)
SEM_p
```

```
[1] 2.013317
```

Så den samlede SE er:

```
se_diff <- sqrt(SEM_b^2 + SEM_p^2)
se_diff
```

```
[1] 2.860459
```

Testværiden er så:

```
-4/se_diff
```

```
[1] -1.398377
```

Ikke signifikant.

Hvad med KI?

```
-4 + c(-1,1)*1.96*se_diff
```

```
[1] -9.606499  1.606499
```

Her ser vi også at det ikke er signifikant, da 0 er indeholdt. Det beregnede 95% KI indeholder med 95% sandsynlighed den sande forskel.

Videre - ønsket størrelse af konfidensinterval

TAVLE

Hvis $21.96SE = 8$, skal SE være lig $8/(2 \cdot 1.96)$

$$SE_{diff} = \sqrt{\left(\frac{s_0}{n_0}\right)^2 + \left(\frac{s_1}{n_1}\right)^2}$$

$$SE_{diff} = \sqrt{\left(\frac{s_0}{n_0}\right)^2 + \left(\frac{s_1}{n_1}\right)^2}$$

Indsæt $n_0 = 2n_1$

$$SE_{diff} = \sqrt{\left(\frac{s_0}{2n_1}\right)^2 + \left(\frac{s_1}{n_1}\right)^2}$$

Indsæt resten

$$4/1.96 = \sqrt{\left(\frac{19.1}{2n_1}\right)^2 + \left(\frac{18.4}{n_1}\right)^2}$$

$$(4/1.96)^2 = \frac{19.1^2}{2n_1^2} + \left(\frac{18.4}{n_1}\right)^2$$

$$(4/1.96)^2 = \frac{19.1^2}{4n_1^2} + \frac{18.4^2}{n_1^2}$$

Endnu en eksamensopgave

Antag at fordelingen af hæmoglobin(koncentrationen) i en population er normalfordelt, med $\mu = 13.3$ g/100 ml. Spredning $\sigma = 1.12$ g/100 ml.

Vi udtager stikprøver af størrelsen n . For hver stikprøve beregnes stikprøvegennemsnittet. Disse stikprøvegennemsnit er normalfordelte med middelværdi μ (hvis vi udtager uendeligt mange stikprøver)

Hvad er spredningen i fordelingen af stikprøvegennemsnittene?

Det er SEM. Den beregner vi ved $\frac{\sigma}{\sqrt{n}}$

Hvis vi sætter n til 15, hvilken andel af stikprøverne vil ligge mellem 13.0 og 13.6 g/100ml?

Vi skal ikke bruge sd, det er SEM for det er andelen af stikprøverne!

$$= 13.3$$

$$= 1.12$$

$$P(13.0 < X < 13.6)$$

$$P(X < 13.6) - P(X < 13.0)$$

$$P(Z < (13.6 - 13.3)/SEM) - P(Z < (13 - 13.3)/SEM)$$

$$SEM = 1.12/\sqrt{15}$$

svaret er ca 70%

Resten af opgaven

Hvor stor skal n være hvis 95% af stikprøverne skal have et snit der ligger mellem -0.2 og $+0.2$

$$\mu \pm 1.96SEM$$

$$\text{Så } 1.96SEM = 0.2$$

$$1.96 \cdot \sigma = 0.2 \sqrt{n}$$

Hoppeksamensopgave

Man har undersøgt 249 børn for hvor langt de kan hoppe. Der er følgende variable i datasættet:

idnr: løbenummer for personen gender: Køn, 1 dreng, 2 pige age: barnets alder height: barnets højde i cm cohR: Længde af hop på højre ben (cm) cohL: Længde af hop på venstre ben (cm) diff: forskel på cohR og cohL

Vi får også oplyst de første fire observationer:

A tibble: 4 × 7 idnr gender age height cohR cohL diff

1 1 1 10 148.2 185.9 207.3 -21.4

2 2 2 9 136.2 257.4 223 34.4

3 3 1 9 139.4 203.5 250.3 -46.8

4 4 2 9 137.6 347 388.4 -41.4

Og noget summarisk data: >mean(cohR) 270.441 >mean(cohL) 265.3871 >mean(diff) 5.053815
 >sd(cohR) 74.69524 >sd(cohL) 79.73807 >sd(diff) 37.87201

Er der overordnet forskel på hoppelængde på højre og venstre ben?

Hop videre

$$SEM = sd_diff / \sqrt{n}$$

$$\text{testværdi } 5.05381 / SEM$$

Sidste Hop - for denne gang Gennemsnit og spredning for diff for pigerne beregnes til hhv 12.51 og 36.15

Når Berit hopper 250 cm på højre ben, men kun 200 cm på venstre ben er der så grund til at tro at der er noget galt med hendes venstre ben?

normalområdet er så

$12.51 \pm 1.96 \cdot SE$

for forskellen.

Berits forskel er 50 cm. Det er indenfor normalområde.

Diabetikere - fra et interval til et andet

Vi får oplyst data for 18 tilfældigt valgte insulin-afhængige diabetikere. Data er procent af ideelvægt. 95 betyder at pågældende individ fjer 5% mindre end ideelvægten. 120 beetyder at vedkommende vejer 20% mere end ideelvægten.

```
c(107,119,99,114,120,104,88,114,124,116,101,121,152,100,125,114,95,117) |> sd()
```

```
[1] 14.42447
```

Vi får oplyst at et 90% reference interval kan beregnes til (89.1; 136.5)

a. Beregn et 95% konfidensinterval for den sande middelfrocent af ideelvægt.

Et referenceinterval er centreret om middelværdien. Så middel finder vi ved: $(89.1+136.5)/2 = 112.8$

Så skal vi finde spredningen. Det er et 90% interval. så den kvantil der er brugt er ikke 95% kvantilen (1.96), men 90% kvantilen:

```
qnorm(0.95)
```

```
[1] 1.644854
```

0.95 i stedet for 0.975 fordi der skal være 5% på hver side, ikke 2.5%

Intervallet er $\pm$ på hver side af middelværdien så: $136.5-112.8 = 1.644854 \cdot s \rightarrow s = (136.5-112.8)/1.644854 = 14.4$

Så ved vi hvad standardafvigelsen er på data. Nu skal vi have konfidensintervallet på middelværdien - så vi skal bruge SEM:

$14.4/\sqrt{18} = 3.394113$

Og så finder vi konfidensintervallet ved: $112.8 + c(-1,1)1.9614.4/\sqrt{18}$

Og her er der altså en regnefejl i modelløsningen...

- b. Indeholder det konfidensinterval vi har beregnet 100%? Hvad fortæller svaret på det spørgsmål? Angiv relevant nullhypotese, samt eventuelt relevant estimat.

fra a ser vi at 95% konfidensintervallet ikke indeholder 100 - så vi må afvise nullhypotesen $H_0: \mu = 100$, hvor μ angiver den sande middelfrocent af idealvægt for populationen af insulin-afhængige diabetikere. Estimatet for μ er 112.8 med et 95% KI på det vi tidligere beregnede.

Danske og polske piger

Histogrammerne

```
library(tidyverse)

set.seed(47)

n <- 100

# højreskæv
right_skew <- rgamma(n, shape = 2, scale = 2)

# venstreskæv (spejlet højreskæv)
left_skew <- max(right_skew) - right_skew

# tilnærmelsesvist normal
normal <- rnorm(n, mean = 10, sd = 2)

# log-transformerede
log_right <- log(right_skew)
log_left <- log(max(left_skew) + 1 - left_skew)

df <- tibble(
  value = c(right_skew, left_skew, normal, log_right, log_left),
  type = rep(
    c(
      "Højreskæv",
      "Venstreskæv",
      "Tilnærmelsesvist normal",
      "Log(højreskæv)",
      "Log(venstreskæv)"
    ),
    each = n
  )
)
```




```

    each = n
  )
)

ggplot(df, aes(x = value)) +
  geom_histogram(bins = 10, fill = "steelblue", color = "white") +
  facet_wrap(~type, scales = "free") +
  theme_minimal()

```



Ud over at vi nok vil blive bedt om at forholde os til hvor gennemsnittene sådan på øjemål ligger, og om der er mere eller mindre spredning i den ene frem for den anden. Så skal vi kunne fortælle at “denne er højreskæv” “denne er venstreskæv” og de log-transformerede data er tilnærmelsesvist normalfordelte.

Danske og polske piger

Vi skal se på data fra en undersøgelse af D-vitaminniveauet for danske og polske piger.

Vi får følgende log-transformerede data oplyst:

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61 Beregn variationen på gennemsnittene (SEM) for det log-transformerede D-vitaminniveau for hhv de danske og

polske piger. Vi får, om logtransformerede data oplyst; Danske piger: $\log(\text{D-vitaminniveau})$
gennemsnit: 3.211 sd = 0.492 n = 59

Polske piger: $\log(\text{D-vitaminniveau})$ gennemsnit: 3.389 sd = 0.418 n = 61

Beregn variationen på gennemsnittene for det log-transformerede D-vitaminniveau for hhv de danske og polske piger.

Danske: $0.495/\sqrt{59}$ polske: $0.418/\sqrt{61}$

Danske og polske piger

Beregn 95% KI for de danske og polske piger separat. Hvordan fortolker vi resultaterne? Kan vi konkludere noget om forskellen i D-vitaminniveau mellem de danske og polske piger? Er den signifikant?

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61 Givet

$SEM = s/\sqrt{n}$

Hvordan beregner vi så et 95% KI?

- c) Beregn 95% KI for de danske og polske piger separat. Hvordan fortolker vi resultaterne? Kan vi konkludere noget om forskellen i D-vitaminniveau mellem de danske og polske piger? Er den signifikant?

danske:

```
3.211 + c(-1,1)*1.96*0.495/sqrt(59)
```

```
[1] 3.084691 3.337309
```

```
3.389 + c(-1,1)*1.96*0.418/sqrt(61)
```

```
[1] 3.284102 3.493898
```

Hvert KI indeholder med 95% sandsynlighed den sande værdi for den log-transformerede D-vitaminkoncentration for de to grupper. Intervallerne overlapper, men ingen af de to gennemsnit ligger i det andet KI, og vi kan derfor ikke konkludere om der er en signifikant forskel.

Danske og polske piger

Udregn teststørrelsen for den approksimative t-test for sammenligning af log(D-vitaminniveau). Brug de beregnede variationer på gennemsnittene. Brug teststørrelsen til at konkludere om forskellen på D-vitaminniveauet er statistisk signifikant på et 5% niveau.

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61

forskel:

```
diff <- 3.21-3.389
```

samlet SEM

```
SEM_samlet <- sqrt((0.495/sqrt(59))^2 + (0.418/sqrt(61))^2)
```

Testværdien:

```
diff/SEM_samlet
```

```
[1] -2.136821
```

Testværdien er større end 1.96 (i absolutte værdier). Og forskellen er derfor signifikant.

p-værdi:

```
2*pt(diff/SEM_samlet, 59+61)
```

```
[1] 0.03464261
```

Og der skal ganges med to...

Danske og polske piger

Vi får nu at vide at vi kan beskrive $\log(\text{D-vitaminniveau})$ i begge lande ved en normalfordeling. Beregn et 95% reference interval for $\log(\text{D-vit})$ for danske piger.

Hvordan beregner vi referenceintervallet?

± 1.96

Skal vi bruge SEM?

Nej, for nu antager vi at tallene er normalfordelte.

Land Gennemsnit Spredning n DK 3.211 0.492 59 PO 3.389 0.418 61

Det danske referenceinterval:

```
3.211+c(-1,1)*1.96*0.492
```

```
[1] 2.24668 4.17532
```

Danske og polske piger

TAVLE Brug derefter og for de polske piger til at beregne hvor stor en andel af dem der forventes at ligge inden for det danske referenceinterval.

Hvis referenceintervallet for de danske piger er [nedre, øvre], hvordan finder vi andelen af polske piger der ligger inden for det?

Hvis X er normalfordelt med middelværdi 3.389 og spredning 0.418, skal vi beregne: $P(2.24668 < X < 4.17532) \Leftrightarrow P(X < 4.17532) - P(X < 2.24668)$

Vi kan bruge `pnorm` direkte (cowboytricket)

```
pnorm(4.17532, 3.389, 0.418) - pnorm(2.24668, 3.389, 0.418)
```

```
[1] 0.9668844
```

Eller vi kan standardisere så vi kan bruge standardnormalfordelingen.

Kategorisk

En opgave

Vi skal se på prævalensen af tuberkulose blandt stiknarkomaner og om den er afhængig af om der deles sprøjter med andre narkomaner. I en gruppe med 97 narkomaner der deler sprøjte med andre narkomaner, testede 24.7% positiv for TB. I en gruppe på 161 narkomaner der ikke delte sprøjte, testede 17.4% positive for TB.

Hvis vi antager at prævalensen ikke afhænger af om der deles sprøjter - hvad estimerer vi så prævalensen til at være?

ja så er det alle tb positive divideret med alle.

Antal positive:

$$0.247 \cdot 97 + 0.174 \cdot 161$$

$$[1] \ 51.973$$

vi regner med 52...

Og hvor mange var der ialt? $161 + 97$

Så andelen er

$$52/258$$

$$[1] \ 0.2015504$$

Hvor sikker var vi?

Hvad er et 95% KI for prævalensen af TB blandt stiknarkomaner, hvis vi antager at den ikke afhænger af om man deler sprøjte eller ej?

Proportionen beregnede vi til 0.2015504

Standardfejlen er givet ved:

$$SE_{prop} = \sqrt{\frac{p(1-p)}{n}}$$

Der var 258 observationer i stikprøven

estimat ± 1.96 SE

```
prop <- 0.2015504
se_prop <- sqrt((prop*(1-prop)/285))
se_prop
```

```
[1] 0.02376256
```

```
prop + c(-1,1)*1.96*se_prop
```

```
[1] 0.1549758 0.2481250
```

Så kan vi regne

Prævalens af TB blandt de 97 der delte sprøjter: 24.7% Prævalens af TB blandt de 161 der ikke delte sprøjter: 17.4%

```
SE_deler <- sqrt(0.247*(1-0.247)/97)
SE_deler_ikke <- sqrt(0.174*(1-0.174)/161)
SE_diff <- sqrt(SE_deler^2 + SE_deler_ikke^2)
dif <- 0.247-0.174
test <- dif/SE_diff
test
```

```
[1] 1.377082
```

Modelbesvarelsen bytter om på 161 og 97 i beregningen af SE, og giver derfor en forkert testværdi. Men dog samme konklusion.

Ved et 5% signifikansniveau (kritisk værdi 1.96) er testværdien 1.38 mindre end den kritiske værdi. Vi kan derfor *ikke* forkaste nullhypotesen, $H_0 : p_{deler} - p_{deler_{ikke}} = 0$ og konkluderer at der i data ikke er evidens for den alternative hypotese, at der skulle være forskel i prævalens for de to grupper.

Forholdet mellem de to prævalenser RR

og så er vi ca. klar til at regne

Hvordan finder vi tabellen?

```
0.247*97
```

```
[1] 23.959
```

```
97-0.247*97
```

```
[1] 73.041
```

```
0.174*161
```

```
[1] 28.014
```

```
161-0.174*161
```

```
[1] 132.986
```

Konklusionen bliver den samme uanset om vi dividerer den ene risiko med den anden eller omvendt. Men tolkningen af resultatet vil være forskellig.

```
SE_log_rr <- sqrt(1/24 - 1/(24+73) + 1/28 - 1/(28+133))
risk_deler <- 24/(24+73)
risk_deler_ikke <- 28/(28+133)
rr <- risk_deler/risk_deler_ikke
testværdi <- log(rr)/SE_log_rr
ki_log <- log(rr) + c(-1,1)*1.96*SE_log_rr
ki <- exp(ki_log)
```

Vi estimerer at RR er 1.42, hvilket svarer til at de der deler sprøjter har ca. 42% højere risiko for TB end de der ikke deler sprøjter. Vi finder et 95% konfidens interval til [0.8772285, 2.3072887]. Da 1 er indeholdt i intervallet, kan vi ikke afvise H_0 på et 5% signifikansniveau. Null-hypotesen var $H_0 : RR = 1$. Alternativt finder vi testværdien til at være ca 1.43 hvilket er mindre end den kritiske værdi 1.96 ved et 5% signifikansniveau. Vi kan derfor ikke forkaste H_0 , og må også på denne baggrund konkludere at der ikke i data er evidens for forskel i prævalensen for TB mellem de to grupper.

Odds-ratio

```

odds_deler <- 24/73
odds_deler_ikke <- 28/133
OR <- odds_deler/odds_deler_ikke
SE_log_OR <- sqrt(1/24 + 1/73 + 1/28 + 1/133)
test_værdi <- log(OR)/SE_log_OR
KI_log_OR <- log(OR) + c(-1,1)*1.96*SE_log_OR
KI_OR <- exp(KI_log_OR)

```

χ^2

```

tab <- matrix(
  c(24, 73,
    28, 133),
  nrow = 2,
  byrow = TRUE
)

dimnames(tab) <- list(
  Exposure = c("Deler", "Deler_ikke"),
  TB = c("Ja", "Nej")
)

chisq.test(tab, correct = FALSE)

```

Pearson's Chi-squared test

```

data:  tab
X-squared = 2.0325, df = 1, p-value = 0.154

```

p-værdien er 0.154. p-værdien er sandsynligheden for at

For tidlig fødsel

Et studie i England undersøgte faktorer for tidlig fødsel blandt gravide kvinder og fandt at incidensen for tidlig fødsel var 7.5% blandt de 1513 kvinder der var med i studiet.

Beregn 95% KI for insidensen for tidlig fødsel baseret på disse tal. $\text{phat}(E) = 0.075$. $\text{se}(\text{phate}) = \sqrt{p(1-p)/n} = \sqrt{0.075(1-0.075)/1513}$


```
se_gb <- sqrt(0.075*(1-0.075)/1513)
se_gb
```

```
[1] 0.006771456
```

Der er et 0 for lidt i modelbesvarelsen...

```
0.075+c(-1,1)*1.96*sqrt(0.075*(1-0.075)/1513)
```

```
[1] 0.06172795 0.08827205
```

For tidlig fødsel

- b) Et tilsvarende studie i Danmark fandt en incidens på 4.5% blandt 51851 kvinder der deltog. Estimer forskellen i incidensen for tidlig fødsel i England vs Danmark. Er der signifikant forskel?

forskel:

```
diff <- 0.075-0.045
diff
```

```
[1] 0.03
```

se_dk:

```
se_dk <- sqrt(0.045*(1-0.045)/51851)
```

```
se_diff <- sqrt(se_dk^2 + se_gb^2)
se_diff
```

```
[1] 0.006832381
```

et 95% ki for diffen:

```
diff + c(-1,1)*1.96*se_diff
```

```
[1] 0.01660853 0.04339147
```

Intervaller indeholder *ikke* 0, og vi kan konkludere at der er en statistisk signifikant forskel.

Lineær regression

Fedme og blodtryk

Vi skal se på sammenhængen mellem blodtryk og fedme. Vi får oplyst at der er et datasæt med 102 individer, 44 mænd, 58 kvinder.

Der er variabler:

KØN (1=kvinde, 0= mand)

FEDME: Fedmegrad - vægt i forhold til ideelvægt. 1.2 betyder at man vejer 20% mere end man burde. Svarende til 120% af ideelvægten

BLODTRYK: Systolisk blodtryk (i mmHg)

De første 6 observationer, og nogle deskriptive størrelser:

```
KØN FEDME BLODTRYK
```

```
1 0 1.31 130
```

```
2 0 1.31 148
```

```
3 0 1.19 146
```

```
4 0 1.11 122
```

```
5 0 1.34 140
```

```
6 0 1.17 146
```

```
mean(BLODTRYK[KØN==0]) 127.9545
```

```
mean(BLODTRYK[KØN==1]) 126.3103
```

```
sd(BLODTRYK[KØN==0]) 16.59077
```

```
sd(BLODTRYK[KØN==1]) 19.41893
```

Reference interval for blodtykket for kvinder.

```
126.3103 + c(-1,1)*1.96*19.41893
```

```
[1] 88.2492 164.3714
```

Fedme og blodtryk - t-test

```
SEM_m <- 16.59077/sqrt(44)
SEM_f <- 19.41893/sqrt(58)
SE_diff <- sqrt(SEM_m^2 + SEM_f^2)
diff <- 127.9545-126.3103
test_value <- diff/SE_diff
```

Det vil jeres eksaminatorer som regel kalde “klart signifikant”. Hardcore statistiskere vil sige at der ikke er noget der hedder “klart signifikant”. Det er signifikant. Eller også er det ikke signifikant. Og det kan det så være på forskellige niveauer.

Fedme og blodtryk - manglende estimat

Køn:

```
-7.730/3.715
```

```
[1] -2.080754
```

Det er statistisk signifikant (på et 5% niveau)

FEDME:

```
7.172*4.049
```

```
[1] 29.03943
```

Er det signifikant?

Hoppemålinger genbesøgt

```
intercept <- -3.775 + c(-1,1)*1.96*3.471
factor_gender <- 16.283+c(-1,1)*1.96*4.714
```

Drenge - hormoner - prediktion

- c. Prædikter (forudsig) hormonniveauet for en dreng på 6 år med et BMI på 17 og for en dreng på 14 med et BMI på 18.

Det finder vi ved: Den 6-årige: $5.40 + 0.058 \cdot 17$

for den 14-årige $5.40 + 0.229 + 0.058 \cdot 18$

transplanteret lungevolumen

```
1.279024/(0.9411598/sqrt(426))
```

```
[1] 28.04918
```

Det er større end 1.96, så statistisk signifikant (nogen føler trang til at sige “klart signifikant”)

transplanteret lungevolumen - fortolk

Fortolk værdierne i søjlen “Estimate”. Beregn tilhørende 95% KI

Intercept er den estimerede ændring i lungefunktion (før vs efter transplantation) for patienter med en donor som var ikke-ryger. Den estimerede ændring er i gennemsnit 1.3697, med et 95% KI på:

```
1.36970 + c(-1,1)*1.96*0.06646
```

```
[1] 1.239438 1.499962
```

Forbedringen i lungefunktion er lidt mindre for patienter med en donor som var ryger (eller ex-ryger). Forbedringen estimeres til i gennemsnit at være 0.19092 laverem, med det tilhørende 95% KI på:

```
-0.19092+c(-1,1)*1.96*0.09644
```

```
[1] -0.3799424 -0.0018976
```

Leversygdom

```
sem_0 <- 0.289/sqrt(167)
sem_1 <- 0.358/sqrt(416)
se_diff <- sqrt(sem_0^2 + sem_1^2)
diff <- -0.011--0.152
diff/se_diff
```

```
[1] 4.959711
```

det er klart signifikant (den er næsten fem standardafvigelser fra 0). der er en signifikant lavere l_ratio blandt de syge.

Leversygdom - kønsfordeling

```
# Sandsynligheden for at være kvinde blandt de raske:
p_0 = 50/(50+117)
p_0
```

```
[1] 0.2994012
```

```
# Sandsynligheden for at være kvinde blandt de syge:
p_1 = 92/(92+324)
p_1
```

```
[1] 0.2211538
```

```
se_0 <- sqrt(0.2994012*(1-0.2994012)/(50+117))
se_0
```

```
[1] 0.03544078
```

```
se_1 <- sqrt(0.2211538*(1-0.2211538)/(92+324))
se_1
```

```
[1] 0.02034822
```

Er den sande værdi af forskellen på de to andele (af kvinder i hhv syg og rask-grupperne) i virkeligheden 0? samlet se

```
se_p <- sqrt(se_0^2 + se_1^2)
se_p
```

```
[1] 0.04086684
```

Og så testværdien:

```
diff <- 0.2994012-0.2211538
diff/se_p
```

```
[1] 1.914692
```

Og det er så ikke signifikant. Null-hypotesen var at der ikke var forskel. Den kan vi ikke forkaste.

Leversygdom - aldersfordeling

Er aldersfordelingen den samme for syge som for raske?

two-sample t-test. så er forskellen på gennemsnitlig alder forskellig fra 0? Her nævnte eksamensspørgsmålet specifikt at man blot skulle forklare hvad man ville gøre - man skulle ikke regne.

```
diff <- 46.2-41.2
sem_0 <- 17.0/sqrt(167)
sem_1 <- 15.7/sqrt(416)
sem_diff <- sqrt(sem_0^2 + sem_1^2)
diff/sem_diff
```

```
[1] 3.280496
```

Vi kan afvise 0-hypotesen

Leversygdom - prediktion

predikter median-ratio for de syge i studiepopulationen med en alder på 50 år, som er kvinder. vores estimat på en middelværdi for l_ration - som altså er log er:

```
0.1730998+-0.1196883+50*-0.0045177
```

```
[1] -0.1724735
```

Og så skal vi eksponentiere:

```
exp(-0.17)
```

```
[1] 0.8436648
```

Blodtryk i Ghana

Er der et signifikant fald i blodtrykket i interventionsgruppen i den undersøgte periode. Besvar samme spørgsmål for kontrolgruppen.

Vi starter med SEM for de to grupper: Intervention: $n = 323$

```
SEM_intervention <- 17.4/sqrt(323)
```

```
SEM_kontrol <- 19.9/sqrt(641-323)
```

Så kan vi beregne 95% KI beregnes for de to grupper:

intervention:

```
-19.6+c(-1,1)*1.96*SEM_intervention
```

```
[1] -21.4976 -17.7024
```

kontrol:

```
-16.6+c(-1,1)*1.96*SEM_kontrol
```

```
[1] -18.78724 -14.41276
```

Ingen af de to KI indeholder 0, så vi kan konkludere at begge behandlinger sænker det systoliske blodtryk signifikant.

Blodtryk i Ghana

Er faldet i blodtryk signifikant forskelligt i de to grupper? hvad kan vi konkludere vedrørende effekten af præcisionsbehandlingen på blodtrykket på baggrund af de beregninger vi har udført indtil videre?

```
SEM_diff <- sqrt(SEM_intervention^2 + SEM_kontrol^2)
```

Det giver os en teststørrelse på forskellen på de to differenser på:

```
(-19.6- -16.6)/SEM_diff
```

```
[1] -2.030622
```

Som (i absolutte tal) er større end 1.96 - der er en signifikant forskel.

Blodtryk i Ghana

- c) Nu udførtes følgende analyser for mænd og kvinder hver for sig: `> summary(lm(diff[sex=="female"]~factor(group[sex=="female"])))` Hvilke analyser er der tale om, og hvad kan vi konkludere på baggrund af disse? Der ønskes en fortolkning af værdierne i "Estimate" søjlerne. Giver det anledning til en anden konklusion end den vi fik lige før?

Der er tale om to multiple lineære regressioner, med diff som kontinuert responsvariabel og group som forklarende, kategorisk (og binær) variabel.

For kvinderne ser vi at blodtrykket i gennemsnit falder med ca 17 mmHg under kontrolbehandling (signifikant, med $p \sim 0$), og yderligere ca 6 mmHg ved præcisionsbehandlingen (signifikant med $p = 0.002$)

For mændene ser vi at blodtrykket i gennemsnit falder med ca. 16 mmHg under kontrolbehandling, men at der ikke er signifikant forskel på effekten af de to behandlinger ($p=0.456$)

Logistisk

Hvordan ser resultatet ud?

Vi skal lave et regnestykke der illustrerer sammenhængen mellem estimat, fejl og z value

Hvor sikre er vi på de estimerer?

```
0.7423 + c(-1,1)*1.96*0.2149
```

```
[1] 0.321096 1.163504
```

```
exp(0.7423)
```

```
[1] 2.100762
```

```
exp(0.7423 + c(-1,1)*1.96*0.2149)
```

```
[1] 1.378638 3.201130
```

Så - vores estimat er at en stigning i alder på 10 år er associeret med 2.1 gange højere odds. Og et konfidensinterval på det estimat mellem 38% og 220% højere odds.

Rygende donorer - regne

For død inden for tre år Ikke-rygerdonor

```
p_NS <- 68/(68+153)
```

rygerdonor

```
p_SM <- 117/(117+153)
```

```
(RR <- p_SM/p_NS)
```

```
[1] 1.408333
```

Og det er smoker divideret med non-smoker fordi vi ser på den øgede risiko for død hvis donor har været ryger.

1.4 gange højere risiko for død inden for tre år - sammenlignet med hvis donor ikke havde været ryger.

```
(se_log_rr <- sqrt(1/68 - 1/(153+68) + 1/88 - 1/(88+117)))
```

```
[1] 0.1290991
```

KI for log(RR)

```
(KI_log_rr <- log(RR) + c(-1,1)*1.96*se_log_rr)
```

```
[1] 0.08937269 0.59544125
```

Og KI for RR

```
exp(KI_log_rr)
```

```
[1] 1.093488 1.813831
```

1 er ikke indeholdt - så signifikant sammenhæng.

Rygende donorer - regressionen

Vi kan konkludere at der er signifikant effekt af begge forklarende variable, rygestatus for donor og alderskategorien for donor.

SMOKE har en OR på

```
exp(0.5751)
```

```
[1] 1.777308
```

KI:

```
exp(0.575 + c(-1,1)*1.96*0.21)
```

```
[1] 1.177508 2.682100
```

det tilhørende konfidensinterval finder vi ved: $\exp(0.575 + c(-1,1)1.960.21)$

dvs 1.77 gange højere odds for at dø inden for 3 år efter transplatation sammen lignet med ikkeryger donor (og fastholdt donoralder). KI indeholder ikke 1, og det er signifikant.

donoralder. Her har vi to. OR_40-55

```
exp(0.444)
```

```
[1] 1.55893
```

og KI:

```
exp(0.444 + c(-1,1)*1.96*0.2527)
```

```
[1] 0.9500012 2.5581696
```

og OR_56

```
exp(0.9395)
```

```
[1] 2.558702
```

KI

```
exp(0.9395 + c(-1,1)*1.96*0.2891)
```

```
[1] 1.451887 4.509273
```

Dvs 1.55 gange højere odds for at dø indenfor 3 år efter transplantation for en patient med en donor der var 40-55 sammenlignet med en donoer der var under 40. Ved fastholdt rygestatus for donor. KI indeholder 1, og er derfor ikke signifikant.

og 2.56 gange højere odds for at dø indenfor 3 år efter transplatatione for en patient med en donor der var over 56, sammenlignet med en donor der var under 40. Ved fastholdt rygestatus for donor. KI indeholder ikke 1, og er derfor signifikant.

rygende donorer endeligt regnestykke

```
exp(-1.2848)/(1+exp(-1.2848))
```

```
[1] 0.2167343
```

Det I skal opdage her er at vi har omregningen fra odds til sandsynlighed!

Hvordan fortolker vi det tal?

-1.2848 er estimatet på intercept.

Det var for referencegruppen. Den patientgruppe der har fået lunger fra en donor under 40 år, der var ikke ryger.

Hvad er det så vi beregner?

$\exp(-1.2848)$ går fra

Log Odds(ratio) til:

Odds

Og brøken giver?

Den går fra odds til sandsynlighed - så vi får?

Den estimerede sandsynlighed for at dø inden for 3 år, for den patientgruppe der fik lunger fra en donor under 40, der var ikke-ryger.

DTP-vaccine umiddelbar sammenhæng?

Ser det umiddelbart ud til at der er en sammenhæng mellem dødeligheden og vaccinstatus?

Sandsynlighed for død ved de to vaccine-statuser

```
(p_0 <- 9/(526+9))
```

```
[1] 0.01682243
```

```
(p_1 <- 46/(46+892))
```

```
[1] 0.04904051
```

RR

```
(RR <- p_1/p_0)
```

```
[1] 2.915186
```

Det vil sige ca. 2.9 gange så høj risiko for død. Ved vaccine!

SE-log-rr

```
(SE_log_rr <- sqrt(1/9 - 1/(9+526) + 1/46 - 1/(46+892)))
```

```
[1] 0.3604372
```

testværdien

```
log(RR)/SE_log_rr
```

```
[1] 2.968433
```

Resultatet er derfor statistisk signifikant på et 5% niveau. Vi kan nok også beregne et KI på RR

DTP-vaccine

OR for effekten af vaccinstatus estimeres til

```
exp(0.0261)
```

```
[1] 1.026444
```

Med et KI på:

```
exp(0.0261 + c(-1,1)*1.96*0.0116)
```

```
[1] 1.003370 1.050048
```

Vaccinerede har ca. 2.6% højere odds for død end ikke-vaccinerede

Glykæmisk kontrol

Baseret på den tabel - er der sammenhæng mellem de to variable?

Hvad er den relative risiko for at have godt helbred hvis HbA1c er 1 - altså velreguleret.

```
(R_velreg <- 188/(188+264))
```

```
[1] 0.4159292
```

```
(R_ejreg <- 354/(354+412))
```

```
[1] 0.462141
```

```
(RR <- R_velreg/R_ejreg)
```

```
[1] 0.900005
```

Så - den relative risiko for at have et godt selvvalueret helbred er reduceret for diabetikere under glykæmisk kontrol, sammenlignet med diabetere der ikke er under glykæmisk kontrol.

Det er kontraintuitivt for ikke-medicineren her.

glykæmisk kontrol - Er det signifikant?

se_log_rr

```
(se_log_rr <- sqrt(1/188 - 1/(188+264) + 1/354 - 1/(354+412)))
```

```
[1] 0.0680157
```

Så KI er

```
log_ki <- log(RR) + c(-1,1)*1.96*se_log_rr  
exp(log_ki)
```

```
[1] 0.7876781 1.0283502
```

1 er indeholdt i intervallet, og estimatet på RR er derfor ikke signifikant.

Glykæmisk kontrol - model

Glykæmisk kontrol har vi allerede regnet på.

Køn. OR

```
exp(0.252051)
```

```
[1] 1.286662
```

Mandlige diabetikere har derfor 28% større odds for godt helbred (selvrapporteret) sammenlignet med kvindelige diabetikere, og et KI på med alder og HbA1C fastholdt:

```
exp(0.252051 + c(-1,1)*1.96*0.117514)
```

```
[1] 1.021961 1.619923
```

Alder, der også var statistisk signifikant (p-værdien)

OR:

```
exp(-0.015573)
```

```
[1] 0.9845476
```

ved fastholdt køn og HbA1C. ca. 1.2% reduceret odds for selvrapporteret godt helbred for hver øgning af alder med 1 år

Ved fastholdt køn og hbA1c

Hvis vi ønsker hvad det er for eg 5 år, skal der ganges med 5 på både estimatet og standardfejlen

@@@ ## Laparotomi

Vi ser på data fra ca 1000 patienters risiko for at dø ved en operation (laparotomi). Har øget ilt-tilførsel under operationen betydning for død i en opfølgingsperiode på ca. 3 år. Patienterne blev randomiseret til et af to ilt-regimer

Vi har følgende variable Allokering: X - patient fik 80% ilt, Y Patient fik 30% ilt diagn_cancer: j: cancer, n: ikke cancer blod: j perioperativ blodtransfusion, n ikke perioperativ blodtransfusion bmi: patientens BMI dead: 1 patienten dør i løbet af opfølgingsperioden, 0 patienten overlever

De første 6 observationer:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.007041	0.386263	-0.018	0.98546
bmi		0.015385	-3.151	

```
head(ilt_data)
```

```
# A tibble: 6 x 5
  Allokering diagn_cancer blod    bmi  dead
  <chr>      <chr>      <chr> <dbl> <dbl>
1 Y         n          n    29.3    0
2 X         n          n    28.1    0
3 X         j          n    21.5    1
4 X         j          n    17.3    1
5 Y         n          n    24.2    0
6 Y         n          n    18.2    0
```

- Hvis vi alene betragter patienternes bmi, hvordan ville vi så undersøge om den har signifikant betydning for risikoen for død efter operation. Outcome - dead er binær og bmi er kontinuert. Så vi vil modellere et kategorisk outcome med kontinuert forklarende variabel: logistisk regression
- Når vi gør det, får vi følgende resultat (de fortsætter deres juleleg med at fjerne dele af output):

Hvad kan vi sige ud fra det?

Vi mangler et estimat for bmi. Det kan vi beregne, fordi z-value finder vi ved at dividere estimatet med standardfejlen. Derfor kan vi finde estimatet ved at gange standardfejl med z value.

```
-3.151*0.015385
```

```
[1] -0.04847813
```

Teststørrelsen er klart signifikant

```
2*pnorm(-3.151)
```

```
[1] 0.001627125
```


Vi kan beregne OR:

```
exp(-0.04847813)
```

```
[1] 0.9526782
```

Så holdes alt andet konstant, vil en patient med et bmi der er 1 større end en anden patient, have vil odds for død reduceres med ca 5% for patienten med det højeste bmi.

Vi kan beregne et 95% KI:

```
exp(-0.04847813 + c(-1,1)*1.96*0.015385)
```

```
[1] 0.9243794 0.9818433
```

1 er ikke indeholdt i intervallet, og forskellen er derfor signifikant. Det så vi også fra p-værdien vi beregnede tidligere.

c) Nu ser vi bort fra bmi, og betragter ilt-allokering.

```
table(dead,Allokering)
```

```
      Allokering  
dead   X     Y  
  0  414  418  
  1  139  107
```

Hvad kan vi konkludere ud fra det?

Vi sammenligner død (1) for de to ilt-regimer X og Y: $\text{odds}_X = 139/414 = 0.3357488$ $P_Y = 107/418 = 0.2559809$

$\text{OR}(X \text{ mod } Y) = 0.3357488/0.2559809 = 1.311617$ dvs at odds for at dø estimeres at være ca. 31% højere ved det høje ilt-regime, sammenlignet med det lave (alt andet fastholdt)

95% KI: standardfejlen på $\log(\text{OR})$: $\sqrt{1/139 + 1/414 + 1/107 + 1/418} = 0.146109$

```
exp(log(1.311617) + c(-1,1)1.960.146109)
```

Det indeholder 1 og estimatet er derfor ikke statistisk signifikant (de er dog i modelbesvarelser glade for at nævne at det er tæt på at være signifikant)

BETON FORSKEL PÅ OR OG RR!

d) Tabellen deles nu op efter den opererede patients diagnose (cancer, ja,nej):

```
table(dead, Allokering, diagn_cancer)
```

```
, , diagn_cancer = j
```

	Allokering	
dead	X	Y
0	188	213
1	101	74

```
, , diagn_cancer = n
```

	Allokering	
dead	X	Y
0	226	205
1	38	33

Giver det anledning til at ændre den tidligere konklusion? Begnd med effektestimater og 95% konfidensintervaller.

Samme øvelse som før, men nu på hver gruppe: Cancerpatienter: $OR = (101/188) / (74/213) = 1.546363$ s.e. på $\log(OR)$: $\sqrt{1/101 + 1/188 + 1/74 + 1/213} = 0.1828346$ KI: $\exp(\log(1.546363) + c(-1,1)1.96 \cdot 0.1828346) = 1.080636 \text{ } 2.212806$

Så for cancerpatienter er odds for at dø ved det høje ilt regime ca 55% højere, med et KI som angivet. Signifikant, da 1 ikke er med i KI.

non-cancer-patienter:

$OR = (38/226) / (33/205) = 1.044516$ se på $\log(OR) = \sqrt{1/38 + 1/226 + 1/33 + 1/205} = 0.2567521$ KI: $\exp(\log(1.044516) + c(-1,1)1.96 \cdot 0.2567521) = 0.6314854 \text{ } 1.7276943$ Så odds er 1.04 gange større i det høje ilt-regime for ikke-cancerpatienter. Men det er ikke signifikant - for 1 er indeholdt i KI.

Så ilt-regime har betydning for cancerpatienter.

Levertal

583 personer er henvist til undersøgelse pga mistanke om leversygdom De første seks observationer:

```
library(tidyverse)
tribble(~age, ~albumin, ~ratio, ~globulin, ~status, ~idnr, ~sex, ~l_ratio,
65, 3.3, 0.90, 3.666667, 1, 1, "F", -0.1053605,
62, 3.2, 0.74, 4.324324, 1, 2, "M", -0.3011051,
62, 3.3, 0.89, 3.707865, 1, 3, "M", -0.1165338,
58, 3.4, 1.00, 3.400000, 1, 4, "M", 0,
72, 2.4, 0.4, 6, 1, 5, "M", -0.9162907,
46, 4.4, 1.3, 3.384615, 1, 6, "M", 0.2623643
)
```

```
# A tibble: 6 x 8
  age albumin ratio globulin status idnr sex l_ratio
<dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <chr> <dbl>
1    65    3.3  0.9    3.67      1     1 F   -0.105
2    62    3.2  0.74    4.32      1     2 M   -0.301
3    62    3.3  0.89    3.71      1     3 M   -0.117
4    58    3.4  1.00    3.4       1     4 M    0
5    72    2.4  0.4     6       1     5 M  -0.916
6    46    4.4  1.3    3.38      1     6 M   0.262
```

Variable: idnr: Løbenummer sex: Køn age: alder i år status: leversygdom, 1=ja albumin: serum albumin g/dL globulin: serum globulin g/dL ratio: ratio m. albumin og globulin l_ratio: log(ratio) (den naturlige logaritme)

Der defineres en binær variabel AG.positiv som $\text{ratio} < 1.1$ Det giver os denne tabel:

```
status <- c(rep(0, 99 + 66),
            rep(1, 308 + 106))

AG.positiv <- c(rep(1, 99), rep(0, 66),
               rep(1, 308), rep(0, 106))
table(AG.positiv, status)
```

```
      status
AG.positiv  0   1
0    66 106
1    99 308
```

a) Undesøg om der er en statistisk signifikant sammenhæng mellem de to variable.

Her kører vi en χ^2 test:

input:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.446661	0.320769	-1.392	0.16378
factor(AG.postiv)1	0.594643	0.199556	2.980	0.00288**
factor(sex)M	0.407717	0.211941	1.924	0.05439.
age	0.015131	0.005927	2.553	0.01069*

```
input <- matrix(c(66,106,99,308), ncol = 2, byrow = TRUE)
chisq.test(input, correct = FALSE)
```

Pearson's Chi-squared test

```
data: input
X-squared = 11.709, df = 1, p-value = 0.0006219
```

Det giver en teststørrelse på 11.7. Vi sætter `correct = FALSE` fordi de forventede værdier i tabellen er “store”, som i større end 5.

Det svarer til en p-værdi der er <0.001 . Så der er signifikant forskel. modelbesvarlsær bruger ofte formuleringen “klart signifikant”. teknisk set er der ikke noget der er mere signifikant end andet. det er signifikant på et bestemt niveau. Eller også er det ikke. Det er ikke “næsten” eller “meget” signifikant.

- b) Nu udfører vi følgende analyse i R: `> model <- glm(status~factor(AG.positiv)+factor(sex)+age, binomial)` `> summary(model)`

Den giver dette resultat:

Hvilken analyse er der tale om, og hvad kan vi konkludere på baggrund af det? Angiv relevant størrelse der kvantificerer effekten af AG.positiv. beregn tilhørende 95% KI.

Det er en logistisk regression med status som responsvariabel og AG.positiv og køn som kategoriske forklarende variable, og alder som kontinuær forklarende variabel. Alder og AG.positiv er signifikante i denne justerede analyse, kønnet er ikke.

OR for AG.positiv $\exp(0.594643) = 1.812384$ og vi estimerer derfor at odds for at status er 1 (at man er syg) er en faktor 1.8 større hvis AG.positive patienter, sammenlignet med AG.negative. KI: $\exp(0.594643 \pm c(-1,1)1.960.199556)$ Da det ikke indeholder 1, er resultatet signifikant (i overensstemmelse med hvad vi så fra p-værdien)

- c) Prædikter sandsynligheden for at have status 1 (syg) for en AG.positiv kvinde på 50.

Vi beregner: $-0.446661 + 0.594643 + 50 \cdot 0.015131 = 0.904532$

Det er logodds. Så vi finder sandsynligheden ved: odds er så: $\exp(0.904532) = 2.470775$ Og sandsynligheden finder vi ved: $\text{odds}/(1+\text{odds}) = 2.470775/(1+2.470775) = 0.7118799$

Bilirubin

Vi skal se på et randomiseret klinisk studie udført på seks forskellige europæiske hospitaler. 349 patienter med leversygdom blev randomiseret til enten den eksperimentelle behandling UDC (176 patienter) eller placebo (173 patienter)

Udfaldet “failure of medical treatment” blev defineret som enten død eller levertransplantation i den 6 årige undersøgelsesperiode. Patienter blev fulgt fra randomiseringstidspunktet til ovenstående udfald - eller til de 6 år var gået.

Vi får de første 6 observationer i sættet. Y er udfaldsvariablen (1 “treatment failure”), R angiver behandling (1 = UDC), X den standardiserede version af logaritmen af bilirubin (umol/L), målt for hver patient ved starten af studiet

```
library(tidyverse)
tribble(~Y, ~R, ~X,
  1, 1, 1.616854293,
  0, 1, 1.990367802,
  0, 1, -0.849360224,
  1, 1, 1.496709981,
  0, 1, 1.335441834,
  0, 1, -0.561678151)
```

```
# A tibble: 6 x 3
      Y     R     X
  <dbl> <dbl> <dbl>
1     1     1  1.62
2     0     1  1.99
3     0     1 -0.849
4     1     1  1.50
5     0     1  1.34
6     0     1 -0.562
```

table(Y,R) giver:

	R	
Y	0	1
0	118	134
1	55	42

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3922	0.2088	-6.668	2.60e-11***
factor(R)1	-0.9054	0.2967	-3.052	0.00227**
X	1.2632	0.1571	8.043	8.79e-16***

a) baseret på ovenstående table ønske beregnet relativ risiko (med tilhørende 95% KI) til belysning af effekten af behandlingen på det betragtede udfald. Husk at konkludere.

Risiko ved behandling: $42/(134+42) = 0.2386364$

Risiko ved placebo: $55/(118+55) = 0.3179191$

$RR = 0.2386364/0.3179191 = 0.7506199$

$\log(RR) = \log(0.7506199) = -0.2868559$

$se.(\log(rr)) = \sqrt{1/42 - 1/176 + 1/55 - 1/173} = 0.174726$

et 95% ki for $\log(rr)$ findes til: $-0.2868559 + c(-1,1)1.960.174726 = -0.62931886 \text{ } 0.05560706$

Derfor er 95% ki for RR: $\exp(c(-0.62931886, 0.05560706)) = 0.5329547 \text{ } 1.0571822$

RR er 0.75. Så vi estimerer at behandlingen reducerer treatment failure med 25% med et 95% KI på 0.5329547 1.0571822 Da 1 er indeholdt i KI er der dermed ikke tale om en signifikant effekt.

b) Nu udførtes følgende analyse: `> model <- glm(Y ~ factor(R) + X, family = "binomial")`
`summary(model)`

der gav dette output:

Hvilken analyse er der tale om. Angiv relevante effektestimater baseret på analysen og formuler konklusioner derfra.

Der er tale om en logistisk regressions analyse, med Y (Treatment failure) som afhængig variabel, og behandling/randomisering som kategorisk uafhængig, forklarende variable, samt X (den standardiserede logartime af bilirubin) som kontinuært forklarende variabel. Såvel behandlingen som X er statistisk signifikante på et 5% niveua.

For den forklarende variabel X får vi en estimeret odds ratio (OR) på behandlingen på $\exp(-0.9054) = 0.4043801$ når der kontrolleres for den forklarende variabel X.

Det tilhørende 95% konfidensinterval findes ved: $\exp(-0.9054 + c(-1,1)1.960.2967)$

OR på 0.4 svarer til en reduktion i odds for treatment failure på ca 60%, ved aktiv behandling vs. placebo, når der kontrolleres for bilirubin. Da KI ikke indeholder 1, er effekten signifikant.