

Powerberegninger

Også kendt som styrkeberegninger

WebR Status

 Ready!



Hvad katten er det?

Når vi laver statistiske test opstiller vi en NULL-hypotese; H_0 , og en alternativ hypotese, H_A .

Grundlæggende: Vi opstiller en hypotese om at der ikke sker noget. Eksempelvis at den sande forskel på to middelværdier er 0.

I de fleste tilfælde vil vi gerne kunne afvise H_0 .



Vi har prøvet det

To grupper, med hver deres middelværdi μ og standardafvigelse σ og antal observationer, n , i hver gruppe.

Beregn SEM for hver af grupperne: $SEM = \frac{\sigma}{\sqrt{n}}$

Beregn en poolet SEM for differencen:

$$SEM_{diff} = \sqrt{SEM_1^2 + SEM_2^2}$$

Og et 95% konfidensinterval:

$$(\mu_1 - \mu_2) \pm 1.96 SEM_{diff}$$

Ligger 0 i intervallet, er der ingen forskel (på et 5% signifikansniveau). Ligger det udenfor, er der forskel, og vi afviser H_0 (på et 5% signifikansniveau).



Hvad betød det?

Kan vi ikke afvise H_0 betyder det blandt andet at forskellen på middelværdierne ikke er så stor at vi kan konkludere at der faktisk er forskel.

Men det kunne være at der var en forskel alligevel.

α giver os den kritiske værdi. Den sammenligner vi med testværdien.

Vi har også set p-værdier. Det er risikoen for at vi afviser H_0 .
Selvom H_0 er sand.

Vi spørger grundlæggende om p-værdien er mindre end α . Er den det er vi normalt glade.



Det kan gå galt på to måder:

Type 1 fejl: Der ser ud til at være en effekt. Eller et positivt resultat.

Vi kan forkaste H_0

Men det er en fejl!

Der er *ikke* en effekt.

Data understøtter *ikke* den alternative hypotese

Det er en falsk positiv

Vi forkastede H_0 ved en fejl

På et $\alpha = 0.05$ niveau

Som er risikoen for at vi ser en falsk positiv.

Det er ikke så godt...



Eksistensen af type 1 fejl indikerer eksistensen af type 2 fejl

Og eksistensen af α indikerer eksistensen af β .

Vi kan også begå fejl på en anden måde.

Det gør vi, hvis test- eller p-værdien fortæller os at vi ikke kan forkaste H_0

Så konkluderer vi at der ikke er forskel. *Selvom der i virkeligheden er forskel!*

Det er en type 2 fejl. En falsk negativ.

Risikoen for at begå en type 2 fejl kan vi også sætte tal på.

Den kalder vi β



Det omvendte af β

Risikoen for at begå en type 2 fejl er en svaghed.

Det omvendte kalder vi power. Det er den “styrke” vores test har.

Eller

- Sandsynligheden for at testen finder forskellen, når forskellen faktisk findes!
- Power er sandsynligheden for *ikke* at begå en type 2 fejl.

Hvis β er risikoen for at vores test ikke finder forskellen, selvom den findes.

Så er power sandsynligheden for at vores test finder forskellen. Når altså den faktisk er der.

$$power = 1 - \beta$$



Hvad afhænger de her ting af?

Helt intuitiv.

Jo flere observationer vi har - jo større er chancen for at vi finder en forskel (der faktisk er der).

Jo mindre standardafvigelser vi har - jo større er chancen for at vi kan se forskelle på det vi sammenligner.

Jo større reel forskel der er, jo lettere bliver det at få øje på den.

Når α stiger, bliver det lettere at forkaste H_0 . Det bliver også lettere at finde en forskel hvis power stiger ($\sim \beta$ falder). Til gengæld stiger risikoen for falsk positive.



Vi har fem parametre

- Stikprøvestørrelserne (n)
- Standardafvigelserne (på stikprøverne, σ)
- Ønsket forskel vi vil kunne finde (δ)
- Risikoen for type 1 fejl (α)
- Risikoen for type 2 fejl (β)

Vi har en hemmelig sjette parameter. Nemlig hvilken test det er vi laver. Sammenligner vi middelværdier? Eller proportioner?

Hvis vi kender værdierne af fire af dem - så kan vi finde værdien af den femte.



Og hvad spørges der til til eksamen?

Her er fire værdier. Find den femte.

Eksempelvis: Vi ønsker et signifikansniveau på 5% og en power på 80%. Vi ønsker at kunne se en forskel på 42 i middelværdierne på to stikprøver, standardafvigelsen kan antages at være den samme i begge stikprøver. Der er 100 observationer i den ene stikprøve. Hvor mange skal der være i den anden?

Det er dog ikke et specielt hyppigt forekommende eksamensspørgsmål.



Det har R funktioner til.

- `power.t.test()`
- `power.prop.test()`
- `power.anova.test()`

Den sidste har jeg ikke set i eksamensopgaver, så den springer vi over.

Der er lidt flere detaljer, two sample eller one sample? Eller parret?

Giv dem fire af de fem parametre, og de beregner den femte.



Men dem bruger vi ikke...

For eksamen tester ikke om I kan putte tal ind i en funktion.

Eksamen tester om I har forstået nok til at I kan gøre det i hånden.

I har muligvis fået udleveret et notat om beregning af stikprøvestørrelser.

Det har jeg i hvert fald set at tidligere årgange har fået.

Sådan et notat har jeg ikke kunne finde.

Har I sådan et - så skal I bruge det!

Hvis I ikke har, så er der et bud på hvordan her.



I stedet

💥 Powerrelationen! 💪

$$\frac{\text{effekt}}{\text{standardfejl}} = z_{1-\alpha/2} + z_{1-\beta}$$

Den effekt vi ønsker at kunne se - divideret med standardfejlen, skal være lig med $z_{1-\alpha/2} + z_{1-\beta}$

Det gælder altid. Forskellen fra test til test bestemmer hvordan vi beregner standardfejlen.

Husk hvordan vi så på testværdierne. Var de langt nok væk fra 0 målt i standardfejl? Det er samme metode.

Vi skal blot lidt længere væk, fordi vi ikke bare lige akkurat skal forkaste H_0 . Vi skal være ekstra sikre - og hvor meget styres af den ønskede power.

“Altid” er med et par forbehold. Der antages normalitet. Det er mere kompliceret ved små stikprøver. Og ikke-lineære modeller. Og når standardfejlen afhænger af det vi prøver at estimere (her er der ingen simpel formel, og man simulerer i stedet)



De sære tegn

Lad os lige repetere:

$z_{1-\alpha/2}$ og $z_{1-\beta}$ kender vi godt.

$z_{1-\alpha/2}$ er kvantilen der matcher 0.975 (% observationer der er mindre end...). Det giver:

```
1 qnorm(1-0.05/2)
```

```
[1] 1.959964
```

Den har vi set før.

$z_{1-\beta}$ er kvantilen der matcher vores power. En power på 0.8 er populær (og det er så $\beta = 0.2$):

```
1 qnorm(1-0.2)
```

```
[1] 0.8416212
```



Hvordan beregnes standardfejlen?

Det har vi set før:

En middelværdi: $SE = \frac{\sigma}{\sqrt{n}}$

Forskel på to middelværdier:

$$SE = \sqrt{SE_1^2 + SE_2^2} = \sqrt{\left(\frac{\sigma_1}{\sqrt{n_1}}\right)^2 + \left(\frac{\sigma_2}{\sqrt{n_2}}\right)^2} = \sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

Forskel på to middelværdier, hvor grupperne er lige store:

$$SE = \sigma \sqrt{\frac{2}{n}}$$

Parrede målinger: $SE = \frac{\sigma_d}{\sqrt{n}}$ hvor σ_d er standardafvigelsen af forskellene



Hvordan beregnes standardfejlen?

En proportion: $SE = \sqrt{\frac{p(1-p)}{n}}$

Forskel mellem to proportioner: $SE = \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$

Forskel mellem to proportioner, hvor grupperne er lige store:

$$SE = \sqrt{\frac{p_1(1-p_1) + p_2(1-p_2)}{n}}$$



Et par fælder

Vi runder altid op. Hvis n beregnes til 7.8, runder vi op til 8.

Vi får næsten altid at vide hvor mange observationer der er i hver gruppe.

Hvis n er 8, skal vi bruge 16 observationer.

Undtagelsen er selvfølgelig hvis vi får at vide at der er 100 observationer i den ene gruppe. Så får vi svaret på hvor mange vi skal bruge i den anden gruppe.



Så er vi klar, lad os tage et eksempel!

Vi skal sammenligne en enzymkoncentration for patienter med en bestemt sygdom med en rask kontrolgruppe, således at der er lige mange patienter og kontroller i studiet. Hvor mange patienter skal inkluderes i studiet hvis forskelle i enzymkoncentrationen på mindre end 1 standardafvigelse () ikke er relevante.

Ønsket styrke er 80% eller 0.8, så $\beta = 1 - 0.8 = 0.2$,
signifikansniveauet sættes til 5%, så $\alpha = 0.05$.

Vi får lov at antage at enzymkoncentrationen varierer lige meget blandt patienter og kontroller.



Første trin

Hvilken type udfald?

Middelværdier - forskel på to grupper. Grupperne skal være lige store.

Hvordan ser vores standardfejl så ud?

$$SE = \sigma \sqrt{\frac{2}{n}}$$

Hvilken effekt ønsker vi at kunne se?

Ønsket effekt vi vil kunne se er 1σ



Opstil powerrelationen

$$\frac{\text{effekt}}{\text{standardfejl}} = z_{1-\alpha/2} + z_{1-\beta}$$

Venstre side:

$$\frac{\text{effekt}}{\text{standardfejl}} = \frac{\sigma}{\text{SE}} = \frac{\sigma}{\sigma \sqrt{\frac{2}{n}}} = \frac{1}{\sqrt{\frac{2}{n}}}$$

Den skal være lig med

$$z_{1-\alpha/2} + z_{1-\beta} = z_{1-0.05/2} + z_{1-0.2} = z_{0.975} + z_{0.8}$$

Eller:

```
1 qnorm(0.975) + qnorm(0.8)
```

```
[1] 2.801585
```



Så er vi klar til at regne

Højre side:

`qnorm(0.975) +
qnorm(0.8)`

$$\frac{1}{\sqrt{\frac{2}{n}}} = 2.801585$$

$$1 = \sqrt{\frac{2}{n}} \cdot 2.801585$$

$$1^2 = \frac{2}{n} \cdot 2.801585^2$$

$$n = 2 \cdot 2.801585^2$$

Og resultatet er pr gruppe!
Husk at runde op!

```
Run Code
1
```



Del to af opgaven

Samme opgave som før.

Men nu får vi oplyst at der allerede er målinger af enzym koncentrationen fra 100 kontroller.

Hvor mange patienter har vi så brug for (med samme forudsætninger som tidligere).

Bemærk at vi nu ikke længere har lige mange i hver gruppe!



Hvordan ser vores standardfejl så ud?

$$SE = \sqrt{\frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2}} = \sqrt{\sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} = \sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

Vi skal stadig bruge powerrelationen:

$$\frac{\text{effekt}}{\text{standardfejl}} = z_{1-\alpha/2} + z_{1-\beta}$$

Og effekten er stadig 1σ



Næste trin

Indsæt i powerrelationen:

$$\frac{\text{effekt}}{\text{standardfejl}} = \frac{\delta}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} = z_{1-\alpha/2} + z_{1-\beta}$$

$$\delta = \sigma \text{ og } n_1 = 100$$

Så skal vi “bare” isolere n_2



Så er vi klar til at regne

$$\frac{\sigma}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \\ = z_{1-0.05/2} + z_{1-0.2}$$

Det tager vi nok lettest på en
tavle

```
Run Code
1
```



Lad os prøve en gang til

Fødselsvægten for børn født indenfor termin med gestationsalder 40 uger antages approksimativt normalfordelt med middelværdi 3500 gram og spredning 430 gram. Vi antager at det er populationsværdier

Det ønskes undersøgt om fødselsvægten for børn hvis mødre røg gennem hele graviditeten har samme middelværdi (μ).

Hvis der indsamles n observationer af fødselsvægten af børn af disse mødre, hvilken test ville vi så anvende for at undersøge om deres gennemsnitlige fødselsvægt X er lig $\mu = 3500$?

Angiv konkret teststørrelse beregnet baseret på de n observationer.

Vi vil skulle beregne SEM for disse børn $\left(\frac{\sigma}{\sqrt{n}} \right)$

Og dernæst teststørrelsen: $\frac{X-3500}{SEM}$



Og så til powerberegningen

Hvis den sande μ er under 3200 gram (eller over 3800 gram), og vi kun vil acceptere en 10% risiko for ikke at opdage en sådan forskel på de to middelværdier, hvor stor en stikprøve skal der så anvendes, med et signifikans niveau på 5%.

Hvad er H_0 og H_A ?

$$H_0 : \mu = 3500$$

$$H_A : \mu \neq 3500$$



Hvad får vi oplyst?

Ønsket afvigelse vi skal kunne opdage:

$$\delta = 3800 - 3500 = 300$$

Risikoen for ikke at opdage forskellen må være på 10%:

$$\beta = 0.1$$

Eller: Power = 0.9

Signifikansniveau 5%: $\alpha = 0.05$

Standardafvigelse $\sigma = 430$



Powerrelationen opstilles

$$\frac{\text{effekt}}{\text{standardfejl}} = \frac{\delta}{SE} = z_{1-\alpha/2} + z_{1-\beta}$$

$$\beta = 0.1, \delta = 430, SE = \frac{\sigma}{\sqrt{n}},$$

$$\sigma = 430$$

$$z_{1-\alpha/2} + z_{1-\beta} = \frac{300}{\frac{430}{\sqrt{n}}}$$

Isoler n - det gør vi på tavlen

▶ Run Code

1



Del 2

Hvis vi vil have en stikprøve på 100 - hvor stor en forskel på μ og 3500 kan vi forvente at kunne finde.

Samme forudsætninger som før.



Opstil powerrelationen

```
Run Code
1
```

$$\frac{\text{effekt}}{\text{standardfejl}} = \frac{\delta}{SE} = z_{1-\alpha/2} + z_{1-\beta}$$

Det er den størrelse vi kan forvente at opdage (mindst)

$$\beta = 0.1, SE = \frac{\sigma}{\sqrt{n}}, \sigma = 430, \text{ med en sandsynlighed p\u00e5 90\%}$$
$$n = 100$$

$$z_{1-\alpha/2} + z_{1-\beta} = \frac{\delta}{\frac{430}{\sqrt{100}}}$$

Isoler δ - det g\u00f8r vi p\u00e5 tavlen



Husk dog!

Det her er til eksamensbrug.

Når I skal til at lave forskning, så bør I basere jer på t-fordelingen i stedet.

Den er bredere, og kan håndtere at variansen ikke er kendt, men skal estimeres.

Den kan også klare sig med færre observationer.

Og når I planlægger forsøget: Så finder I hvor mange observationer/patienter I skal bruge teoretisk.

Og ganger med 2 for at få noget sikkerhedsmargen på det.

