

Konfidensintervaller og hypotesetests

Standard Error of the Mean

WebR Status

 Ready!



Hvorfor var normalfordelingen vigtig?

Der er ofte typeopgaver til eksamen hvor I skal demonstrere at I forstår den

Og hvor I skal bruge q_{norm} og p_{norm} til at regne frem og tilbage.



Men også fordi!

Vi kunne *rigtig* godt tænke os at vide hvad det gennemsnitlige systoliske blodtryk for en gruppe patienter er.

Det er ikke realistisk at måle blodtryk på *alle* patienter i den gruppe.

I stedet kan vi tage en stikprøve, og måle blodtrykket på de patienter.

Men det fortæller os kun hvad gennemsnittet er i *den* stikprøve.

Ikke hvad den “sande” middelværdi for *hele* populationen er.

Vi har normalt “kun” en stikprøve, som vi har trukket fra populationen.

Vi kender ikke den “sande” middelværdi i populationen.

Eller den “sande” spredning/standardafvigelse

Men vi vil stadig *rigtig* gerne kunne sige noget om hvad den “sande” middelværdi er.



Den centrale grænseværdisætning

Tager vi tilstrækkeligt mange (tilpas store) stikprøver, vil disse stikprøvers middelværdier følge en fordeling.

Det vil være en normalfordeling

Den normalfordeling vil have en middelværdi der er lig med den “sande” middelværdi for populationen.



CLT?

Vi er interesseret i gennemsnitshøjden af danske mænd. Vi ved ikke hvilken sandsynlighedsfordeling der beskriver danske mænds højde.

Så vi tager en stikprøve på eksempelvis 20 mænd fra populationen (alle danske mænd) og måler deres højde.

Vi beregner gennemsnittet af den stikprøve og gemmer det.

Det gentager vi mange gange. Ny stikprøve - mål - beregn gennemsnit. Ny stikprøve - mål - beregn gennemsnit.

Det gør vi mange gange.

Det giver en masse gennemsnit/middelværdier.

De middelværdier vil følge normalfordelingen.

Uanset hvilken sandsynlighedsfordeling danske mænds højde følger.

Det kan man føre bevis for. Men det springer vi over.



En gang til - det er vigtigt!

Hvis vi tager mange stikprøver, og beregner deres middelværdier. Så vil de middelværdier følge normalfordelingen.

Det gælder kun hvis stikprøven er tilpas stor. Ofte er 30 nok.


Hvis populationen selv er normalfordelt, er middelværdien normalfordelt uanset størrelsen af stikprøven.

Bemærk at vi ikke kender disse middelværdiers spredning. Eller hvad middelværdien af middelværdierne er. Det kommer vi til.



CLT demo

▶ Run Code



```
1 data <- mean(rexp(20))
2 data <- c(data, mean(rexp
  (20)))
3 hist(data, main = length
  (data))
```



Hvordan hjælper det os?

Vi har tidligere set hvordan vi beregnede et 95% normalområde for en værdi.

Det krævede at vi havde middelværdien, og standardafvigelsen.

Nu har vi mange middelværdier. Hvis vi havde “standardafvigelsen” for de middelværdier.

Så kunne vi beregne et interval, hvor 95% af middelværdierne fra stikprøverne var.

Det kalder vi et 95% konfidensinterval



Hvad er et 95% konfidensinterval?

Det område, hvor, hvis værdierne var normalfordelte, vi kan forvente at finde 95% af dem.

Middelværdierne af stikprøverne vil, når vi har nok af dem, være normalfordelte.

Så 95% af vores stikprøver vil have en middelværdi der ligger inden for det område.



Hvad er et 95% konfidensinterval?

Vi kan også formulere det som:

Vi har et estimat. Det er vores bedste bud. Men vi ved at det nok ikke er 100% korrekt. Det er næppe den “sande” værdi.

Men vi kan beregne et interval.

Intuitivt kan vi forstå det interval, som at vi er 95% sikre på indeholder den sande værdi.

Eller mere korrekt, at hvis vi beregner et interval ud fra tilstrækkeligt mange stikprøver, så vil den sande værdi være indeholdt i 95% af de intervaller.




så

Hvis vi kender spredningen på stikprøvens middelværdier.

Kan vi beregne et 95% KI for den middelværdi.

Det interval vil, i 95% af tilfældene, indeholde den sande middelværdi for populationen.



Hvordan beregner vi så det?

Da vi beregnede normalområdet skulle vi bruge en middelværdi og en standardafvigelse.

Standardafvigelsen fortæller hvordan de enkelte målinger i vores stikprøve afviger fra middelværdien af stikprøven.

Ikke hvordan middelværdierne fra mange stikprøver afviger.

Vi springer matematikken over, men spredningen af middelværdien af stikprøven kalder vi “Standard Error of the Mean”. SEM blandt venner.

Og den vi beregner vi ved

$$SEM = \frac{\sigma}{\sqrt{n}}$$

Vi har et estimat på “mean”. Der ikke 100% korrekt. Det har en fejl, “error”. Hvad er vores bedste bud på størrelsen af den fejl? SEM.



Hvordan regner vi så?

Vi fandt 95% normalområdet ved

$$\mu \pm 1.96 \cdot \sigma$$

Vi finder så 95% konfidensintervallet ved

$$\hat{x} \pm 1.96 \cdot \text{SEM}$$

Og SEM fandt vi ved:

$$\text{SEM} = \frac{s}{\sqrt{n}}$$

n er antallet af observationer. Og vi skriver s i stedet for σ fordi?

σ er den “sande” standardafvigelse i populationen. Vi har ikke målt på hele populationen. Så den kender vi ikke, og derfor bruger vi s i stedet



En del af en eksamensopgave

Vi får oplyst “summeriske regnestørrelser” for plasma magnesium for diabetikere. Vi får lov at antage at plasma magnesium er normalfordelt for de to populationer stikprøverne er trukket fra:

gruppe	Antal	Gennemsnit	Spredning
Diabetikere	227	0.719	0.068
Ikke-diabetikere	140	0.810	0.057

Beregn 95% konfidensinterval (KI) for hver af de to grupper.

Ja, det ligner noget vi har set før. Dengang skulle vi se på det interval der indeholdt 95% af observationer. Nu skal vi estimere to middelværdier.

```
Run Code
1
```



Testværdi

Vi fandt et 95% KI for plasma-magnesium for diabetikere: [0.7101539, 0.7278461]. SEM var 0.004513319

Nu får vi en værdi for plasma-magnesium for ikke-diabetikere. Det giver os et estimat for plasma-magnesium for ikke-diabetikere på 0.810.

Er den så tæt på værdierne for diabetikerne, at vi ikke kan se forskel? Eller er den så langt væk at vi kan konkludere, at den nok er forskellig?

Vi kan intuitivt se at hvis 0.810 ikke er indeholdt i KI, og KI med 95% sikkerhed indeholder den sande værdi - så er 0.810 nok så langt væk fra den sande værdi, at der må være en forskel.

Eller at 0.81 ligger så langt væk fra 0.719, at sandsynligheden for at 0.81 er indeholdt i konfidensintervallet, er *meget* lille.



Testværdi

Man kan også se, at:

$$\frac{0.810 - 0.719}{SEM} = \frac{0.810 - 0.719}{0.004513319} = 20.16255$$

Det er det samme som:


$$0.81 = 0.719 + 20.16255 \cdot SEM$$

Vi kalder 20.16255 for testværdien.

Den kritiske værdi ved 95% er 1.96. Er 20.16255 større? Ja, så ligger værdien længere væk end 1.96 standardfejl fra (estimatet for) middelværdien. Og så ligger den udenfor 95% konfidensintervallet.



Visualiseret



Hypotesetest

Det var en hypotesetest.

Vi testede om 0.810 kunne være indeholdt i konfidensintervallet på $[0.7101539, 0.7278461]$ og $SEM = 0.004513319$.

Det kan vi se at den ikke er. Afvigelsen er stor, men det kunne jo være et statistisk tilfælde.

Hvordan tester vi det mere generelt?



Hvad er en hypotese

En antagelse om en parameter i populationen.

- En bestemt middelværdi, eg $\mu = 0.81$
- En bestemt forskel på to middelværdier, ofte som $\mu_1 - \mu_2 = 0$
- En bestemt andel eller ratio (senere)

Vi opstiller en null-hypotese H_0 :

- $\mu = 0.81$
- $\mu_1 - \mu_2 = 0$

Eller mere generelt $\theta = \theta_0$. θ_0 den konkrete værdi vi tester parameteren imod, eg. 0.81 eller 0.

I praksis “ingen forskel” eller “ingen effekt”.

Vi skriver θ fordi theta starter med t, og det er vores testværdi. Det er mere generelt end μ , og tillader os at bruge samme notation uanset om det er middelværdier eller noget andet vi tester. Vi kalder H_0 for “null”-hypotesen, fordi “null” er en prætentios måde at sige “ingenting”. Og vi tester om der ingen effekt er. Ofte kalder vi den så nul-hypotesen i stedet, fordi vi jo skriver 0 i H_0 .



Den alternative hypotese

Kaldet H_A , enten at

- $\mu \neq 0.81$
- $\mu_1 - \mu_2 \neq 0$

Det er tosidet. Der μ kan være større eller mindre, vi er ligeglade og kun interesseret i om der er en forskel.

Eller, ensidet:

- $\mu > 0.81$ eller
- $\mu < 0.81$

Tosidet: Enhver forskel

Ensidet: En forskel i en bestemt retning



Kernen i hypotesetesten

Vi har en null-hypotese, $H_0 : \theta = \theta_0$.

Hvor vi tester om θ_0 kunne være den “sande” værdi i populationen; givet vores data, som har givet os et estimat $\hat{\theta}$ fra vores observationer.

Vi kigger lige nu på middelværdier og ville normalt skrive μ . Men bruger θ fordi vi så kan generalisere.

Hvor langt ligger estimatet fra H_0 , målt i standardfejl?

Ligger den for langt væk, *forkaster* vi H_0 . Det betyder *ikke* (!) at H_A er sand eller bevist.



Hvor langt er for langt?

Hvis estimatet ligger “for langt” fra H_0 , forkaster vi H_0 (og konkluderer at data understøtter H_A).

Når vi skal tage stilling til hvor langt for langt er, skal vi vælge hvor stor risiko vi vil løbe for at forkaste H_0 . Selvom H_0 faktisk er sand.


Den risiko betegner vi α . Normalt sætter vi den til 5%, eller 0.05.

Vær vågne hvis opgaven taler om noget som helst andet!



Det er den kritiske værdi


To-sidet. Hvor vi er interesseret i enhver forskel:



Ensidet - større end

Ensidet test: større end


Vi forkaster kun i højre hale



Ensidigt - mindre end

Ensidet test: mindre end

Vi forkaster kun i venstre hale



Den kritiske værdi

Hvis vi vil finde enhver forskel, typisk at $\mu_1 - \mu_2 = 0$, er vi ligeglade med om testværdien er “for lille” eller “for stor”. De 5% risiko vi accepterer kan derfor ligge på begge sider af kurven.

Har vi $\alpha = 0.5$ skal den altså fordeles på begge sider og vi bruger:

```
1 c(-1,1)*qnorm(1 - 0.05/2)
```

```
[1] -1.959964  1.959964
```

Hvis vi er interesseret i om en værdi er mindre ($H_A : \theta < \theta_0$) - så må testværdien gerne være for stor. Den må blot ikke være for lille.

```
1 qnorm(0.05)
```

```
[1] -1.644854
```

Og hvis vi er interesseret i om en værdi er større ($H_A : \theta > \theta_0$) - så må testværdien gerne være for lille. Den må blot ikke være for stor.

```
1 qnorm(1-0.05)
```

```
[1] 1.644854
```



Testværdien

Vi har besluttet hvilken hypotese vi vil teste.

Vi har fundet den kritiske værdi - ud fra ønsket α og retningen af testen.

Så mangler vi blot testværdien, som vi skal sammenligne med den kritiske værdi.

Der skal bruges to ting:

Hvad er afstanden fra vores estimat til H_0 , og

Hvad er standardfejlen

Den skal vi nemlig bruge beregne afstanden målt i standardfejl.



Afstanden

Vi havde den generelle $H_0 : \theta = \theta_0$

Eller hvis vi taler om middelværdier: $H_0 : \mu = \mu_0$

Vi havde også et estimat på hvad μ kunne være. Det fik vi fra vores data. Vi bør kalde den for $\hat{\mu}$.

Afstanden finder vi så ved at trække μ_0 fra $\hat{\mu}$

Så hvis vores estimat var 0.719 og vores null-hypotese var $\mu = 0.81$

Er afstanden: $0.719 - 0.81 = -0.091$

Middelværdier ved vi godt hvordan vi beregner.

Men vi bliver normalt ikke bedt om det til eksamen - der får vi dem oplyst.

Hvis vi skal sammenligne to middelværdier er H_0 typisk at forskellen på dem er 0.

Til eksamen får vi typisk enten oplyst to middelværdier, trækker så den ene fra den anden.

Eller også får vi oplyst hvad forskellen er på dem.



Standardfejlen

Vi skulle måle afstanden i enheder af standardfejlen.

Den afhænger af *hvad* vi tester - ikke af hypotesen!

For en enkelt middelværdi: $SEM = \frac{\sigma}{\sqrt{n}}$

Hvis vi sammenligner to middelværdier der ikke er parrede:

$$SE(\hat{\mu}_1 - \hat{\mu}_2) = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

Og hvis data er parrede:

$$SE(\bar{d}) = \frac{s_d}{\sqrt{n}}$$

Oftentimes we don't know the "true" σ but have an estimate of standard deviations from data. So we use Latin letters instead of Greek. The mathematics is the same.



Hov! Hvad betyder parret?

Ikke-parrede data kommer fra to uafhængige grupper. Med forskellige individer i hver gruppe.

- Behandling vs kontrol
- Kvinder vs mænd

Her har vi to separate middelværdier. Og undersøger variation mellem personer.

Parrede data kommer fra to grupper der *ikke* er uafhængige. Så de afhænger!

- Samme individer målt to gange
- Matchede par

Det kan være

- Før og efter behandling
- Tvillinger/matchede personer

Her undersøger vi variation indenfor “samme” person.



Trin for trin

- Opstil H_0
- Er den alternative hypotese en- eller tosidet?
- Vælg signifikansniveau (typisk 0.05)
- Bestem den kritiske værdi (afhænger af: En- eller tosidet og α)
- Beregn estimatet
- Beregn standardfejlen
- Beregn testværdien
- Sammenlign testværdi med kritisk værdi
- Konkluder: Forkaster vi H_0 ? ja eller nej.



Tilbage til plasma magnesium

Vi fik oplyst “summeriske regnestørrelser” for plasma magnesium for diabetikere og ikke diabetikere. Og måtte antage normalfordeling i de to populationer:

```
# A tibble: 2 × 4
  gruppe      Antal Gennemsnit Sprdning
  <chr>      <dbl>      <dbl>      <dbl>
1 Diabetikere    227      0.719      0.068
2 Ikke-diabetikere 140      0.81       0.057
```

Vi beregnede 95% konfidensintervaller på hver af de to grupper, og konstaterede at middelværdien for diabetikere ikke er indeholdt i KI for ikke-diabetikere og omvendt, og at der derfor var signifikant forskel på niveauet.

Det var i hvert fald konklusionen i modelbesvarelsen.

Hvordan kunne vi ellers teste - når nu vi har lært den generelle metode for hypotesetestning?



Forskellen på middelværdierne

Er den 0?

Eller:

$$H_0 : \mu_{dia} - \mu_{ejdia} = 0$$

Er den alternative hypotese en- eller to-sidet?

Vi er ude efter enhver forskel, så to-sidet.

Signifikansniveau?

$$\alpha = 0.05$$

Det er et valg vi træffer.



Forskellen på middelværdierne

Hvad er så den kritiske værdi?

1.96

eller

```
1 c(-1,1)*qnorm(1-0.05/2)
```

```
[1] -1.959964  1.959964
```



Forskellen på middelværdierne

Og hvor langt er vores estimat fra H_0 ?

$$H_0 : \mu_{dia} - \mu_{ejdia} = 0$$

$\mu_{dia} = 0.719$, $\mu_{ejdia} = 0.810$, så vores estimat er:

$$0.719 - 0.810 = -0.091$$

Og afstanden fra H_0 er så: $0 - -0.091 = 0.091$



Forskellen på middelværdierne

Hvad er standardfejlen?

Hvor mange samples?

To. Er de parrede?

Nej.

Så skal vi bruge:

$$SE(\hat{\mu}_1 - \hat{\mu}_2) = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

$$s_1 = 0.068, n_1 = 227$$

$$s_2 = 0.057, n_2 = 140$$

$$\text{og derfor: } SE_{diff} = \sqrt{\frac{0.068^2}{227} + \frac{0.057^2}{140}} = 0.00660$$



Forskellen på middelværdierne

Hvor stor er forskellen så, målt i standardfejl?

$$0.091/0.00660 = 13.78788$$

Er den større end den kritiske værdi?

Ja.

Hvad betyder det?

At vores estimat ligger så langt fra H_0 , at vi kan forkaste H_0 , at forskellen på de to middelværdier er 0.

Og det kan vi med en sikkerhed på $\alpha = 0.05$



Ændring i blodtryk

En gruppe patienter deles op i to, kontrol (318 patienter) og behandling (intervention, 323 patienter).

Der måles blodtryk før behandling (baseline), og efter 12 måneders behandling.

Forskellen i systolisk blodtryk mellem baseline og efter 12 måneder, oplyses som “diff”.

For kontrolgruppen får vi oplyst at forskellen er -16.6 mmHg og spredningen er 19.9

For interventionsgruppen er de tilsvarende tal -19.6 og 17.4

Vi skal nu finde ud af om der er et signifikant fald i blodtrykket for interventionsgruppen.

Det ser jo ud til at det falder. Forskellen er -19.6, men er det signifikant? Kunne det tænkes at den sande middelværdi er 0?



Ændring i blodtryk - intervention

Hvad er konfidensintervallet på forskellen?

For interventionsgruppen:

Fald: -19.6

Spredning: 17.4

▶ Run Code

↺

📄

1



Ændring i blodtryk - kontrol

Hvad er konfidensintervallet
på forskellen?

Samme beregninger - nu

For kontrolgruppen:

Fald: -16.6

Spredning: 19.9

▶ Run Code

↺

📄

1



Bredde af konfidensinterval

Vi får oplyst et konfidensinterval for fødselsvægte (g): [3561.5; 3583.4].

Beregnet baseret på 11279 kvinder.

Hvor meget bredere havde konfidensintervallet været, hvis vi kun havde haft data for 200 kvinder?

Hint: $SEM = \frac{sd}{\sqrt{n}}$

▶ Run Code

↺ ↻

```
1
```



En anden eksamensopgave - forskel på middelværdier

Vi undersøger effekten af et blodtrykssænkende præparat i sammenligning med placebo.

Vi får oplyst regnestørrelser for det systoliske blodtryk i mmHg for de to grupper:

```
# A tibble: 2 × 4
  Gruppe      n gennemsnit spredning
  <chr>    <dbl>      <dbl>    <dbl>
1 Behandling    82      152.     18.4
2 Placebo      90      156.     19.1
```

må

Vi har to samples. Så vi bruger two-sample t-test. Vi er ude efter at se om forskellen mellem de to grupper 152.5-156.5 er



videre - ønsket størrelse af konfidensinterval

Lidt kringlet eksamensspørgsmål

Hvis antallet af forsøgspersoner der skal have behandlingen kaldes n_1 og antallet af personer i kontrollen (placebo) kaldes n_0 . og vi vil have at der er dobbelt så mange i kontrolgruppen som i forsøgsgruppen ($n_0 = 2 \cdot n_1$). hvor mange personer skal vi så have ialt, hvis det 95% konfidensinterval vi beregnede lige før får længden 8. Givet at spredningerne er uændrede.

Puha.

Svaret vil være $n_0 + n_1$. Eller, $3 \cdot n_1$ fordi n_0 er lig $2n_1$

Konfidensintervallet skal have en længde på 8.



endnu en eksamensopgave

Vi har en population -
fordelingen af hæmoglobin i
populationen er
normalfordelt. middelværdi μ
= 13.3 g/100 ml. Spredning σ =
1.12 g/100 ml.

Vi udtager stikprøver af
størrelsen n . For hver af de
stikprøver beregnes
stikprøvegennemsnittet. Disse
stikprøvegennemsnit er
normalfordelte med

```
Run Code
1
```



del b

Hvis vi sætter n til 15, hvilken andel af stikprøverne vil ligge mellem 13.0 og 13.6 g/100ml?

...

$$P(13.0 < X < 13.6)$$

...

$$P(X < 13.6) - P(X < 13.0)$$

...

$$\text{standardiser. SEM} = \frac{\sigma}{\sqrt{n}},$$

$$\mu = 13.3$$

```
Run Code
1
```



del c

Hvor stor skal n være hvis 95% af stikprøverne skal have et snit der ligger mellem $\mu - 0.2$ og $\mu + 0.2$

... 95% intervallet er:

$$\mu \pm 1.96SEM$$

...

$$\text{Så } 1.96SEM = 0.2$$

...

$$1.96 \frac{\sigma}{\sqrt{n}} = 0.2$$

```
Run Code
1
```



Hoppeeksamensopgave

man har undersøgt 249 børn for hvor langt de kan hoppe. Der er følgende variable i datasættet:

idnr: løbenummer for personen gender: Køn, 1 dreng, 2 pige

age: barnets alder height: barnets højde i cm cohR: Længde af

hop på højre ben (cm) cohL: Længde af hop på venstre ben

(cm) diff: forskel på cohR og cohL

Vi får også oplyst de første fire observatiner:

```
# A tibble: 4 × 7
  idnr gender age height cohR cohL diff
<dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1     1     1    10   148.   186.   207.  -21.4
2     2     2     9   136.   257.   223.   34.4
3     3     1     9   139.   204.   250.  -46.8
4     4     2     9   138.   347.   388.  -41.4
```

Og noget summarisk data: >mean(cohR) 270.441 >mean(cohL)

